



UNIVERSIDAD DE GRANADA

TRABAJO FIN DE MÁSTER
MASTER EN CIENCIA DE DATOS

Compensating for Patient Heterogeneity Bias

in Glucose Prediction Models via Data Balancing

Autor

Juan Ricardo Hernández Sánchez-Agosta (estudiante)

Director/es

Oresti Baños Legrán (tutor 1)

Claudia Villalonga Palliser (tutor 2)



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE TELECOMUNICACIÓN

Granada, 5 de agosto de 2026



Compensating for Patient Heterogeneity Bias

in Glucose Prediction Models via Data Balancing

Autor

Juan Ricardo Hernández Sánchez-Agosta (estudiante)

Director/es

Oresti Baños Legrán (tutor 1)
Claudia Villalonga Palliser (tutor 2)

Compensating for Patient Heterogeneity Bias: in Glucose Prediction Models via Data Balancing

Juan Ricardo Hernández Sánchez-Agosta (estudiante)

Palabras clave: diabetes mellitus tipo 1, predicción de glucosa, monitorización continua de glucosa (CGM), LSTM, balanceo demográfico, equidad algorítmica, series temporales, validación cruzada por grupos.

Resumen

La predicción de glucosa en sangre es una herramienta clave en la gestión de la diabetes mellitus tipo 1 (DM1), ya que permite anticipar episodios de hipoglucemia e hiperglucemia y mejorar la calidad de vida de los pacientes. Los modelos de aprendizaje profundo basados en redes LSTM (*Long Short-Term Memory*) han demostrado un rendimiento sólido en este dominio gracias a su capacidad de capturar dependencias temporales complejas en señales de monitorización continua de glucosa (CGM). Sin embargo, la heterogeneidad demográfica de las cohortes disponibles —en particular las diferencias de edad y sexo— puede introducir sesgos sistemáticos en el entrenamiento, comprometiendo la equidad y la generalización de estos modelos hacia subgrupos infrarrepresentados.

Este Trabajo Fin de Máster parte de la hipótesis de que equilibrar la composición demográfica del conjunto de entrenamiento mejora el rendimiento clínico de un modelo LSTM de predicción de glucosa, especialmente para los subgrupos minoritarios. Para contrastarla, se diseña e implementa un *pipeline* experimental de balanceo aplicado exclusivamente a los pliegues de entrenamiento en un esquema de validación cruzada por grupos (*Group K-Fold*), que garantiza la separación estricta de pacientes entre particiones. Se evalúa una taxonomía de técnicas de balanceo —organizadas en familias aleatorias, guiadas e híbridas— aplicadas sobre dos dimensiones demográficas (edad y sexo) más una condición de control sin balanceo, en tres conjuntos de datos de CGM con características estructurales distintas: **T1DiabetesGranada** (643 pacientes, más de 30 millones de mediciones), **REPLACE-BG** y **DiaTrend**.

El análisis estadístico combina pruebas de Friedman, comparaciones *post-hoc* de Nemenyi, tamaños del efecto de Cohen's *d* y agregación de *rankings* mediante el método de Borda, con el fin de determinar si el balanceo demográfico produce efectos significativos y consistentes, y en qué condiciones resulta beneficioso desde una perspectiva clínica.

Compensating for Patient Heterogeneity Bias: in Glucose Prediction Models via Data Balancing

Juan Ricardo Hernández Sánchez-Agosta (estudiante)

Keywords: type 1 diabetes mellitus, blood glucose prediction, continuous glucose monitoring (CGM), LSTM, demographic balancing, algorithmic fairness, time series, group cross-validation.

Abstract

Blood glucose prediction is a key tool in the management of type 1 diabetes mellitus (T1DM), enabling the anticipation of hypoglycaemic and hyperglycaemic episodes and improving patients' quality of life. Deep learning models based on LSTM (*Long Short-Term Memory*) networks have demonstrated strong performance in this domain owing to their ability to capture complex temporal dependencies in continuous glucose monitoring (CGM) signals. However, the demographic heterogeneity inherent to available patient cohorts —particularly differences in age and sex— may introduce systematic biases during training, compromising the fairness and generalisation of these models towards underrepresented subgroups.

This Master's Thesis starts from the hypothesis that demographically balancing the training set improves the clinical performance of an LSTM-based glucose prediction model, especially for minority subgroups. To test this hypothesis, an experimental balancing *pipeline* is designed and implemented, applied exclusively to the training folds within a patient-wise cross-validation scheme (*Group K-Fold*) that enforces strict patient separation across partitions. A taxonomy of balancing techniques —organised into random, guided, and hybrid families— is evaluated across two demographic dimensions (age and sex) alongside an unbalanced control condition, on three CGM datasets with distinct structural characteristics: **T1DiabetesGranada** (643 patients, over 30 million readings), **REPLACE-BG**, and **DiaTrend**.

The statistical analysis combines Friedman tests, Nemenyi *post-hoc* comparisons, Cohen's *d* effect sizes, and Borda count ranking aggregation, with the aim of determining whether demographic balancing produces significant and consistent effects, and under which conditions it proves beneficial from a clinical standpoint.

Keywords: type 1 diabetes mellitus, blood glucose prediction, continuous glucose monitoring (CGM), LSTM, demographic balancing, algorithmic fairness, time series, group cross-validation.

Yo, **Juan Ricardo Hernández Sánchez-Agesta** (estudiante), alumno del **MÁSTER DE CIENCIA DE DATOS E INGENIERÍA DE COMPUTADORES**, con DNI **78154358-J**, autorizo la ubicación de la siguiente copia de mi Trabajo Fin de Máster en la biblioteca del centro para que pueda ser consultada por las personas que lo deseen.

Fdo: *Juan Ricardo Hernández Sánchez-Agesta (estudiante)*

Granada a 5 de agosto de 2026.

D. **Oresti Baños Legrán (tutor 1)**, Profesor del Área de Ingeniería de Computadores, Automática y Robótica del Departamento Ingeniería de Computadores, Automática y Robótica de la Universidad de Granada.

D. **Claudia Villalonga Palliser (tutor 2)**, Profesor del Área de Ingeniería de Computadores, Automática y Robótica del Departamento de Ingeniería de Computadores, Automática y Robótica de la Universidad de Granada.

Informan:

Que el presente trabajo, titulado *Compensating for Patient Heterogeneity Bias, in Glucose Prediction Models via Data Balancing*, ha sido realizado bajo su supervisión por **Juan Ricardo Hernández Sánchez-Agosta (estudiante)**, y autorizamos la defensa de dicho trabajo ante el tribunal que corresponda.

Y para que conste, expiden y firman el presente informe en Granada a 5 de agosto de 2026.

Los directores:

Oresti Baños Legrán (tutor 1) Claudia Villalonga Palliser (tutor 2)

Yo, **Juan Ricardo Hernández Sánchez-Agesta** (estudiante), alumno del **MÁSTER DE CIENCIA DE DATOS E INGENIERÍA DE COMPUTADORES** de la **Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación de la Universidad de Granada**, con DNI **78154358-J**, declaro explícitamente que el trabajo presentado es original, entendido en el sentido que no he utilizado ninguna fuente sin citarla debidamente.

Fdo: **Juan Ricardo Hernández Sánchez-Agesta** (estudiante)

Granada, 5 de agosto de 2026.

Agradecimientos

Poner aquí los agradecimientos.

Índice general

1. Introducción	1
1.1. Motivación	2
1.2. Objetivos	2
1.3. Estructura del trabajo	3
2. Fundamentación teórica	5
2.1. Contexto clínico: DM1 y monitorización continua de glucosa	5
2.1.1. Diabetes mellitus tipo 1: fisiopatología y desafíos de gestión	5
2.1.2. Monitorización continua de glucosa: principio de funcionamiento y métricas clínicas	6
2.1.3. Métricas de error en predicción de glucosa	7
2.2. Aprendizaje profundo para series temporales: redes LSTM	7
2.2.1. Redes neuronales recurrentes: motivación y limitaciones	7
2.2.2. Redes LSTM: arquitectura y mecanismo de puertas	8
2.2.3. Predicción de glucosa como regresión temporal con ventana deslizante	8
2.2.4. Validación cruzada por grupos en datos de pacientes	9
2.3. <i>Imbalanced learning</i> y desequilibrio demográfico	9
2.3.1. Desequilibrio de clase: definición y consecuencias	9
2.3.2. Técnicas de remuestreo en <i>imbalanced learning</i>	9
2.3.3. Extensión al desequilibrio demográfico	10
2.3.4. Métricas de evaluación en contexto de desequilibrio	10
3. Estado del arte	13
3.1. Modelos de predicción de glucosa	13
3.1.1. Modelos fisiológicos y basados en ecuaciones	13
3.1.2. Métodos estadísticos de series temporales	14
3.1.3. Aprendizaje automático clásico	14
3.1.4. Aprendizaje profundo: CNN y LSTM	14
3.1.5. Tendencias actuales	14
3.2. <i>Datasets</i> para la predicción de glucosa	15
3.2.1. Categorías generales de <i>datasets</i>	15
3.2.2. Repositorios abiertos y sus limitaciones	15
3.2.3. <i>Datasets</i> utilizados en este trabajo	16
3.3. Diferencias por sexo y edad en la dinámica glucémica	16
3.3.1. Diferencias por sexo	16
3.3.2. Diferencias por edad	17
3.4. Desequilibrio demográfico en modelos clínicos	17
3.4.1. Desequilibrio demográfico frente a desequilibrio de clase	17
3.4.2. Evidencia de disparidad de rendimiento por subgrupo	17

3.4.3. Técnicas de mitigación del desequilibrio demográfico	18
3.5. Técnicas de balanceo en series temporales y datos médicos	20
3.5.1. Balanceo en datos de series temporales: estado de la cuestión	20
3.5.2. Balanceo demográfico en series temporales fisiológicas	21
3.5.3. Generación sintética de series temporales fisiológicas	22
3.6. Brechas en la literatura y motivación del trabajo	23
4. Desarrollo del trabajo	25
4.1. Recopilación y descripción de los datos	25
4.1.1. Criterios de selección de los <i>datasets</i>	25
4.1.2. T1DiabetesGranada	26
4.1.3. REPLACE-BG	27
4.1.4. DiaTrend	27
4.1.5. Estructura unificada de datos de entrada	28
4.2. Análisis exploratorio de datos	29
4.2.1. Distribución demográfica de los <i>datasets</i>	29
4.2.2. Distribución de la señal CGM	31
4.2.3. Análisis de datos ausentes	32
4.2.4. Análisis de separabilidad demográfica	33
4.3. Detección y cuantificación del desequilibrio demográfico	35
4.3.1. Desequilibrio a nivel de paciente frente a nivel de ventana	35
4.3.2. Desequilibrio por dimensión demográfica y <i>fold</i>	35
4.4. Investigación de técnicas de balanceo para series temporales	38
4.4.1. Criterios de selección de técnicas	38
4.4.2. Taxonomía de técnicas implementadas	39
4.4.3. Validación formal del <i>pipeline</i> de balanceo	43
4.5. Transformación de datos: generación de ventanas deslizantes	43
4.5.1. Parámetros de ventana	44
4.5.2. Restricciones de continuidad temporal	44
4.5.3. Esquema de partición: <i>Group K-Fold</i> con $K = 5$	45
4.6. Análisis exploratorio de ventanas	45
4.6.1. Distribución de ventanas por grupo demográfico y <i>fold</i>	46
4.6.2. Distribución de la variable objetivo por grupo demográfico	46
4.6.3. Verificación de integridad de las particiones	46
4.7. Arquitectura del modelo LSTM	46
4.7.1. Especificación de la arquitectura	46
4.7.2. Función de pérdida y optimizador	46
4.7.3. Estrategia de entrenamiento	47
4.7.4. Configuración del entorno de ejecución	47
4.8. <i>Pipeline</i> de entrenamiento y evaluación	48
4.8.1. Modo original y modo balanceado	48
4.8.2. Flujo de datos por <i>fold</i>	49
4.8.3. Evaluación por rango glucémico	50
4.8.4. Agregación de resultados y protocolo estadístico	50
4.8.5. Trazabilidad y reproducibilidad	51
5. Resultados y discusión	53
6. Conclusiones	57

Bibliografía	64
A. Ejemplo de anexo: Planificación y gestión del proyecto (opcional)	65
A.1. Metodología/Ciclo de vida	66
A.2. Herramientas y plataformas utilizadas para el desarrollo del proyecto	66
A.3. Costes del proyecto	66
A.4. Gestión del proyecto. Planificación temporal. Diagrama de Gantt	66
A.5. Texto añadido	66
B. Ejemplo de anexo: Innovación (opcional)	69
B.1. Estudio del Mercado	69
B.1.1. Segmentos de Clientes	69
B.1.2. Competidores	69
B.2. Propuesta de Valor	69
B.3. Recursos Clave	69
B.4. Actividades Clave	69
B.5. Socios y Alianzas Clave	69
B.6. Estructura de Costes Prevista	70
B.7. Vías de Ingresos	70
B.8. Canales de Distribución	70
B.9. Relación con los Clientes	70
B.10.Descripción del Producto Mínimo Viable	70
B.11.Roadmap de Desarrollo	70
B.12.Aspectos Legales	70
B.13.Texto añadido	70
C. Ejemplo de anexo: Manual de usuario (opcional)	73
C.1. Texto añadido	73

Índice de figuras

4.1. Distribución de pacientes por grupo de edad (<31 , $31-45$, $46-65$, ≥ 66) en cada <i>dataset</i>	29
4.2. Distribución de pacientes por sexo en cada <i>dataset</i>	30
4.3. <i>Heatmap</i> de la distribución conjunta edad $\times$ sexo por <i>dataset</i> . Cada celda muestra el número de pacientes en esa combinación demográfica.	30
4.4. Distribución de los valores de glucosa (mg/dL) por grupo de edad en cada <i>dataset</i> . Las líneas horizontales internas indican la mediana; los límites del violín, el rango intercuartílico (IQR).	31
4.5. Porcentaje de mediciones en cada rango glucémico (TBR-2, TBR-1, TIR, TAR-1, TAR-2) desagregado por sexo y <i>dataset</i>	31
4.6. Distribución de mediciones por rango glucémico (TBR-2, TBR-1, TIR, TAR-1, TAR-2) según grupo de edad, por <i>dataset</i>	32
4.7. Número de mediciones por paciente desagregado por grupo de edad y <i>dataset</i> . La gran dispersión inter-paciente refleja la heterogeneidad en la duración efectiva del seguimiento y en la adherencia al sensor.	32
4.8. Duración del seguimiento (en días) por grupo de edad y <i>dataset</i>	33
4.9. Glucemia media por grupo de edad y <i>dataset</i> . Las barras de error representan la desviación típica inter-paciente dentro de cada grupo.	34
4.10. Variabilidad glucémica intra-grupo por dimensión demográfica y <i>dataset</i>	34
4.11. Distribución del número de ventanas de entrenamiento por grupo de edad en cada <i>dataset</i> (horizonte PH=4, fold de referencia). Los valores absolutos y porcentuales permiten comparar el desequilibrio a nivel de ventana con el desequilibrio a nivel de paciente de la figura 4.1.	36
4.12. Ratio de desequilibrio (grupo mayoritario / grupo minoritario) a nivel de ventana por dimensión de edad y <i>dataset</i> . Un ratio de 1,0 indica distribución perfectamente equilibrada.	37
4.13. Distribución del número de ventanas de entrenamiento por sexo en cada <i>dataset</i>	37
5.1. Mi logo	55
5.2. Lista de distribuciones	56

Índice de tablas

3.1. <i>Datasets</i> utilizados en este trabajo y disponibilidad de variables demográficas. . .	16
3.2. Comparativa de técnicas para la mitigación del desequilibrio demográfico.	20
4.1. Características principales de los <i>datasets</i> utilizados.	29
4.2. Tamaño del efecto de Cohen (d) para las diferencias glucémicas entre subgrupos demográficos en T1DiabetesGranada, calculado sobre ventanas clínicas de 1, 14 y 90 días.	34
4.3. Ratio de desequilibrio a nivel de ventana (grupo mayoritario / grupo minoritario) por <i>fold</i> , dimensión demográfica y <i>dataset</i> (horizonte PH=4). Los valores ilustran la variabilidad introducida por el esquema Group K-Fold.	35
4.4. Taxonomía de las diez técnicas de balanceo implementadas.	39
4.5. Hiperparámetros del modelo LSTM.	46
4.6. Rangos glucémicos para la evaluación desagregada del rendimiento.	50
5.1. Tabla grande	53
5.2. Tabla enorme	54

Capítulo 1

Introducción

La diabetes mellitus tipo 1 (DM1) es una enfermedad crónica de carácter autoinmune que afecta a millones de personas en todo el mundo y que se caracteriza por la destrucción de las células beta del páncreas, impidiendo la producción endógena de insulina. A diferencia de otras enfermedades crónicas con una dinámica relativamente estable, la DM1 somete al paciente a una gestión terapéutica diaria de alta complejidad: la concentración de glucosa en sangre fluctúa de forma continua en respuesta a la insulina exógena, la ingesta, el ejercicio físico, el estrés y otros factores fisiológicos. El desafío clínico central es anticipar estas fluctuaciones con suficiente antelación para que el paciente pueda actuar antes de que se produzcan episodios de hipoglucemia o hiperglucemia, que pueden tener consecuencias agudas graves a corto plazo y complicaciones crónicas severas a largo plazo.

Los sistemas de monitorización continua de glucosa (CGM, por sus siglas en inglés) han transformado el seguimiento clínico de la DM1, al generar señales de alta frecuencia —una medición cada 5 o 15 minutos— que capturan la dinámica glucémica con una resolución imposible mediante los métodos tradicionales de glucometría capilar. Esta riqueza temporal ha impulsado el desarrollo de modelos predictivos basados en aprendizaje automático que estiman el valor futuro de glucosa a partir de la trayectoria reciente de la señal. Entre estas arquitecturas, las redes neuronales recurrentes de tipo LSTM (*Long Short-Term Memory*) han ocupado un lugar consolidado por su capacidad de aprender dependencias temporales de largo alcance directamente de la secuencia bruta, sin necesidad de ingeniería manual de características.

Sin embargo, el rendimiento de un modelo LSTM de predicción de glucosa no depende únicamente de su arquitectura ni de la calidad de la señal CGM en sí misma: depende también de la composición del conjunto de datos con el que se entrena. Los *datasets* de investigación en DM1 disponibles públicamente son, por construcción, muestras de conveniencia clínica. Sus distribuciones demográficas no son uniformes: algunos *datasets* presentan una mayoría de pacientes de un determinado sexo o de un rango etario concreto, lo que se traduce en una asimetría estructural en el número de ventanas de entrenamiento disponibles por grupo demográfico. Esta asimetría puede inducir que el modelo aprenda preferentemente la dinámica glucémica del subgrupo mayoritario, degradando su capacidad predictiva para los subgrupos infrarrepresentados.

La cuestión de si esta composición demográfica del conjunto de entrenamiento afecta de forma medible y corregible al rendimiento predictivo de un modelo LSTM constituye la pregunta central de este Trabajo Fin de Máster. Se trata de una pregunta que la literatura ha comenzado a explorar en el dominio amplio del aprendizaje automático clínico, pero que permanece escasamente estudiada en el contexto específico de la predicción de glucosa mediante CGM, lo que delimita y justifica la contribución de este trabajo.

1.1. Motivación

La motivación de este trabajo surge de la intersección de dos líneas de inquietud: una de carácter personal, derivada del interés por aplicar técnicas de ciencia de datos a problemas con impacto clínico real; y otra de carácter técnico, derivada de una limitación metodológica concreta identificada en la literatura existente.

Desde el punto de vista personal, la predicción de glucosa en DM1 representa un problema de modelado especialmente rico: combina series temporales de alta frecuencia con contexto clínico complejo, heterogeneidad interindividual pronunciada y consecuencias potencialmente graves de los errores de predicción. Es, además, un dominio en el que la brecha entre el rendimiento agregado de un modelo y su rendimiento en subgrupos específicos puede traducirse en diferencias reales en la calidad del cuidado que reciben los pacientes. Trabajar en este dominio con las herramientas propias de la ingeniería de datos y el aprendizaje automático, y hacerlo con rigor estadístico, constituye una motivación genuina que subyace a todas las decisiones de diseño de este trabajo.

Desde el punto de vista técnico, la motivación surge de una observación concreta: la equidad algorítmica en salud —el estudio sistemático de si los modelos de aprendizaje automático producen rendimientos dispares en función de características demográficas de los pacientes— ha recibido creciente atención en la literatura, pero ha operado mayoritariamente sobre datos tabulares en los que cada observación corresponde a un paciente o a un episodio clínico discreto. El problema de la predicción de series temporales mediante ventana deslizante introduce una complicación estructural que no ha sido tratada explícitamente en la literatura revisada: la unidad de balanceo no es el paciente sino la ventana. Un mismo paciente con una serie temporal larga puede generar órdenes de magnitud más ventanas de entrenamiento que otro paciente con una serie corta, incluso cuando ambos pertenecen nominalmente al mismo grupo demográfico. Esta distinción entre balanceo a nivel de paciente y balanceo a nivel de ventana es metodológicamente relevante y constituye una de las contribuciones de diseño de este trabajo.

Adicionalmente, la elección de las dimensiones demográficas de estudio —sexo y edad— está motivada por evidencia fisiológica consolidada: tanto el sexo como la edad están asociados a patrones de dinámica glucémica distinguibles. Las diferencias hormonales entre hombres y mujeres, así como la evolución de la respuesta insulínica a lo largo de la vida, producen perfiles CGM sistémicamente distintos entre subgrupos, lo que hace esperable —y justifica estudiar empíricamente— que un modelo LSTM entrenado sobre una composición demográficamente sesgada aprenda de forma subóptima para los subgrupos infrarrepresentados.

Por último, existe una motivación de relevancia práctica e inmediata: el *dataset* T1DiabetesGranada, generado en el Hospital Universitario Virgen de las Nieves de Granada con más de 643 pacientes y más de 30 millones de mediciones registradas entre 2018 y 2022, es uno de los tres conjuntos de datos sobre los que se trabaja en este TFM. Incorporar un recurso de investigación local de esta envergadura, y contribuir a entender sus propiedades estadísticas y sus implicaciones para el entrenamiento de modelos predictivos, añade una dimensión de relevancia territorial y clínica directa a la investigación.

1.2. Objetivos

El objetivo general de este trabajo es cuantificar empíricamente el impacto de las técnicas de balanceo demográfico —aplicadas sobre las dimensiones de sexo y edad— en el rendimiento predictivo de un modelo LSTM de predicción de glucosa entrenado sobre datos CGM, y determinar bajo qué condiciones dicho balanceo produce mejoras clínicamente relevantes.

De este objetivo general se derivan los siguientes objetivos específicos:

1. **Diseñar e implementar un *pipeline* de balanceo demográfico** que opere exclusivamente sobre el conjunto de entrenamiento de cada *fold* en un esquema de validación cruzada por grupos (*Group K-Fold*), garantizando la separación estricta de pacientes entre particiones y la invarianza bit a bit de los conjuntos de validación y test entre condiciones experimentales.
2. **Implementar y validar una taxonomía de diez técnicas de balanceo**, clasificadas en tres familias: técnicas aleatorias (*random undersampling*, *random oversampling*), técnicas guiadas (*SMOTE*, *Tomek Links*) y combinaciones híbridas (*patient-aware undersampling*, *jittering*, *undersampling + oversampling*, *undersampling + SMOTE*, *SMOTE + Tomek*, *oversampling + Tomek Links*), aplicadas en dos variantes demográficas (edad y sexo) más una condición de control sin balanceo.
3. **Evaluar el efecto del balanceo demográfico sobre el rendimiento global del modelo LSTM**, medido mediante métricas de error de predicción (RMSE, MAE) y métricas de la *Clarke Error Grid* (zonas A, B, A+B), desagregadas por rango glucémico (TBR-2, TBR-1, TIR, TAR-1, TAR-2, rango completo).
4. **Comparar el impacto del balanceo por edad frente al balanceo por sexo** y determinar cuál de las dos dimensiones demográficas produce un efecto mayor y más consistente sobre el rendimiento predictivo.
5. **Caracterizar la robustez de los resultados entre *datasets***, evaluando si los efectos observados son consistentes a través de los tres conjuntos de datos (T1DiabetesGranada, REPLACE-BG, DiaTrend) o si dependen de propiedades estructurales específicas de cada cohorte, como el tamaño muestral, el patrón de datos ausentes o la distribución demográfica intrínseca.
6. **Identificar la técnica de balanceo con mejor rendimiento agregado** mediante un análisis estadístico formal que incluya pruebas de Friedman, comparaciones *post-hoc* de Nemenyi, tamaños del efecto de Cohen's *d* y agregación de *rankings* mediante el método de Borda.
7. **Describir las limitaciones metodológicas y los compromisos clínicos** identificados en los resultados, en particular aquellos casos en que la mejora en un rango glucémico conlleva una degradación en otro, con el objetivo de proporcionar una base de evidencia honesta para la toma de decisiones sobre la incorporación de balanceo demográfico en sistemas de predicción clínica.

1.3. Estructura del trabajo

El presente trabajo se organiza en seis capítulos, cuya estructura refleja la progresión lógica desde la fundamentación teórica hasta las conclusiones empíricas.

El capítulo 2.3.4 ([Métricas de evaluación en contexto de desequilibrio](#)) establece el marco teórico y bibliográfico del trabajo. Se introduce el contexto clínico de la DM1 y de los sistemas CGM, se revisa la evidencia fisiológica de que el sexo y la edad modulan la dinámica glucémica, se examina la literatura sobre desequilibrio demográfico en *datasets* clínicos y su impacto documentado en el rendimiento de modelos de aprendizaje automático, y se revisan las técnicas del estado del arte para la mitigación de este desequilibrio. El capítulo concluye identificando las tres brechas concretas que este trabajo aborda.

El capítulo de metodología describe el diseño experimental completo: la arquitectura del modelo LSTM utilizado, el esquema de validación cruzada por grupos, el proceso de generación de

ventanas deslizantes a partir de las señales CGM, la implementación de las diez técnicas de balanceo demográfico y el proceso de validación formal del *pipeline* mediante un *notebook* de verificación de restricciones. Se describen igualmente las métricas de evaluación empleadas y el protocolo estadístico utilizado para el análisis comparativo.

El capítulo de resultados y discusión presenta los resultados experimentales siguiendo una estructura analítica en embudo: se parte de una visión global del efecto del balanceo agregado sobre todos los *datasets* y rangos glucémicos, y se desciende progresivamente hacia el análisis por *dataset*, por dimensión demográfica, por rango glucémico y por técnica individual. Los resultados de los tests de Friedman, los *rankings* de Nemenyi y la agregación de Borda se presentan en este capítulo, junto con la discusión de los compromisos clínicos identificados y la caracterización de la robustez entre *datasets*.

Finalmente, el capítulo 6 ([Conclusiones](#)) recoge las conclusiones del trabajo, contrastando los resultados obtenidos con los objetivos específicos enumerados en la sección 1.2, e identifica las líneas de trabajo futuro más directamente motivadas por los resultados y las limitaciones encontradas.

Capítulo 2

Fundamentación teórica

Este capítulo proporciona la base conceptual necesaria para comprender el problema abordado en este trabajo y las decisiones metodológicas que lo articulan. Se organiza en tres bloques.

El primer bloque (sección 2.1) desarrolla el contexto clínico de la diabetes mellitus tipo 1 y de los sistemas CGM, incluyendo las métricas clínicas y de error que articulan la evaluación de los modelos predictivos.

El segundo bloque (sección 2.2) expone las bases del aprendizaje profundo para series temporales, con especial atención a las redes LSTM: su arquitectura, su mecanismo de puertas y la formulación del problema de predicción de glucosa como regresión temporal con ventana deslizante.

El tercer bloque (sección 2.3) introduce los fundamentos del *imbalanced learning*, explica su extensión al desequilibrio de composición demográfica del conjunto de entrenamiento y revisa las métricas de evaluación pertinentes en este contexto.

2.1. Contexto clínico: DM1 y monitorización continua de glucosa

2.1.1. Diabetes mellitus tipo 1: fisiopatología y desafíos de gestión

La diabetes mellitus tipo 1 (DM1) es una enfermedad autoinmune crónica caracterizada por la destrucción selectiva de las células beta de los islotes de Langerhans del páncreas, mediada por linfocitos T autorreactivos [1]. La consecuencia directa de esta destrucción es la deficiencia absoluta de insulina: el páncreas pierde progresivamente —y en la mayoría de los casos de forma irreversible— su capacidad de producir la hormona responsable de facilitar la captación de glucosa por los tejidos periféricos. A diferencia de la diabetes tipo 2, en la que la resistencia a la insulina y el déficit relativo de producción constituyen los mecanismos fisiopatológicos predominantes, la DM1 convierte al paciente en dependiente de la administración exógena de insulina desde el momento del diagnóstico y de forma permanente.

La prevalencia global de la DM1 se estima en torno a 8,75 millones de personas, con una incidencia creciente en las últimas décadas especialmente en países de renta alta [2]. En España, los datos del registro nacional estiman una prevalencia de entre 0,3 y 0,5 casos por cada 100 habitantes, con una incidencia anual de entre 10 y 17 nuevos casos por cada 100.000 habitantes menores de 15 años [3].

El desafío clínico central en la DM1 no es únicamente la deficiencia de insulina en sí misma, sino la enorme variabilidad de los requerimientos de insulina exógena a lo largo del día y entre días. La glucosa en sangre fluctúa en respuesta a múltiples factores: la cantidad y composición de los alimentos ingeridos, el tipo e intensidad del ejercicio físico, el estrés psicológico, la fase del ciclo

menstrual en mujeres, las enfermedades intercurrentes y la farmacocinética de la propia insulina administrada, entre otros [4]. Esta variabilidad multifactorial convierte la gestión glucémica diaria en una tarea de control continuo que exige al paciente —o a los sistemas automáticos que le asisten— tomar decisiones clínicas frecuentes y adaptadas al contexto, a menudo con información incompleta o retardada.

Las consecuencias clínicas de una gestión subóptima son bidireccionales. La **hipoglucemia** —concentración de glucosa en sangre inferior a 70 mg/dL en su nivel 1, e inferior a 54 mg/dL en el nivel 2 con riesgo vital inmediato— es la complicación aguda más temida: puede producir alteración de la consciencia, convulsiones y, en casos extremos, la muerte. La **hiperglucemia sostenida** —definida clínicamente por tiempos prolongados por encima de 180 mg/dL— produce a largo plazo complicaciones microvasculares y macrovasculares graves, incluyendo retinopatía, nefropatía, neuropatía periférica y enfermedad cardiovascular [5]. El objetivo terapéutico es, por tanto, mantener la glucosa dentro de un rango euglucémico de seguridad —convencionalmente 70–180 mg/dL, denominado *Time in Range* (TIR)— durante el mayor tiempo posible, minimizando simultáneamente el tiempo en hipoglucemia y el tiempo en hiperglucemia.

La gestión glucémica es, en definitiva, un problema de control dinámico bajo incertidumbre: el paciente o el sistema que le asiste debe anticipar la trayectoria futura de la glucosa con suficiente antelación para actuar de forma preventiva antes de que se produzca una desviación clínicamente relevante. Esta necesidad de anticipación es precisamente la que motiva el desarrollo de modelos de predicción de glucosa.

2.1.2. Monitorización continua de glucosa: principio de funcionamiento y métricas clínicas

Los sistemas de monitorización continua de glucosa (CGM, del inglés *Continuous Glucose Monitoring*) miden la concentración de glucosa de forma automática y continuada mediante electrodos enzimáticos subcutáneos que detectan la glucosa en el líquido intersticial. A diferencia de la glucometría capilar tradicional, los sistemas CGM generan señales de alta frecuencia con periodos de muestreo de entre 5 y 15 minutos [6]. Un paciente con seguimiento CGM durante un año acumula entre 35.000 y 105.000 puntos de medición, lo que hace de estos datos un sustrato natural para el entrenamiento de modelos de series temporales.

Es importante precisar que la señal CGM no mide directamente la glucosa en sangre (glucosa plasmática), sino la glucosa en el líquido intersticial. Existe un retardo fisiológico de entre 5 y 15 minutos entre ambas señales durante los periodos de cambio rápido de glucosa —como tras la ingesta o durante el ejercicio— denominado *lag* intersticial [7]. Este retardo introduce una fuente de error sistemático en las predicciones a corto plazo que los modelos basados en CGM deben compensar implícitamente.

Las métricas clínicas estándar derivadas de la señal CGM están formalizadas en el consenso del *Ambulatory Glucose Profile* (AGP) y en las recomendaciones de la *Advanced Technologies and Treatments for Diabetes* (ATTD) [8]. Las más relevantes para este trabajo son:

- ***Time in Range* (TIR)**: porcentaje de tiempo con glucosa entre 70 y 180 mg/dL. Métrica primaria de control glucémico en la práctica clínica moderna.
- ***Time Below Range nivel 1* (TBR-1)**: porcentaje de tiempo con glucosa entre 54 y 69 mg/dL (hipoglucemia clínicamente significativa).
- ***Time Below Range nivel 2* (TBR-2)**: porcentaje de tiempo con glucosa inferior a 54 mg/dL (hipoglucemia grave con riesgo vital).
- ***Time Above Range nivel 1* (TAR-1)**: porcentaje de tiempo con glucosa entre 181 y 250 mg/dL (hiperglucemia moderada).

- **Time Above Range nivel 2 (TAR-2)**: porcentaje de tiempo con glucosa superior a 250 mg/dL (hiperglucemia severa).

En el contexto de la evaluación de modelos predictivos, el rendimiento se mide frecuentemente mediante la *Clarke Error Grid* (CEG) [9], una representación bidimensional que clasifica las predicciones en cinco zonas (A–E) según su consecuencia clínica. La zona A agrupa las predicciones clínicamente exactas (error relativo inferior al 20 %); las zonas C, D y E corresponden a errores con consecuencias clínicas crecientes, incluyendo decisiones terapéuticas potencialmente peligrosas.

2.1.3. Métricas de error en predicción de glucosa

La evaluación cuantitativa de los modelos de predicción de glucosa utiliza métricas de error estándar en regresión. Las más empleadas en la literatura son:

- **RMSE** (*Root Mean Squared Error*): raíz cuadrada del error cuadrático medio, expresada en mg/dL. Penaliza los errores grandes de forma cuadrática, lo que la hace especialmente sensible a los errores en rangos extremos (hipoglucemia severa, hiperglucemia severa). Es la métrica de referencia dominante en la literatura de predicción de glucosa.
- **MAE** (*Mean Absolute Error*): media del valor absoluto de los errores, expresada en mg/dL. Más robusta frente a valores atípicos y directamente interpretable como el error medio esperado.
- **MAPE** (*Mean Absolute Percentage Error*): error porcentual absoluto medio. Adimensional, pero con inestabilidad numérica en rangos de hipoglucemia severa, donde el denominador se aproxima a cero.

La elección del RMSE como métrica primaria en este trabajo —siguiendo la convención dominante en la literatura— responde a su sensibilidad diferencial hacia los errores clínicamente más graves: una predicción errónea en hipoglucemia severa produce un error cuadrático desproporcionadamente mayor que un error de pequeña magnitud clínica, lo que se traduce en una penalización implícita de los errores más peligrosos.

2.2. Aprendizaje profundo para series temporales: redes LSTM

2.2.1. Redes neuronales recurrentes: motivación y limitaciones

Las redes neuronales recurrentes (RNN, del inglés *Recurrent Neural Networks*) son una familia de arquitecturas de aprendizaje profundo diseñadas para procesar secuencias de longitud arbitraria mediante la introducción de conexiones recurrentes: la salida —o un resumen interno— del paso temporal t se retroalimenta como entrada adicional en el paso $t + 1$, de modo que la red mantiene un estado oculto $\mathbf{h}_t$ que actúa como memoria comprimida de la historia de la secuencia hasta el instante t [10].

Formalmente, la actualización del estado oculto en una RNN estándar en el instante t se expresa como:

$$\mathbf{h}_t = f(\mathbf{W}_h \mathbf{h}_{t-1} + \mathbf{W}_x \mathbf{x}_t + \mathbf{b}) \quad (2.1)$$

donde $\mathbf{x}_t$ es el vector de entrada en el instante t , $\mathbf{W}_h$ y $\mathbf{W}_x$ son matrices de pesos entrenables, $\mathbf{b}$ es un vector de sesgo y f es una función de activación no lineal (habitualmente $\tanh$). La predicción se obtiene aplicando una transformación lineal al estado oculto: $\hat{y}_t = \mathbf{W}_y \mathbf{h}_t + \mathbf{b}_y$.

La limitación fundamental de las RNN estándar reside en el entrenamiento mediante retropropagación a través del tiempo (*Backpropagation Through Time*, BPTT): el gradiente involucra productos reiterados de la matriz jacobiana de la función de transición. Cuando la secuencia es larga, este producto puede converger exponencialmente a cero (*vanishing gradient*) o crecer exponencialmente (*exploding gradient*), impidiendo en la práctica que la red aprenda dependencias temporales de largo alcance [11, ?].

2.2.2. Redes LSTM: arquitectura y mecanismo de puertas

Las redes *Long Short-Term Memory* (LSTM), propuestas por Hochreiter y Schmidhuber en 1997 [12], resuelven el problema del gradiente evanescente mediante la introducción de una celda de memoria $\mathbf{c}_t$ con flujo de gradiente controlado y un sistema de *puertas* (*gates*) que regulan de forma diferenciable qué información se retiene, qué información se descarta y qué información nueva se incorpora en cada paso temporal.

Puerta de olvido (*forget gate*, $\mathbf{f}_t$): determina qué fracción de la celda de memoria anterior $\mathbf{c}_{t-1}$ se conserva:

$$\mathbf{f}_t = \sigma(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \quad (2.2)$$

Puerta de entrada (*input gate*, $\mathbf{i}_t$) y **candidato de celda** ($\tilde{\mathbf{c}}_t$): determinan qué nueva información se escribe en la celda de memoria:

$$\mathbf{i}_t = \sigma(\mathbf{W}_i[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i), \quad \tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_c[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c) \quad (2.3)$$

Actualización de la celda: combina la información retenida y la nueva información candidata:

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t \quad (2.4)$$

donde $\odot$ denota el producto elemento a elemento (*Hadamard product*).

Puerta de salida (*output gate*, $\mathbf{o}_t$): filtra la información de la celda de memoria que se propaga al estado oculto:

$$\mathbf{o}_t = \sigma(\mathbf{W}_o[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o), \quad \mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t) \quad (2.5)$$

La clave del mecanismo es que la celda $\mathbf{c}_t$ se actualiza mediante suma —no multiplicación— de la información nueva, lo que permite que el gradiente fluya a través de la secuencia sin atenuarse de forma multiplicativa. Este flujo de gradiente no obstruido habilita a las LSTM para capturar dependencias temporales de largo alcance, una propiedad esencial para modelar la dinámica glucémica, en la que patrones ocurridos horas antes pueden seguir influyendo en la señal CGM observada mucho tiempo después.

2.2.3. Predicción de glucosa como regresión temporal con ventana deslizante

En el contexto de este trabajo, la predicción de glucosa se formula como un problema de regresión de un paso a horizonte fijo: dado un historial de mediciones CGM de longitud fija $\{g_{t-n+1}, \dots, g_t\}$ —denominado *Historical Window* (HW)— se estima el valor de glucosa en un instante futuro $\hat{g}_{t+PH}$, donde PH es el horizonte de predicción (*Prediction Horizon*). Este trabajo utiliza $HW = 8$ mediciones y $PH = 4$ mediciones, lo que corresponde a una ventana de observación de 2 horas y un horizonte de predicción de 1 hora a una frecuencia de muestreo de 15 minutos (T1DiabetesGranada), y de 40 minutos de observación con 20 minutos de horizonte a 5 minutos de muestreo (DiaTrend, REPLACE-BG). El horizonte de una hora es clínicamente relevante por ofrecer margen suficiente para ajustes terapéuticos preventivos antes de que se produzca una desviación glucémica [13].

El proceso de generación de instancias de entrenamiento se realiza mediante **ventana deslizante** (*sliding window*): para cada posición t válida en la serie de un paciente, se extrae una ventana

de entrada $\mathbf{x}^{(t)} = [g_{t-n+1}, \dots, g_t]$ y un valor objetivo $y^{(t)} = g_{t+PH}$. Esta formulación introduce una propiedad estructural relevante: la unidad de análisis no es el paciente sino la ventana. Un paciente con una serie de alta densidad puede aportar decenas de miles de ventanas; un paciente con una serie fragmentada puede aportar apenas unos centenares. Esta disparidad en la contribución de ventanas entre pacientes —independiente de la distribución demográfica del *dataset*— constituye por sí misma una forma de desequilibrio de representación en el conjunto de entrenamiento.

2.2.4. Validación cruzada por grupos en datos de pacientes

La validación cruzada estándar (*K-Fold*) distribuye las observaciones aleatoriamente entre los *folds*, lo que en el contexto de series temporales CGM producidas por ventana deslizante introduce *data leakage*: ventanas del mismo paciente —y frecuentemente ventanas temporalmente contiguas— pueden aparecer simultáneamente en el conjunto de entrenamiento y en el de validación del mismo *fold*. Este solapamiento produce una estimación artificialmente optimista del rendimiento del modelo.

La **validación cruzada por grupos** (*Group K-Fold*) resuelve este problema garantizando que ningún paciente aparece simultáneamente en el conjunto de entrenamiento y en el de validación de un mismo *fold*: todos los pacientes se asignan íntegramente a un único *fold* [14]. Esta estrategia produce una evaluación más pesimista pero más realista del rendimiento sobre pacientes no vistos durante el entrenamiento, que es el escenario clínico relevante.

En este trabajo se utiliza un esquema de 5-fold *Group K-Fold*, con la restricción adicional de que el conjunto de test permanece fijo e idéntico en todas las condiciones experimentales (con y sin balanceo, para todas las técnicas), de modo que las diferencias de rendimiento observadas sean atribuibles exclusivamente a las transformaciones aplicadas al conjunto de entrenamiento.

2.3. *Imbalanced learning* y desequilibrio demográfico

2.3.1. Desequilibrio de clase: definición y consecuencias

El aprendizaje sobre datos desequilibrados (*imbalanced learning*) estudia cómo diseñar, entrenar y evaluar modelos cuando las clases de la variable objetivo tienen frecuencias muy dispares. En la formulación clásica del problema, el desequilibrio de clase se produce cuando la clase mayoritaria representa una fracción dominante del conjunto de entrenamiento mientras que la clase minoritaria —a menudo la más relevante desde el punto de vista del dominio— representa una fracción marginal [15].

Las consecuencias del desequilibrio de clase en el entrenamiento son bien conocidas: un modelo que minimiza una función de pérdida agregada sobre un conjunto de entrenamiento desequilibrado tiende a aprender preferentemente la distribución de la clase mayoritaria. En clasificación, esto se manifiesta como sesgo sistemático hacia la clase dominante. En regresión —el tipo de problema abordado en este trabajo— el efecto es análogo: el modelo aprende preferentemente la distribución de los valores objetivo más frecuentes, produciendo predicciones menos precisas para los valores que aparecen con menor frecuencia, aunque estos sean clínicamente los más relevantes [16].

2.3.2. Técnicas de remuestreo en *imbalanced learning*

Las estrategias para mitigar el impacto del desequilibrio de clase pueden clasificarse en tres niveles: preprocesado de los datos (*pre-processing*), modificación del proceso de entrenamiento

(*in-processing*) y postprocesado de las predicciones (*post-processing*) [17]. Las técnicas de preprocesado son las más compatibles con el requisito metodológico de este trabajo —el balanceo debe materializarse exclusivamente como una transformación de los datos de entrada— y son las más estudiadas en la literatura.

Dentro de las técnicas de preprocesado, las de **remuestreo** son las más utilizadas:

***Undersampling* (submuestreo)**: reduce el tamaño de la clase mayoritaria eliminando observaciones. La estrategia más simple es el submuestreo aleatorio (*Random Undersampling*, RUS). Estrategias más sofisticadas, como *Tomek Links* [18], identifican y eliminan selectivamente los pares de observaciones de clases opuestas que son vecinos mutuos en el espacio de características. La limitación principal del *undersampling* es la pérdida de información.

***Oversampling* (sobremuestreo)**: aumenta el tamaño de la clase minoritaria generando nuevas observaciones. La técnica más influyente es SMOTE (*Synthetic Minority Oversampling Technique*) [19], que genera observaciones sintéticas interpolando linealmente entre observaciones reales de la clase minoritaria y sus k vecinos más cercanos. Su limitación es la introducción de puntos sintéticos que pueden no respetar la distribución real de la clase minoritaria.

Técnicas híbridas: combinan *undersampling* y *oversampling* de forma secuencial. *SMOTE+Tomek* aplica SMOTE para aumentar la clase minoritaria y a continuación elimina mediante *Tomek Links* los pares ruidosos en la frontera de decisión [20].

2.3.3. Extensión al desequilibrio demográfico

El problema abordado en este trabajo no es el desequilibrio de clase en su formulación clásica —desequilibrio entre clases glucémicas (hipoglucemia, normoglucemia, hiperglucemia)—, sino un tipo de desequilibrio cualitativamente diferente: el **desequilibrio de composición demográfica** del conjunto de entrenamiento. Este problema surge cuando la proporción de ventanas de entrenamiento procedentes de distintos grupos demográficos —definidos por sexo o por grupo de edad— es muy dispar, no porque los pacientes de distintos grupos tengan dinámicas glucémicas intrínsecamente distintas en frecuencia, sino porque el *dataset* contiene más pacientes de algunos grupos que de otros, o porque los pacientes de distintos grupos tienen series CGM de longitud o densidad diferente.

La distinción conceptual es importante: en el desequilibrio de clase clásico, la variable desequilibrada es la etiqueta de clase que el modelo intenta predecir. En el desequilibrio demográfico, la variable desequilibrada es un atributo del sujeto que produjo los datos, no el valor que el modelo predice. Un modelo que minimiza el error de predicción sobre un conjunto demográficamente desequilibrado aprende preferentemente la dinámica glucémica del subgrupo mayoritario, produciendo predicciones sistemáticamente menos precisas para los subgrupos infrarrepresentados. Las técnicas de remuestreo clásicas no fueron diseñadas para corregir este tipo de desequilibrio. La adaptación de estas técnicas al desequilibrio demográfico requiere redefinir la unidad de remuestreo: en lugar de operar sobre la distribución de la variable objetivo, se opera sobre la distribución de la variable demográfica. Esta redefinición es precisamente lo que diferencia metodológicamente el *pipeline* de balanceo demográfico implementado en este trabajo de la aplicación directa de las técnicas estándar de *imbalanced learning*.

2.3.4. Métricas de evaluación en contexto de desequilibrio

La evaluación del rendimiento de modelos entrenados sobre datos desequilibrados requiere métricas que sean sensibles a la disparidad de rendimiento entre subgrupos, y no únicamente al rendimiento medio agregado. En el contexto de regresión, un modelo puede obtener un RMSE global bajo mientras produce predicciones sistemáticamente peores para el subgrupo demográfico minoritario, sin que esta disparidad sea detectable en la métrica agregada. Por este motivo, el

análisis estadístico de este trabajo examina tanto el rendimiento global como el rendimiento desagregado por rango glucémico y por subgrupo demográfico.

El protocolo estadístico formal utilizado —pruebas de Friedman, comparaciones *post-hoc* de Nemenyi, tamaños del efecto de Cohen's d y agregación de *rankings* mediante el método de Borda— responde a la necesidad de comparar simultáneamente múltiples técnicas sobre múltiples *datasets* y rangos glucémicos, controlando el error de tipo I en comparaciones múltiples. La elección de pruebas no paramétricas está motivada por la imposibilidad de asumir normalidad en las distribuciones de error entre *folds* para todas las condiciones experimentales.

Capítulo 3

Estado del arte

Este capítulo revisa la evidencia científica sobre tres líneas de investigación cuya confluencia define el presente trabajo: la predicción de glucosa mediante modelos de series temporales, los sesgos demográficos en modelos clínicos de aprendizaje automático y las técnicas para su mitigación. La revisión no tiene por objeto explicar los conceptos que sustentan estas líneas —tratados en el capítulo anterior— sino identificar la frontera del conocimiento actual y las brechas que este trabajo aborda.

Se organiza en cuatro secciones. La sección 3.1 revisa el estado del arte en modelos de predicción de glucosa. La sección 3.2 describe los *datasets* disponibles y sus limitaciones para el análisis de subgrupos. La sección 3.3 establece la evidencia fisiológica y clínica de que el sexo y la edad modulan la dinámica glucémica. La sección 3.4 revisa la literatura sobre desequilibrio demográfico y técnicas de mitigación. La sección 3.5 revisa la literatura sobre técnicas de balanceo aplicadas específicamente a series temporales y datos médicos. El capítulo concluye con la identificación de las brechas específicas que motivan este trabajo.

3.1. Modelos de predicción de glucosa

A lo largo de las últimas décadas se han propuesto para la predicción de glucosa en sangre en pacientes con DM1 metodologías muy diversas, cuya progresión refleja tanto la evolución de las herramientas computacionales como la mayor disponibilidad de datos CGM. Esta sección revisa las principales familias de modelos que han conformado el estado del arte, con énfasis en su rendimiento comparado y en los aspectos no resueltos que motivan el presente trabajo.

3.1.1. Modelos fisiológicos y basados en ecuaciones

Los primeros intentos de predicción de glucosa se apoyaron en modelos fisiológicos que describen la dinámica de la glucosa y la insulina mediante sistemas de ecuaciones diferenciales [21]. Los modelos más conocidos son los modelos mínimos de regulación glucosa-insulina, que capturan el efecto de la sensibilidad a la insulina, la producción hepática de glucosa y la absorción de hidratos de carbono. Estos modelos ofrecen resultados interpretables y una comprensión mecanicista de la enfermedad, pero presentan limitaciones importantes: requieren calibración individual, son costosos de diseñar y carecen de escalabilidad cuando se incorporan nuevas variables. Pese a estas limitaciones, los modelos basados en ecuaciones han servido históricamente como *baseline* de referencia y continúan utilizándose en enfoques híbridos.

3.1.2. Métodos estadísticos de series temporales

Con el crecimiento de los datos CGM, los investigadores adoptaron técnicas de predicción estadística. El modelo ARIMA (*AutoRegressive Integrated Moving Average*) [22] ha sido durante décadas el estándar en análisis de series temporales y se ha aplicado a la captura de la estructura autorregresiva de la glucosa, a veces con órdenes adaptativos para abordar la no estacionariedad. Aunque interpretables y eficientes computacionalmente, estos modelos tienen dificultades para capturar dependencias no lineales y de largo alcance. Otros métodos estadísticos, como los filtros de Kalman [23] y los filtros bayesianos, también han sido aplicados con resultados variables. En general, estos enfoques alcanzan una precisión moderada para horizontes cortos (15–30 minutos) pero se degradan significativamente cuando el horizonte se amplía.

3.1.3. Aprendizaje automático clásico

La introducción de algoritmos de aprendizaje automático ofreció mayor flexibilidad para capturar relaciones no lineales. Los algoritmos más empleados incluyen la regresión de vectores de soporte (SVR) [24], los bosques aleatorios (RF), los procesos gaussianos (GP) [25] y las máquinas de aprendizaje extremo (ELM). Entre estos, los procesos gaussianos han atraído interés por su naturaleza probabilística y su capacidad para cuantificar la incertidumbre predictiva. Sin embargo, estos métodos suelen requerir características diseñadas manualmente (tendencias pasadas de glucosa, marcadores de ingesta o dosis de insulina) y no pueden explotar directamente secuencias largas en bruto. Su rendimiento es también sensible al tamaño y calidad del *dataset*, lo que ha limitado su adopción generalizada en los últimos años.

3.1.4. Aprendizaje profundo: CNN y LSTM

La última década ha estado dominada por el aprendizaje profundo, impulsado por la mayor disponibilidad de datos y los avances en arquitecturas neuronales. Estos modelos aprenden representaciones automáticamente a partir de secuencias CGM en bruto, sin requerir extracción manual de características.

Las dos familias de arquitecturas de aprendizaje profundo más utilizadas en predicción de glucosa son las redes convolucionales (CNN) y las redes recurrentes (RNN), especialmente LSTM y GRU. Las CNN unidimensionales capturan patrones temporales locales en las trayectorias de glucosa; las CNN dilatadas extienden el campo receptivo sin aumentar el número de parámetros [26]. Los modelos LSTM y GRU retienen por diseño memoria de estados pasados y capturan dependencias secuenciales. Los modelos LSTM personalizados —entrenados individualmente para cada paciente— han demostrado superar en algunos casos a los modelos globales, mientras que otros enfoques han intentado entrenar LSTM generalizados capaces de manejar cohortes heterogéneas [27].

Varios trabajos han explorado también modelos de conjunto (*ensemble*) [28], que combinan las salidas de múltiples algoritmos para mejorar la robustez, y más recientemente arquitecturas *Transformer* aplicadas a predicción glucémica [29]. Estos modelos reportan mejoras incrementales respecto a las LSTM en algunos benchmarks, aunque a costa de una mayor complejidad computacional y de una menor interpretabilidad.

3.1.5. Tendencias actuales

La evidencia disponible permite identificar las siguientes tendencias consolidadas en la literatura reciente:

- Las arquitecturas basadas en LSTM permanecen como el enfoque dominante para la predicción de glucosa a corto plazo (15–60 minutos), con un rendimiento bien documentado en múltiples *datasets* públicos.
- Los modelos híbridos que combinan distintas arquitecturas neuronales, o integran elementos fisiológicos y basados en datos, son cada vez más frecuentes.
- El interés por los modelos personalizados —que adaptan sus parámetros a la dinámica específica de cada paciente— contrasta con el de los modelos generalizables desplegados sobre poblaciones amplias [30].
- A pesar de los avances técnicos, la mayoría de los trabajos se centra en minimizar el error de predicción medio, sin explorar cómo se distribuye ese error entre distintos subgrupos de pacientes. La equidad (*fairness*), la interpretabilidad y la usabilidad clínica permanecen como dimensiones sistemáticamente subexploradas.

En resumen, la trayectoria de los modelos de predicción de glucosa ha evolucionado de métodos interpretativos pero rígidos hacia arquitecturas de aprendizaje profundo altamente flexibles. El reto pendiente no es únicamente mejorar la precisión bruta, sino comprender cómo se comportan estos modelos en distintas poblaciones de pacientes, un aspecto central para este trabajo.

3.2. *Datasets* para la predicción de glucosa

La calidad y diversidad del *dataset* juegan un papel decisivo en el éxito y la generalización de los modelos de predicción de glucosa. Esta sección revisa el panorama de *datasets* disponibles, con énfasis en sus limitaciones para el análisis de subgrupos demográficos.

3.2.1. Categorías generales de *datasets*

Los *datasets* empleados en la literatura pueden clasificarse en dos categorías principales:

Los ***datasets in-silico*** se generan mediante simuladores fisiológicos validados, siendo el más utilizado el simulador UVA/Padova T1D [31], aceptado por la FDA como sustituto de algunos ensayos clínicos. Los datos *in-silico* pueden generarse en grandes volúmenes bajo condiciones controladas, pero los pacientes simulados no capturan plenamente la complejidad de la DM1 real, por lo que los modelos entrenados exclusivamente sobre datos sintéticos frecuentemente no generalizan a entornos clínicos.

Los ***datasets del mundo real*** se obtienen directamente de pacientes con dispositivos CGM, ya sea en condiciones controladas de ensayo clínico o durante la vida libre. Son más representativos de la variabilidad real, pero más costosos y difíciles de recopilar; muchos permanecen privados y los públicos presentan limitaciones en tamaño, duración o diversidad clínica.

3.2.2. Repositorios abiertos y sus limitaciones

La disponibilidad de repositorios abiertos ha sido clave para acelerar la investigación en este campo, al permitir la reproducibilidad de resultados y proporcionar *benchmarks* comunes. Los repositorios clásicos más utilizados incluyen OhioT1DM [32] y D1NAMO [33], que involucran típicamente decenas de pacientes y semanas de datos. Aunque valiosos para el desarrollo de modelos, su reducido tamaño limita la evaluación de la generalización a subpoblaciones específicas. Esta limitación motiva la necesidad de *datasets* más amplios y diversos, capaces de capturar la variabilidad glucémica entre grupos de edad, sexos y distintos entornos clínicos. El presente trabajo se apoya en tres repositorios de este tipo.

3.2.3. *Datasets* utilizados en este trabajo

REPLACE-BG [34]: ensayo clínico aleatorizado realizado en Estados Unidos con el objetivo de evaluar si los adultos con DM1 que utilizan CGM podían reemplazar de forma segura las mediciones capilares rutinarias. El *dataset* incluye registros CGM de 226 adultos recogidos durante 182 días en un entorno altamente estructurado y controlado. Desde la perspectiva de este trabajo, REPLACE-BG es valioso porque representa condiciones de ensayo clínico estandarizadas, aunque esto implica que la variabilidad es limitada respecto a los datos de vida libre y que la diversidad demográfica es más estrecha que en *datasets* poblacionales.

DiaTrend [35]: repositorio que agrega registros de dos estudios liderados por Dartmouth: *Digital SMD* (2019), con 17 adultos de 25 a 74 años, y *SweetGoals* (en curso), con 37 adultos jóvenes de 19 a 29 años. En total, DiaTrend incluye 54 adultos con DM1, con una media de 510 días de datos CGM y de bomba de insulina por participante. La composición de la cohorte es especialmente relevante para este trabajo: incluye adultos jóvenes con mayor variabilidad glucémica y participantes de mayor edad con patrones más estables, permitiendo comparaciones entre grupos de edad.

T1DiabetesGranada [36]: uno de los mayores *datasets* abiertos de registros CGM para DM1 publicados hasta la fecha. Recogido en la Unidad Clínica de Endocrinología y Nutrición del Hospital Universitario San Cecilio (Granada, España), incluye más de 22 millones de mediciones de glucosa de 736 pacientes a lo largo de un periodo de cuatro años. A diferencia de REPLACE-BG o DiaTrend, este *dataset* refleja la práctica clínica rutinaria bajo condiciones de vida real. Su gran escala y diversidad demográfica lo hacen especialmente adecuado para analizar el rendimiento de los modelos predictivos entre subgrupos.

La tabla 3.1 resume las características de los tres *datasets* desde la perspectiva relevante para este trabajo.

Tabla 3.1: *Datasets* utilizados en este trabajo y disponibilidad de variables demográficas.

Dataset	Pacientes	Muestreo	Seguimiento	Variables demográficas
DiaTrend	54	5 min	≤ 7 años	Sexo, edad
REPLACE-BG	226	5 min	26 sem	Sexo, edad, HbA1c, duración
T1DGranada	643	15 min	≤ 4 años	Sexo, edad

3.3. Diferencias por sexo y edad en la dinámica glucémica

Antes de revisar las técnicas de balanceo demográfico, es necesario establecer la premisa fisiológica que justifica su pertinencia: si el sexo y la edad no tuvieran ninguna relación demostrable con la dinámica glucémica, equilibrar su representación en el conjunto de entrenamiento carecería de motivación clínica. La evidencia disponible indica lo contrario.

3.3.1. Diferencias por sexo

La DM1 presenta una predominancia masculina documentada en su incidencia [2], y la literatura ha identificado dimorfismo sexual en la homeostasis de la glucosa derivado de factores fisiológicos como las hormonas sexuales, la distribución de masa grasa y muscular y diferencias cromosómicas [37]. Conti et al. [38] evaluaron de forma prospectiva, en una cohorte de 176 adultos con DM1 tratados con sistemas de circuito cerrado híbrido avanzado, las diferencias por sexo en métricas CGM y variabilidad glucémica a lo largo de un año de seguimiento, encontrando diferencias sistemáticas en el control glucémico entre hombres y mujeres pese a recibir idéntica terapia.

En la misma línea, un estudio publicado en *The Lancet Diabetes & Endocrinology* documentó disparidades por sexo entre el control glucémico percibido por el paciente y el objetivo medido por CGM, señalando explícitamente la necesidad de investigar más a fondo el papel del sexo en la heterogeneidad fisiopatológica de la enfermedad [39].

3.3.2. Diferencias por edad

La dinámica glucémica difiere también de forma sustancial entre grupos etarios. En el extremo pediátrico y adolescente, un estudio sobre control glucémico en horario escolar encontró que las niñas presentaban un riesgo significativamente mayor de deterioro del control glucémico nocturno que los niños ($OR = 3.26$, $IC95\% 1.17-9.72$) [40], lo que sugiere además una interacción entre edad y sexo en la dinámica glucémica. En el extremo de mayor edad, un estudio sobre 2.260 pacientes adultos con diabetes comparó el control glucémico entre pacientes de hasta 65 años y mayores de 65 años, encontrando que solo el 23,2 % de los pacientes más jóvenes alcanzaba su objetivo individualizado de TIR, frente al 69 % de los pacientes mayores de 65 años [41]. Esta diferencia confirma que la edad modula el comportamiento glucémico observable en CGM y advierte de que la relación entre edad y control glucémico no es monótona ni trivial.

En conjunto, esta evidencia establece que tanto el sexo como la edad están asociados a patrones de dinámica glucémica distinguibles, lo que proporciona la motivación necesaria para estudiar si un modelo LSTM entrenado sobre una composición demográfica desequilibrada generaliza peor a los subgrupos infrarrepresentados.

3.4. Desequilibrio demográfico en modelos clínicos

3.4.1. Desequilibrio demográfico frente a desequilibrio de clase

El desarrollo de modelos de aprendizaje automático en contextos sanitarios plantea un problema distinto del desequilibrio de clases. Mientras que el desequilibrio de clases hace referencia a la proporción desigual entre las categorías de la variable objetivo, el desequilibrio demográfico se refiere a la proporción desigual de observaciones pertenecientes a distintos grupos poblacionales dentro del conjunto de entrenamiento, con independencia de cuál sea la variable objetivo del modelo. Cuando esto ocurre, los algoritmos de aprendizaje —especialmente las redes neuronales recurrentes— tienden a ajustar sus representaciones internas preferentemente a la dinámica del subgrupo mayoritario, lo que puede traducirse en una degradación sistemática del rendimiento predictivo en los subgrupos infrarrepresentados [42, 43].

Una revisión sistemática publicada en el *Journal of Clinical Epidemiology* identificó múltiples mecanismos por los cuales el sesgo se introduce en modelos clínicos, señalando el reponderado de muestras como una de las estrategias de mitigación más eficaces, con un 83 % de efectividad reportada en los estudios analizados [43]. Straw y Wu [42] demostraron en un estudio de predicción de enfermedad hepática que modelos entrenados sin considerar el desequilibrio por sexo presentaban disparidades de rendimiento sistemáticas entre subgrupos, replicando inequidades clínicas ya documentadas en la literatura médica.

3.4.2. Evidencia de disparidad de rendimiento por subgrupo

La pregunta de si la composición demográfica del entrenamiento afecta al rendimiento de un modelo predictivo ha sido investigada de forma directa en varios trabajos recientes.

Wang et al. [44] analizaron datos de más de 25.000 individuos con enfermedades crónicas —incluyendo diabetes— procedentes de siete *datasets* distintos, encontrando disparidades de rendimiento predictivo sistemáticas por sexo, favoreciendo la precisión en pacientes varones, y dispa-

ridades más acusadas por edad, con mejor precisión en pacientes jóvenes y un comportamiento inconsistente en pacientes de mayor edad. Un hallazgo central de este trabajo es que **la paridad demográfica en la composición del *dataset* no garantiza por sí sola la paridad en el rendimiento del modelo resultante**: incluso conjuntos de datos demográficamente equilibrados pueden producir modelos con disparidad de rendimiento.

Yan et al. [45] propusieron un método de corrección de sesgo de representación (*double prioritized bias correction*) y lo compararon sistemáticamente contra ocho técnicas de muestreo existentes —incluyendo SMOTE y ADASYN— para mitigar disparidades de rendimiento por edad y raza en pronóstico clínico. Un resultado especialmente relevante es que las **técnicas estándar de remuestreo de clase no están diseñadas para abordar sesgos de subgrupo demográfico**, ya que muestrean toda la clase minoritaria de la variable objetivo sin diferenciar a qué subgrupo demográfico pertenece cada observación.

En el dominio específico de la predicción de glucosa mediante CGM, Ovalle et al. [46] entrenaron modelos LSTM para predecir glucosa a 60 minutos a partir de datos CGM, evaluando la disparidad de rendimiento (medida en RMSE) entre subgrupos raciales en función de la composición demográfica del conjunto de entrenamiento. Esta constituye la referencia metodológicamente más próxima al presente trabajo. La diferencia sustancial es la variable de estratificación: mientras que Ovalle et al. estudian la raza, este trabajo estudia el sexo y la edad, dos dimensiones no exploradas en dicho estudio y con fundamento fisiológico propio.

3.4.3. Técnicas de mitigación del desequilibrio demográfico

Esta sección revisa las familias de técnicas disponibles para corregir el desequilibrio en la representación de subgrupos demográficos dentro de un conjunto de entrenamiento, evaluando para cada una su fundamento, sus ventajas y limitaciones, y su compatibilidad con la restricción metodológica de este trabajo: el balanceo debe operar exclusivamente sobre las ventanas de entrenamiento, sin modificar el modelo LSTM ni su procedimiento de entrenamiento.

Reponderado de muestras (*Reweighting*)

El reponderado, propuesto originalmente por Kamiran y Calders [47], asigna un peso distinto a cada observación en función de su pertenencia a un grupo demográfico, de modo que el grupo infrarrepresentado adquiere mayor influencia relativa en la función de pérdida sin necesidad de alterar físicamente el número de observaciones:

$$w(a) = \frac{P_{\text{teórica}}(a)}{P_{\text{empírica}}(a)} = \frac{1/|A|}{n_a/N} \quad (3.1)$$

donde n_a es el número de observaciones del grupo a y N el número total. Los grupos infrarrepresentados reciben así un peso $w(a) > 1$, mientras que los sobrerrepresentados reciben $w(a) < 1$ [48, 49]. Su aplicación estándar requiere que el algoritmo de entrenamiento acepte un parámetro de peso por muestra (**sample_weight**), lo que constituye una modificación del proceso de entrenamiento. Dado que en este trabajo el balanceo debe producirse exclusivamente como una transformación de los datos de entrada, el reponderado puro **no es aplicable** salvo que se aproxime mediante remuestreo proporcional a los pesos calculados. Esta técnica está ampliamente utilizada en el ecosistema de *IBM AI Fairness 360* [50] y ha sido evaluada extensamente como referencia en estudios de equidad clínica [43].

Remuestreo dirigido por grupo demográfico

El remuestreo dirigido por grupo es la contrapartida basada en remuestreo del reponderado: se duplican (*oversampling*) o eliminan (*undersampling*) físicamente observaciones hasta alcanzar la

proporción demográfica deseada [49, 47]. A esta familia pertenecen las técnicas implementadas en este trabajo —*Random Oversampling*, *Random Undersampling*, *Patient-Aware Undersampling*, SMOTE y *Jittering*—, aplicadas sobre la distribución de ventanas por grupo demográfico en lugar de sobre la distribución de clase glucémica. Su principal ventaja es la compatibilidad total con un *pipeline* en el que el balanceo debe materializarse como una transformación de los datos de entrada sin modificar el proceso de entrenamiento posterior. El riesgo de introducir sesgos está documentado [51, 52]: el remuestreo uniforme corrige la proporción global del grupo, pero puede mantener la concentración de las muestras añadidas en un subconjunto reducido de individuos, un riesgo de pseudo-replicación especialmente relevante en *datasets* de tamaño muestral reducido como DiaTrend.

Chu et al. [53] en *JMIR Aging* describen el caso de un estudio de neuroimagen en el que se duplicaron muestras de grupos etarios sobrerrepresentados para igualar la representación de grupos etarios minoritarios, observando que un sesgo residual persistió tras el balanceo. Yan et al. [45] mostraron empíricamente que las técnicas de remuestreo estándar de clase (incluido SMOTE) ofrecen una mitigación limitada de la disparidad por subgrupo demográfico precisamente por no diferenciar el subgrupo dentro de la clase remuestreada, motivando la necesidad de aplicar el remuestreo directamente sobre la variable demográfica, como se hace en este trabajo.

Generación sintética mediante redes generativas adversarias temporales

TimeGAN [54] combina un *autoencoder* con una arquitectura GAN y un componente supervisado adicional que preserva explícitamente la dinámica temporal de las secuencias generadas. A diferencia de las GAN convencionales que tratan cada muestra como independiente, TimeGAN aprende conjuntamente un espacio latente y una dinámica de transición en dicho espacio, optimizando simultáneamente una pérdida adversaria, una pérdida de reconstrucción y una pérdida supervisada de predicción del siguiente paso temporal. La aplicabilidad a balanceo por sexo y por edad requiere generación condicionada: el generador debe condicionarse a la etiqueta de grupo demográfico del paciente de origen, de forma que las ventanas sintéticas hereden las características temporales del subgrupo infrarrepresentado. Su limitación principal es que requiere entrenar un modelo generativo adicional, lo que añade complejidad sustancial. En el dominio de sensores corporales, TS-GAN [55] y un estudio de detección de estrés mediante GAN condicionales con arquitectura LSTM [56] confirman la viabilidad técnica de generar series fisiológicas sintéticas de calidad suficiente para aumentar el entrenamiento de modelos de clasificación, si bien ninguno de los dos evalúa explícitamente el sexo o la edad como variable de balanceo.

Representaciones invariantes al atributo demográfico

Esta familia de técnicas modifica el proceso de entrenamiento añadiendo un clasificador adversario que intenta predecir el atributo demográfico sensible a partir de la representación interna de la red. El modelo principal se entrena para minimizar simultáneamente su pérdida de predicción y maximizar la pérdida del adversario [57, 58, 59]. Su limitación es decisiva para este trabajo: es por definición una técnica de *in-processing*, que exige modificar la arquitectura y el proceso de entrenamiento del modelo LSTM, lo que la sitúa **fuera del alcance metodológico** de este trabajo.

Validación cruzada con muestreo estratificado por grupo

Esta técnica garantiza que la composición demográfica del conjunto de entrenamiento sea representativa de la composición demográfica global del *dataset*, evitando que el proceso de partición en *folds* introduzca o amplifique un desequilibrio adicional al ya presente [60]. Su ventaja es

el bajo coste de implementación y un riesgo metodológico mínimo; su limitación es que por sí sola no resuelve el problema central: si la población de pacientes está intrínsecamente desequilibrada en número de ventanas por grupo, una partición estratificada simplemente replicará ese desequilibrio en cada *fold* sin corregirlo.

Comparativa de técnicas

La tabla 3.2 resume las familias de técnicas revisadas según su tipo, su compatibilidad con la restricción metodológica, su complejidad de implementación y la evidencia disponible en el dominio sanitario.

Tabla 3.2: Comparativa de técnicas para la mitigación del desequilibrio demográfico.

Técnica	Tipo	Compat. restricción	Edad/ Sexo	Complej.	Evidencia <i>Healthcare</i>
Reponderado	Pre-procesado	Parcial	Sí	Baja	Alta
Remuestreo dirigido por grupo	Pre-procesado	Sí	Sí	Baja	Alta
GAN temporal condicionada	Generativa	Sí	Sí	Alta	Media
Representaciones invariantes	In-processing	No	Sí	Alta	Alta
CV estratificada por grupo	Estructural	Sí	Sí	Baja	Media

3.5. Técnicas de balanceo en series temporales y datos médicos

La sección anterior ha revisado las técnicas de mitigación del desequilibrio demográfico desde la perspectiva de la equidad algorítmica. Esta sección complementa esa revisión examinando la literatura específica sobre técnicas de balanceo aplicadas a series temporales clínicas y, cuando existe evidencia directa, a la predicción de glucosa.

3.5.1. Balanceo en datos de series temporales: estado de la cuestión

La aplicación de técnicas de remuestreo a series temporales plantea desafíos específicos que no se presentan en datos tabulares independientes. El principal es la preservación de la autocorrelación temporal y de las propiedades distribucionales de la serie: duplicar una ventana temporal introduce redundancia exacta que puede sesgar la estimación de las autocorrelaciones durante el entrenamiento; interpolar mediante SMOTE entre ventanas de distintos pacientes puede generar trayectorias fisiológicamente implausibles.

En el contexto de la predicción de glucosa, la aplicación de SMOTE a los rangos glucémicos minoritarios (hipoglucemia, hiperglucemia severa) ha sido estudiada como estrategia para mejorar el rendimiento del modelo en los eventos clínicamente más relevantes.

En el contexto específico de datos glucémicos, el trabajo de Machado et al. [61] constituye la referencia más completa hasta la fecha sobre el impacto de los métodos de balanceo en minería

de datos basada en señales CGM. Los autores evaluaron una batería amplia de técnicas de sobre-muestreo (*random oversampling*, SMOTE, Borderline-SMOTE, ADASYN), submuestreo (*near miss*, ENN, *Tomek links*) e híbridas (SMOTE+ENN, SMOTE+*Tomek*) sobre los conjuntos de datos Ohio y St. Louis, abordando el problema como clasificación de episodios glucémicos (hipoglucemia, normoglucemia, hiperglucemia). Sus resultados muestran que, contrariamente a la intuición, las técnicas de sobremuestreo aisladas no producen mejoras consistentes: la limpieza de la frontera de decisión aportada por los métodos de submuestreo —en particular ENN— resulta tan o más determinante que la generación de ejemplos sintéticos. La combinación SMO-TE+ENN es la que mayor robustez exhibe a lo largo de todos los experimentos, alcanzando ganancias de hasta un 21 % en F1 para hipoglucemia respecto a la condición sin balanceo en la validación *leave-one-out* sobre datos CGM. Los autores también señalan que el impacto del balanceo es irregular entre rangos glucémicos: las ganancias son pronunciadas para hipoglucemia e hiperglucemia, pero modestas para normoglucemia, anticipando la heterogeneidad por rango que se analiza sistemáticamente en el presente trabajo.

3.5.2. Balanceo demográfico en series temporales fisiológicas

En el dominio de las señales fisiológicas de series temporales —electrocardiogramas, registros de actividad, señales CGM— la mayoría de los trabajos sobre desequilibrio se han centrado en el desequilibrio de clase de la variable objetivo (p. ej., detección de arritmias en señales ECG con clases minoritarias muy infrecuentes), no en el desequilibrio de la composición demográfica del conjunto de entrenamiento.

Sin embargo, algunos trabajos recientes constituyen excepciones relevantes. Ovalle et al. [46] —revisado en la sección anterior— aplican balanceo demográfico por raza en ventanas CGM para LSTM de predicción de glucosa. En el dominio de señales de actividad y estrés, Dahmen et al. [56] entrenan GAN condicionales sobre señales de sensores corporales para generar muestras sintéticas de subgrupos infrarrepresentados, si bien el atributo de balanceo es la clase de actividad, no un atributo demográfico.

La evidencia empírica más directa de que la composición demográfica del conjunto de entrenamiento afecta al rendimiento de modelos LSTM de predicción de glucosa sobre señales CGM proviene de Thomsen et al. [62]. En un diseño experimental riguroso, los autores entrenaron modelos LSTM sobre 11 configuraciones de datos construidas variando la proporción de participantes de raza blanca (*non-Hispanic White*) y raza negra (*non-Hispanic Black*) entre 0 % y 100 %, utilizando datos CGM de 205 participantes con DM1 recogidos por el centro JAEB. Los resultados del modelo generalizado (*Base-Generalized*) revelan una interacción estadísticamente significativa ($p = 0.02$) entre la raza y la proporción racial del conjunto de entrenamiento: a medida que aumenta la proporción de participantes blancos, el RMSE crece 0.04 mmol/L más en los participantes negros que en los blancos, es decir, el modelo favorece progresivamente al grupo mayoritario en entrenamiento. Esta disparidad desaparece al aplicar *transfer learning* personalizado ($p = 0.20$), lo que sugiere que la personalización es una estrategia complementaria eficaz. El estudio también encuentra que la edad es un predictor significativo del error ($p < 0.001$): la predicción de glucosa en niños produce errores sistemáticamente mayores que en adultos, independientemente de la raza o la composición del entrenamiento. Esta evidencia establece que la composición demográfica del conjunto de entrenamiento no es un factor neutral en los modelos de predicción CGM y que atributos como la edad constituyen una fuente de heterogeneidad que merece intervención explícita, motivando directamente el enfoque de balanceo por edad y por sexo adoptado en el presente trabajo.

3.5.3. Generación sintética de series temporales fisiológicas

La generación de series temporales sintéticas mediante modelos generativos profundos ha recibido atención creciente en los últimos años como alternativa al remuestreo exacto o a la interpolación lineal. Las familias de modelos más relevantes son las GAN temporales (TimeGAN [54], TS-GAN [55]), los modelos de difusión sobre series temporales [63] y los *variational autoencoders* condicionales.

En el dominio de la diabetes y la glucosa específicamente, la generación de pacientes sintéticos se ha explorado principalmente como estrategia de aumento de datos para mejorar el rendimiento global del modelo, no como mecanismo de balanceo demográfico:

Una línea de trabajo emergente propone la generación sintética condicional de series temporales médicas como estrategia para compensar el desequilibrio de subpoblaciones en los conjuntos de entrenamiento. Bing et al. [64] presentan HEALTHGEN, un modelo generativo basado en VAE secuencial que permite sintetizar historiales clínicos longitudinales condicionados sobre variables estáticas del paciente —incluyendo edad, sexo y etnia— respetando además los patrones de datos ausentes de los registros reales. Los autores demuestran sobre el conjunto MIMIC-III que la generación condicional de cohortes de subpoblaciones infrarrepresentadas y su incorporación al conjunto de entrenamiento mejora significativamente la equidad de los modelos resultantes, elevando el rendimiento en los grupos minoritarios sin degradar el de los grupos mayoritarios. Esta aproximación es conceptualmente análoga a la filosofía del balanceo demográfico explorado en el presente trabajo, si bien opera sobre la distribución de pacientes completos (generación a nivel de sujeto) en lugar de sobre la distribución de ventanas temporales (balanceo a nivel de instancia de entrenamiento). La ausencia de un modelo de generación condicional específicamente validado para señales CGM con atributos de edad y sexo como factores de condicionamiento constituye una de las brechas que delimitan la contribución del presente trabajo.

El trabajo más directamente relacionado con el diseño experimental del presente estudio es el de Mayo et al. [?], que introduce dos contribuciones metodológicas relevantes. La primera es la propuesta de métricas de error *glucemia-conscientes*: en lugar de evaluar el RMSE o el MARD sobre el rango completo, los autores desagregan el error por rango glucémico (hipoglucemia, normoglucemia, hiperglucemia), demostrando que la selección del mejor modelo varía sustancialmente según el rango considerado. La segunda es la aplicación de técnicas de sobremuestreo (*random oversampling*, SMOTE, ADASYN) al problema de regresión glucémica sobre el conjunto OhioT1DM, para lo cual adaptan las etiquetas de clase mediante *pseudolabels* basados en los rangos glucémicos. Sus resultados muestran que las redes MLP entrenadas con sobremuestreo superan a los modelos lineales en el rango hipoglucémico, con diferencias estadísticamente significativas ($p = 0.025$) frente al mejor modelo sin balanceo, mientras que para el rango normoglucémico el modelo lineal sin balanceo es más competitivo. Esta asimetría por rango sugiere que el impacto del balanceo no es uniforme a lo largo de la escala glucémica, lo que anticipa la necesidad de analizar el rendimiento desagregado por rango que se adopta como eje central del análisis de resultados en este trabajo. No obstante, Mayo et al. abordan el desequilibrio de clase glucémica —la distribución desigual de valores objetivo entre rangos— y no el desequilibrio demográfico del conjunto de entrenamiento, que es el objeto específico de esta investigación.

El estudio de Thomsen et al. [62], ya citado en la sección 2.3.3, proporciona además la única evidencia disponible de disparidad de rendimiento por subgrupo demográfico en predicción de glucosa con modelos LSTM sobre señales CGM reales, confirmando que la composición racial del entrenamiento produce efectos mesurables y estadísticamente significativos. La extensión de este análisis a las dimensiones de sexo y edad en una taxonomía sistemática de técnicas de balanceo —en lugar de limitarse a la composición racial del conjunto de entrenamiento— constituye la principal brecha que el presente trabajo aborda.

3.6. Brechas en la literatura y motivación del trabajo

La revisión anterior permite identificar tres brechas específicas que motivan y delimitan la contribución de este trabajo.

Primera brecha: el único estudio de disparidad demográfica en predicción de glucosa con LSTM sobre señales CGM se restringe a la dimensión racial y no cubre sexo ni grupos de edad. La evidencia de que la composición demográfica del conjunto de entrenamiento afecta al rendimiento de modelos de predicción en DM1 ha quedado establecida recientemente por Thomsen et al. [62], que demostraron una divergencia estadísticamente significativa en el RMSE entre participantes blancos y negros al variar la proporción racial del conjunto de entrenamiento de modelos LSTM sobre datos CGM. Sin embargo, ese estudio no evalúa las dimensiones de sexo ni de edad, pese a que la sección 3.3 establece que ambas variables están asociadas a diferencias fisiológicas demostrables en la dinámica glucémica [?]. La propia discusión de Thomsen et al. señala explícitamente que “*Future studies on investigating algorithmic fairness by other sensitive attributes are warranted*”, identificando sexo y edad como las dimensiones prioritarias de análisis. Este trabajo responde directamente a esa llamada, evaluando por primera vez y de forma sistemática la disparidad de rendimiento predictivo por sexo y por grupos de edad en modelos LSTM de predicción de glucosa sobre datos CGM, junto con estrategias de mitigación mediante balanceo.

Segunda brecha: las técnicas de remuestreo aplicadas a predicción de glucosa corrigen el desequilibrio de clase glucémica, no la composición demográfica del conjunto de entrenamiento. Los trabajos de Machado et al. [61] y Mayo et al. [?] demuestran que el balanceo del conjunto de entrenamiento mejora el rendimiento de los modelos de predicción glucémica, especialmente en los rangos de hipoglucemia. No obstante, en ambos casos la variable remuestreada es la clase glucémica de la variable objetivo (hipoglucemia, normoglucemia, hiperglucemia): se trata de corregir cuántas ventanas de entrenamiento pertenecen a cada rango de glucosa, no cuántas proceden de cada subgrupo demográfico. Esta distinción es conceptualmente fundamental: un conjunto de entrenamiento puede estar perfectamente equilibrado en la distribución de rangos glucémicos y, al mismo tiempo, presentar un desequilibrio severo en la proporción de ventanas procedentes de distintos grupos de edad o sexo. Las técnicas de balanceo estándar —incluyendo SMOTE y sus variantes— no diferencian ni corrigen este desequilibrio demográfico porque fueron diseñadas para operar sobre la variable objetivo, no sobre los atributos del sujeto que generó los datos. Este trabajo aplica explícitamente estas mismas técnicas redefiniendo la unidad de balanceo: en lugar de operar sobre la distribución de clases glucémicas, se opera sobre la distribución de grupos demográficos (sexo o grupo de edad) dentro del conjunto de entrenamiento, una distinción metodológica que la literatura señala como necesaria pero que no ha sido implementada ni evaluada de forma sistemática en el contexto de predicción de glucosa.

Tercera brecha: la literatura de equidad algorítmica en salud no contempla la distinción entre balanceo a nivel de paciente y balanceo a nivel de ventana temporal. Los trabajos existentes sobre disparidad demográfica en aprendizaje automático clínico, incluido el de Thomsen et al. [62], operan sobre observaciones donde la unidad de análisis es el paciente o el episodio clínico discreto. En el contexto de series temporales generadas mediante ventana deslizante sobre señales CGM, la unidad de balanceo efectiva no es el paciente sino la ventana: un mismo paciente con una serie temporal larga y densa puede aportar órdenes de magnitud más ventanas de entrenamiento que otro paciente con una serie corta o fragmentada, incluso perteneciendo ambos al mismo grupo demográfico nominal. En consecuencia, el desequilibrio demográfico en el conjunto de ventanas puede ser cualitativamente distinto —y a menudo más severo— que el desequilibrio a nivel de paciente, y ambos niveles pueden divergir por razones

ajenas a la composición demográfica de la cohorte, como el patrón de datos ausentes o la heterogeneidad en el tiempo de seguimiento entre pacientes. La gestión de esta distinción entre balanceo a nivel de paciente y balanceo a nivel de ventana, y su impacto sobre el rendimiento y la equidad del modelo resultante, no ha sido abordada en ninguno de los trabajos revisados.

Este trabajo se sitúa en la intersección de estas tres brechas: aplica un conjunto sistemático de técnicas de balanceo demográfico —adaptadas explícitamente a la unidad de ventana temporal en lugar de a la unidad de paciente— para evaluar empíricamente, en tres *datasets* públicos de DM1 y mediante un modelo LSTM de referencia validado, si la corrección de la composición demográfica del conjunto de entrenamiento por sexo y por edad mejora el rendimiento predictivo y reduce la disparidad entre subgrupos en la predicción de glucosa, con especial atención a los rangos glucémicos clínicamente críticos.

Capítulo 4

Desarrollo del trabajo

Este capítulo describe en detalle el proceso completo llevado a cabo para abordar la pregunta de investigación planteada en el capítulo . Se sigue el orden cronológico y lógico del trabajo: desde la recopilación y comprensión de los datos hasta la construcción del *pipeline* de entrenamiento y evaluación que produce los resultados analizados en el capítulo 5. Cada sección documenta las decisiones de diseño adoptadas, las alternativas consideradas y los criterios que motivaron la elección final, con el objetivo de garantizar la reproducibilidad del trabajo y la trazabilidad de cada decisión metodológica.

La figura ?? ofrece una visión de conjunto del flujo de trabajo completo, que se detalla a lo largo de las secciones siguientes.

4.1. Recopilación y descripción de los datos

Esta sección describe el proceso de recopilación de los tres conjuntos de datos utilizados en el trabajo, los criterios de selección que motivaron su elección y las características estructurales relevantes de cada uno de ellos desde el punto de vista del problema de balanceo demográfico. La descripción clínica y demográfica de los *datasets* se introduce en el capítulo 2.3.4; aquí se documentan los aspectos prácticos de su obtención y las particularidades que condicionaron las decisiones de preprocesado posteriores.

4.1.1. Criterios de selección de los *datasets*

La selección de los conjuntos de datos estuvo guiada por cuatro criterios complementarios, cuya aplicación conjunta redujo el espacio de candidatos a los tres repositorios finalmente utilizados.

Disponibilidad pública y accesibilidad. Los datos debían ser accesibles de forma abierta o previa solicitud no restrictiva, de manera que los experimentos fueran reproducibles por la comunidad investigadora sin barreras institucionales. Este criterio descartó varias cohortes hospitalarias de acceso restringido identificadas durante la revisión bibliográfica.

Presencia de variables demográficas a nivel de paciente. El objetivo central del trabajo es cuantificar el efecto del balanceo demográfico sobre el rendimiento del modelo predictivo. Para ello es imprescindible disponer de al menos las variables *sexo* y *edad* con resolución de paciente, de modo que puedan definirse subgrupos clínicamente relevantes y aplicarse las técnicas de balanceo de forma controlada. Repositorios con ausencia de una o ambas variables, o con anonimización que impidiera la asignación de grupo demográfico, fueron excluidos.

Frecuencia de muestreo CGM suficiente. Para la construcción de ventanas de entrada de 8 pasos temporales con un horizonte de predicción de 60 minutos ($PH=4$), la frecuencia de muestreo debe ser, como mínimo, de 15 minutos entre lecturas consecutivas. Datasets con cadencias superiores a 15 minutos o con elevada proporción de huecos estructurales no recuperables fueron descartados por no garantizar la densidad mínima de ventanas válidas.

Diversidad estructural entre repositorios. Se buscó deliberadamente que los tres *datasets* seleccionados presentaran características estructurales heterogéneas —tamaño muestral, duración del seguimiento, cadencia nativa del sensor, origen clínico o de estudio— con el fin de que los resultados del análisis de balanceo no dependieran de las particularidades de una única fuente de datos. Esta diversidad estructural constituye también una garantía de generalidad de las conclusiones obtenidas.

Otros repositorios revisados durante la fase de selección —entre ellos el *OhioT1DM dataset* [?] y diversas cohortes de proyectos europeos— fueron descartados bien por ausencia de la variable edad a nivel de paciente, bien por tamaños muestrales insuficientes para sostener la validación cruzada estratificada por paciente, o bien por no estar disponibles en acceso abierto en el momento de inicio del trabajo.

4.1.2. T1DiabetesGranada

El *dataset* T1DiabetesGranada fue proporcionado directamente por el Hospital Universitario Virgen de las Nieves de Granada en el marco del proyecto RELIEF-T1D. Se trata de uno de los repositorios de monitorización continua de glucosa más completos disponibles en diabetes de tipo 1, tanto por su volumen —más de 30 millones de mediciones— como por la duración del seguimiento —entre 2018 y 2022, con periodos individuales de hasta cuatro años por paciente.

Estructura de los archivos. El repositorio crudo se compone de dos componentes principales. El primero es el archivo de mediciones glucémicas (*Glucose_measurements.csv*), con las columnas *Patient_ID*, *Measurement_date* (formato YYYY-MM-DD), *Measurement_time* (HH:MM:SS) y *GlucoseValue*. El segundo es el archivo de información de paciente (*Patient_info.csv*), que incluye variables demográficas (*Sex*, *Birth_year*), fechas de inicio y fin de monitorización, y conteos de disponibilidad de datos (*Number_of_days_with_measures*, *Number_of_measurements*), entre otras variables clínicas adicionales. La edad de cada paciente se calculó dinámicamente como la diferencia entre el año de la primera medición disponible y el año de nacimiento, garantizando una alineación temporal precisa entre la variable demográfica y el periodo de monitorización [65].

Cadencia nativa de 15 minutos. A diferencia de los otros dos *datasets*, T1DiabetesGranada emplea dispositivos CGM con cadencia nativa de 15 minutos. Esta particularidad impuso adaptaciones específicas en el algoritmo de remuestreo (véase sección ??): mientras que REPLACE-BG y DiaTrend se procesan con un paso $\Delta = 300$ s y tolerancias estrechas (± 2 s), Granada utiliza $\Delta = 900$ s con tolerancias relajadas (± 120 s) y una sonda de punto medio más amplia, preservando la fase nativa del dispositivo sin forzar una expansión a cuadrícula de 5 minutos que introduciría un sesgo de fase sistemático [65].

Patrón MNAR de missingness. El análisis exploratorio inicial (mayo 2026) identificó un patrón de datos faltantes de tipo MNAR (*Missing Not At Random*): los huecos en las series temporales no son aleatorios sino que se concentran en episodios de alta variabilidad glucémica o en periodos de baja adherencia al sensor, ambos correlacionados con el estado clínico del

paciente. Este hallazgo tuvo implicaciones directas sobre la estrategia de ventaneo: las ventanas que contenían huecos en cualquiera de sus ocho posiciones de entrada o en la posición objetivo fueron descartadas, en lugar de imputadas, para evitar introducir información artificial que distorsionara el análisis de balanceo posterior.

Separabilidad demográfica. El mismo análisis exploratorio cuantificó la separabilidad de los subgrupos demográficos mediante el tamaño del efecto de Cohen (d) sobre ventanas clínicas de 1, 14 y 90 días. Los resultados evidenciaron diferencias estadísticamente significativas en la distribución glucémica entre grupos de edad y entre sexos, confirmando que el balanceo demográfico tiene potencial de efecto real sobre el rendimiento del modelo predictivo y justificando la inclusión de este *dataset* como caso de estudio principal.

El conjunto resultante comprende **643 pacientes**, con un rango de sensor de [40, 500] mg/dL y más de 30 millones de mediciones brutas, que tras el remuestreo y la generación de ventanas válidas producen el mayor conjunto de instancias de los tres repositorios considerados.

4.1.3. REPLACE-BG

REPLACE-BG es un *dataset* procedente de un ensayo clínico aleatorizado y controlado publicado por Aleppo *et al.* [66] con el objetivo de evaluar la seguridad del uso de la monitorización continua de glucosa sin calibración con glucómetro capilar en adultos con diabetes de tipo 1. El estudio reclutó a 226 participantes adultos distribuidos en dos brazos de intervención —CGM con y sin calibración capilar— con un seguimiento de 26 semanas bajo protocolo clínico estricto.

Acceso y estructura. El repositorio está disponible públicamente a través del repositorio *JAEB Center for Health Research*. Los datos brutos incluyen el archivo de mediciones CGM (*HDeviceCGM*), con variables de tiempo, tipo de evento y valor glucémico, junto con las tablas de información de paciente (*Screening* y *Roster*). El preprocesado aplicado por Alemán Granados [65] seleccionó *DeviceTime* como referencia temporal canónica —por ser la variable con menor proporción de valores ausentes— y descartó los registros de calibración (0,95 % del total) y los datos previos a la aleatorización (29,79 % del total), reteniendo únicamente la fase de intervención controlada.

Homogeneidad demográfica por diseño. REPLACE-BG es el único de los tres repositorios con diseño experimental controlado, lo que le confiere una distribución demográfica más homogénea que las cohortes observacionales. El reclutamiento protocolizado garantiza proporciones similares de sexo y rangos de edad acotados, a diferencia de los sesgos de selección presentes en datos de registro de vida real. Esta característica hace que el potencial efecto del balanceo demográfico sea *a priori* menor que en los otros dos *datasets*, sirviendo como caso de referencia o control dentro del diseño experimental del trabajo.

Las variables demográficas disponibles a nivel de paciente incluyen sexo, edad, HbA1c y duración de la enfermedad, obtenidas por fusión de las tablas *Screening* y *Roster* [65]. El *dataset* resultante comprende **226 pacientes**, con cadencia nativa de 5 minutos y un rango de sensor de [39, 401] mg/dL.

4.1.4. DiaTrend

DiaTrend es un repositorio de CGM longitudinal publicado por Sun *et al.* [67] que recoge datos de vida real de pacientes adultos con diabetes de tipo 1, con seguimientos de hasta siete años. El repositorio está disponible en acceso abierto y fue diseñado específicamente para facilitar el desarrollo y la evaluación de modelos de predicción de glucosa a largo plazo.

Estructura y preprocesado. En su forma original, DiaTrend consiste en 54 archivos individuales, uno por paciente (`Subject1.csv`, ..., `Subject54.csv`), con las columnas `date` y concentración de glucosa en sangre (mg/dL). El preprocesado aplicado por Alemán Granados [65] unificó los 54 archivos en un único *dataset* estructurado, añadiendo la columna `Patient_ID` para preservar la trazabilidad individual y estandarizando los nombres de columna a `Timestamp` y `GlucoseValue`.

Limitaciones del repositorio. DiaTrend es el *dataset* de menor tamaño muestral de los tres considerados —**54 pacientes**— lo que implica que, tras la partición en cinco *folds* y la separación por subgrupo demográfico, el número de pacientes por celda (grupo de edad $\times$ *fold*) es reducido. Esta circunstancia amplifica la variabilidad de los resultados de balanceo y hace que el análisis de estabilidad inter-*fold* sea especialmente relevante para este repositorio. Adicionalmente, DiaTrend no incluye anotaciones de insulina ni de ingesta de carbohidratos, lo que limita su uso a escenarios de predicción basados exclusivamente en la historia glucémica, coherentemente con la arquitectura LSTM univariante utilizada en este trabajo. El rango de sensor es de [39, 401] mg/dL con cadencia nativa de 5 minutos.

4.1.5. Estructura unificada de datos de entrada

Los tres *datasets* fueron transformados a un formato unificado mediante el *pipeline* de preprocesado desarrollado por Alemán Granados [65] y descrito en detalle en las secciones ?? y ??. El resultado de dicho proceso es, para cada *dataset* y horizonte de predicción, un único archivo *parquet* con la siguiente estructura de columnas:

- **Columnas de entrada:** `x0`, `x1`, ..., `x7` — los ocho valores de glucosa consecutivos (en mg/dL) que constituyen la ventana de historia de 120 minutos.
- **Columna objetivo:** `y` — el valor de glucosa en el horizonte de predicción (en mg/dL).
- **Columnas de trazabilidad:** `x_date_7` y `x_time_7` — fecha y hora de la última medición de la ventana de entrada, utilizadas para la desagregación por rango glucémico y la auditoría de resultados.
- **Identificador de paciente:** `patient_id` — preservado para la validación cruzada por paciente y el análisis de balanceo.
- **Columnas de *fold*:** `fold_0`, `fold_1`, ..., `fold_4` — asignación de cada ventana a la partición correspondiente ('train', 'val' o 'test') en cada uno de los cinco *folds* de validación cruzada.

Además del archivo de ventanas, cada *dataset* dispone de un archivo de información de paciente con las variables demográficas necesarias para el balanceo: `patient_id`, `sex` y `age` (o `birth_year` en el caso de T1DiabetesGranada, donde la edad se calcula dinámicamente).

Los límites de sensor aplicados durante el proceso de *clipping* —paso previo al entrenamiento, descrito en la sección 4.8.2— son específicos de cada *dataset* y reflejan el rango operativo declarado por el fabricante del dispositivo CGM correspondiente:

La heterogeneidad entre los tres *datasets* —tanto en número de pacientes como en cadencia, duración de seguimiento y volumen de datos— es precisamente lo que hace que el diseño experimental de este trabajo sea informativo: si el efecto del balanceo demográfico fuera consistente entre repositorios tan distintos, las conclusiones tendrían un alcance de generalización mayor que el obtenible con una única cohorte.

Tabla 4.1: Características principales de los *datasets* utilizados.

Dataset	Pacientes	Cadencia	Seguimiento	Mediciones	Rango sensor (mg/dL)
T1DGranada	643	15 min	≤4 años	>30 M	[40, 500]
REPLACE-BG	226	5 min	26 semanas	~9 M	[39, 401]
DiaTrend	54	5 min	≤7 años	~0,8 M	[39, 401]

4.2. Análisis exploratorio de datos

Antes de proceder a la construcción del *pipeline* experimental, se realizó un análisis exploratorio de datos (EDA) con dos objetivos: comprender las propiedades estadísticas y estructurales de cada *dataset*, y obtener evidencia cuantitativa de la presencia —o ausencia— de desequilibrio demográfico en la composición de los datos de partida. Este análisis es el que justifica y motiva las decisiones de diseño del *pipeline* de balanceo descritas en la sección ??.

4.2.1. Distribución demográfica de los *datasets*

La composición demográfica de los tres *datasets* presenta desequilibrios marcados tanto en la dimensión de sexo como en la de grupo de edad, aunque con patrones distintos entre repositorios. Las figuras 4.1, 4.2 y 4.3 muestran, de forma agregada para los tres conjuntos, la distribución de pacientes por grupo de edad, por sexo y la interacción entre ambas dimensiones.




Figura 4.1: Distribución de pacientes por grupo de edad (<31, 31–45, 46–65, ≥66) en cada *dataset*.

Distribución por grupo de edad. El grupo de edad dominante varía entre repositorios. T1DiabetesGranada, al proceder de un registro hospitalario de larga duración, concentra la mayor parte de sus pacientes en las franjas de mediana edad (31–45 y 46–65 años), con una representación notablemente inferior del grupo más joven (<31) y del grupo de mayor edad (≥66). REPLACE-BG, por su diseño de ensayo clínico con criterios de inclusión acotados, presenta una distribución por edad DiaTrend, con solo 54 pacientes, muestra la mayor variabilidad relativa entre grupos etarios, con celdas de muy baja frecuencia que condicionan directamente la aplicabilidad de las técnicas de balanceo.

Distribución por sexo. Los tres *datasets* presentan un cierto predominio de uno de los sexos, aunque la magnitud del desequilibrio difiere.




Figura 4.2: Distribución de pacientes por sexo en cada *dataset*.




Figura 4.3: *Heatmap* de la distribución conjunta edad $\times$ sexo por *dataset*. Cada celda muestra el número de pacientes en esa combinación demográfica.

Interacción edad $\times$ sexo. El *heatmap* de la figura 4.3 revela que el desequilibrio no es independiente entre dimensiones:

4.2.2. Distribución de la señal CGM

La distribución de los valores de glucosa presenta diferencias tanto entre *datasets* como entre subgrupos demográficos dentro de cada uno de ellos. La figura 4.4 muestra, mediante diagramas de violín, la distribución de la glucemia por grupo de edad en los tres repositorios. La figura 4.5 desagrega el tiempo en rango por sexo.




Figura 4.4: Distribución de los valores de glucosa (mg/dL) por grupo de edad en cada *dataset*. Las líneas horizontales internas indican la mediana; los límites del violín, el rango intercuartílico (IQR).




Figura 4.5: Porcentaje de mediciones en cada rango glucémico (TBR-2, TBR-1, TIR, TAR-1, TAR-2) desagregado por sexo y *dataset*.

Estadísticos descriptivos globales. Los tres *datasets* presentan distribuciones de glucosa con asimetría positiva característica de las poblaciones con diabetes de tipo 1, con una cola derecha más pronunciada que refleja los episodios de hiperglucemia.

Diferencias entre rangos de sensor. T1DiabetesGranada emplea dispositivos con un rango operativo de [40, 500] mg/dL, mientras que REPLACE-BG y DiaTrend utilizan sensores con




Figura 4.6: Distribución de mediciones por rango glucémico (TBR-2, TBR-1, TIR, TAR-1, TAR-2) según grupo de edad, por *dataset*.

rango [39, 401] mg/dL. Esta diferencia implica que la cola superior de la distribución glucémica de T1DiabetesGranada captura episodios de hiperglucemia severa que los otros dos repositorios truncan al valor máximo del sensor (401 mg/dL).

Variabilidad glucémica por subgrupo demográfico. Los diagramas de violín revelan La desagregación por sexo (figura 4.5) muestra

4.2.3. Análisis de datos ausentes

La presencia de datos ausentes en series temporales CGM no es aleatoria. En los tres *datasets* considerados, los huecos en las series temporales responden a causas estructurales —retirada del sensor, fallos de calibración, periodos de hospitalización— que los convierten en un caso de *missing not at random* (MNAR): la probabilidad de ausencia está correlacionada con el estado clínico del paciente y, por tanto, con los propios valores glucémicos no observados.




Figura 4.7: Número de mediciones por paciente desagregado por grupo de edad y *dataset*. La gran dispersión inter-paciente refleja la heterogeneidad en la duración efectiva del seguimiento y en la adherencia al sensor.

Heterogeneidad inter-paciente. La figura 4.7 pone de manifiesto una elevada dispersión en el número de mediciones por paciente dentro de cada *dataset*. Esta heterogeneidad no es independiente del grupo demográfico:




Figura 4.8: Duración del seguimiento (en días) por grupo de edad y *dataset*.

Patrón MNAR en T1DiabetesGranada. T1DiabetesGranada es el *dataset* en el que el patrón MNAR es más pronunciado, dada la duración de seguimiento de hasta cuatro años y la naturaleza observacional de los datos. Los huecos se concentran en episodios de alta variabilidad glucémica y en periodos de baja adherencia al sensor, ambos correlacionados con el estado clínico del paciente.

Impacto sobre la generación de ventanas. El patrón MNAR impone una restricción fundamental sobre la estrategia de ventaneo: las ventanas de historia que contienen uno o más valores ausentes en cualquiera de sus ocho posiciones de entrada, o en la posición objetivo, son descartadas íntegramente en lugar de imputadas. Esta decisión evita introducir información artificial que distorsionaría el análisis de balanceo posterior, pero implica que el número de ventanas válidas por paciente es proporcional a la longitud de sus segmentos continuos de registro, amplificando el desequilibrio demográfico a nivel de ventana respecto al desequilibrio a nivel de paciente (véase sección 4.3.1).

4.2.4. Análisis de separabilidad demográfica

Para cuantificar si las diferencias glucémicas entre subgrupos demográficos son estadísticamente detectables, se calculó el tamaño del efecto de Cohen (d) comparando las distribuciones glucémicas entre pares de grupos, en ventanas clínicas de 1, 14 y 90 días. El análisis se llevó a cabo sobre T1DiabetesGranada, el único *dataset* con suficiente volumen y duración de seguimiento para sostener ventanas de 90 días con representación adecuada en todos los grupos demográficos.

Interpretación de los resultados. Los valores de Cohen d obtenidos revelan que las diferencias glucémicas entre subgrupos demográficos son estadísticamente detectables pero de magnitud La separabilidad El par de grupos con mayor separabilidad es

Implicaciones para el diseño experimental. La existencia de diferencias glucémicas entre subgrupos demográficos, aunque de magnitud moderada, constituye una evidencia cuantitativa de que la composición demográfica del conjunto de entrenamiento puede influir en el rendimiento diferencial del modelo LSTM por subgrupo. Esto justifica el estudio sistemático de las técnicas de balanceo y, en particular, la evaluación por rango glucémico descrita en la sección 4.8.3: si el modelo aprende una distribución glucémica sesgada hacia los grupos mayoritarios, el error será mayor en los rangos donde los grupos minoritarios tienen una distribución distinta.




Figura 4.9: Glucemia media por grupo de edad y *dataset*. Las barras de error representan la desviación típica inter-paciente dentro de cada grupo.




Figura 4.10: Variabilidad glucémica intra-grupo por dimensión demográfica y *dataset*.

Tabla 4.2: Tamaño del efecto de Cohen (*d*) para las diferencias glucémicas entre subgrupos demográficos en T1DiabetesGranada, calculado sobre ventanas clínicas de 1, 14 y 90 días.

Comparación	Ventana 1 día	Ventana 14 días	Ventana 90 días
<i>Dimensión edad</i>			
<31 vs. 31–45	TODO	TODO	TODO
<31 vs. 46–65	TODO	TODO	TODO
<31 vs. ≥66	TODO	TODO	TODO
31–45 vs. 46–65	TODO	TODO	TODO
31–45 vs. ≥66	TODO	TODO	TODO
46–65 vs. ≥66	TODO	TODO	TODO
<i>Dimensión sexo</i>			
Hombre vs. Mujer	TODO	TODO	TODO

4.3. Detección y cuantificación del desequilibrio demográfico

Una vez comprendidas las propiedades estructurales de los *datasets* a nivel de paciente, el siguiente paso es cuantificar el desequilibrio demográfico a nivel de **ventana de entrenamiento**, que es la unidad de balanceo relevante en este trabajo. Como se argumenta en la sección 2.3.3, la unidad de balanceo en el contexto de series temporales generadas mediante ventana deslizante no es el paciente sino la ventana, y el desequilibrio a nivel de ventana puede ser sustancialmente mayor que el desequilibrio a nivel de paciente.

4.3.1. Desequilibrio a nivel de paciente frente a nivel de ventana

El desequilibrio demográfico a nivel de paciente puede amplificarse o atenuarse al calcular el desequilibrio a nivel de ventana, dependiendo de si los pacientes de los grupos mayoritarios tienen series temporales más largas o más cortas que los de los grupos minoritarios. Las figuras 4.11, 4.12 y 4.13 cuantifican este efecto.

Amplificación del desequilibrio al pasar de paciente a ventana. En T1DiabetesGranada, el paso de la unidad de análisis de paciente a ventana produce una amplificación del desequilibrio en la dimensión edad. En REPLACE-BG En DiaTrend

Implicación para la elección de la unidad de balanceo. Este análisis confirma que operar directamente sobre ventanas, en lugar de sobre pacientes, es la decisión correcta para este problema: el desequilibrio observable por el modelo durante el entrenamiento es el desequilibrio a nivel de ventana, no a nivel de paciente. Las técnicas de balanceo descritas en la sección ?? actúan por tanto sobre la distribución de ventanas, no sobre la de pacientes.

4.3.2. Desequilibrio por dimensión demográfica y *fold*

El esquema de validación cruzada Group K-Fold asigna cada paciente íntegramente a un único *fold*, de modo que la composición demográfica de cada partición de entrenamiento depende de qué pacientes concretos quedan excluidos en ese *fold* (los del test). Como resultado, el ratio de desequilibrio demográfico no es constante entre *folds*: varía en función de la distribución demográfica de los pacientes asignados al conjunto de test de cada iteración.

Tabla 4.3: Ratio de desequilibrio a nivel de ventana (grupo mayoritario / grupo minoritario) por *fold*, dimensión demográfica y *dataset* (horizonte PH=4). Los valores ilustran la variabilidad introducida por el esquema Group K-Fold.

Dataset	Dimensión	Fold 0	Fold 1	Fold 2	Fold 3	Fold 4
T1DGranada	Edad	TODO	TODO	TODO	TODO	TODO
T1DGranada	Sexo	TODO	TODO	TODO	TODO	TODO
REPLACE-BG	Edad	TODO	TODO	TODO	TODO	TODO
REPLACE-BG	Sexo	TODO	TODO	TODO	TODO	TODO
DiaTrend	Edad	TODO	TODO	TODO	TODO	TODO
DiaTrend	Sexo	TODO	TODO	TODO	TODO	TODO

Variabilidad inter-*fold* del desequilibrio. La tabla 4.3 muestra que el ratio de desequilibrio no es estable entre *folds*. Esta variabilidad tiene una implicación directa sobre la interpretación de los resultados: las diferencias de rendimiento entre condiciones de balanceo observadas en un




Figura 4.11: Distribución del número de ventanas de entrenamiento por grupo de edad en cada *dataset* (horizonte PH=4, fold de referencia). Los valores absolutos y porcentuales permiten comparar el desequilibrio a nivel de ventana con el desequilibrio a nivel de paciente de la figura 4.1.




Figura 4.12: Ratio de desequilibrio (grupo mayoritario / grupo minoritario) a nivel de ventana por dimensión de edad y *dataset*. Un ratio de 1,0 indica distribución perfectamente equilibrada.




Figura 4.13: Distribución del número de ventanas de entrenamiento por sexo en cada *dataset*.

fold concreto pueden ser parcialmente atribuibles a la composición demográfica de ese *fold*, no exclusivamente a la técnica de balanceo. Esta es una de las razones por las que el protocolo de evaluación adopta la agregación sobre los cinco *folds* (media y desviación estándar) y el análisis estadístico de Friedman en lugar de comparaciones punto a punto entre condiciones.

4.4. Investigación de técnicas de balanceo para series temporales

La selección de las técnicas de balanceo a implementar requirió una fase de investigación específica orientada a evaluar la compatibilidad de las técnicas estándar de *imbalanced learning* con las restricciones propias de la señal CGM. Esta sección describe los criterios de selección y la taxonomía de técnicas resultante.

4.4.1. Criterios de selección de técnicas

La elección de las diez técnicas implementadas no fue arbitraria: cada candidata fue evaluada frente a tres criterios de compatibilidad que derivan directamente de la naturaleza del problema.

1. Compatibilidad con la unidad de balanceo. En este trabajo la unidad de muestreo no es el paciente sino la *ventana temporal* de observación, un vector de ocho mediciones CGM consecutivas que se extrae mediante una ventana deslizante. Cualquier técnica que requiera conocer la estructura de la serie completa de un paciente (p. ej., métodos de interpolación de series como TimeGAN [54] o técnicas basadas en DTW [68]) introduce dependencias entre ventanas que presuponen continuidad entre segmentos que en los datos reales pueden estar separados por periodos de no uso del sensor. Se descartaron igualmente los métodos que actúan a nivel de instancia de paciente (ADASYN orientado a pacientes [69]) porque en nuestro diseño el nivel de análisis demográfico se proyecta sobre ventanas, no sobre sujetos.

2. Respeto de los límites fisiológicos del sensor. Los monitores CGM tienen un rango de medición físico acotado: [40, 500] mg/dL para T1DiabetesGranada y [39, 401] mg/dL para REPLACE-BG y DiaTrend [34, 70]. Cualquier técnica que genere valores sintéticos (SMOTE, Jittering) debe garantizar que los puntos resultantes no superen estos límites, puesto que valores fuera de rango son fisiológicamente imposibles y podrían sesgar el modelo LSTM introduciendo distribuciones que no existen en la señal real. Como mecanismo de garantía, todas las técnicas generativas incorporan un *clip* final a los límites del sensor del dataset correspondiente (véase función `clip_feature_columns` en la implementación). Se descartaron variantes de Gaussian Noise sin clip y técnicas de extrapolación.

3. Aplicabilidad exclusiva al conjunto de entrenamiento de cada fold. La validación cruzada Group K-Fold con $K = 5$ garantiza que ningún paciente aparece simultáneamente en train y en val/test. Sin embargo, para que la comparación entre técnicas sea válida, los conjuntos de validación y test deben ser *idénticos bit a bit* entre todas las condiciones experimentales. Esto excluye cualquier técnica que, por su diseño, modifique ejemplos ya asignados a val o test, o cuyo muestreo aleatorio dependa del contenido de esos conjuntos. En la implementación, la separación se realiza antes de cualquier operación de balanceo: se extraen los índices de val y test y se concatenan intactos tras el balanceo del train (véase el flujo principal de `process_dataset`). Se descartaron asimismo técnicas que requieran modificar la arquitectura del modelo (pérdidas ponderadas por clase, *focal loss* [71]), ya que el objetivo del trabajo es evaluar el efecto del balanceo de datos de forma aislada, manteniendo fija la arquitectura LSTM.

4.4.2. Taxonomía de técnicas implementadas

Las diez técnicas seleccionadas se organizan en tres familias según su mecanismo de acción: aleatorias (modifican la distribución sin crear información nueva), guiadas (incorporan información estructural del espacio de features o de la topología de los datos) e híbridas (combinan un mecanismo de aumento con uno de reducción para preservar el tamaño total del conjunto de entrenamiento). La Tabla 4.4 resume la clasificación.

Tabla 4.4: Taxonomía de las diez técnicas de balanceo implementadas.

Familia	Técnica	Mecanismo	Tamaño post-balanceo
Aleatoria	RUS (<code>undersampling</code>)	Eliminación aleatoria	$< N_{\text{train}}$
Aleatoria	ROS (<code>oversampling</code>)	Duplicación aleatoria	$> N_{\text{train}}$
Guiada	SMOTE (<code>smote</code>)	Interpolación k-NN	$> N_{\text{train}}$
Guiada	Tomek Links (<code>tomek_links</code>)	Limpieza de frontera	$\leq N_{\text{train}}$
Guiada	Jittering (<code>jittering</code>)	Ruido gaussiano local	$> N_{\text{train}}$
Híbrida	<code>patient_aware_undersampling</code>	RUS con cuota por paciente	$< N_{\text{train}}$
Híbrida	<code>undersampling_oversampling</code>	RUS + ROS	$= N_{\text{train}}$
Híbrida	<code>undersampling_smote</code>	RUS + SMOTE	$= N_{\text{train}}$
Híbrida	<code>smote_tomek</code>	SMOTE + Tomek	$\approx N_{\text{train}}$
Híbrida	<code>oversampling_tomek</code>	ROS + Tomek	$= N_{\text{train}}$

Familia aleatoria

Las técnicas aleatorias operan exclusivamente mediante reordenamiento o duplicación de índices y no acceden al contenido de las features. Su ventaja principal es la reproducibilidad exacta dado un generador inicializado con semilla fija (`np.random.default_rng(seed)`).

Random Under-Sampling (RUS). RUS reduce el conjunto de entrenamiento igualando todos los grupos demográficos al tamaño del grupo minoritario. Formalmente, sea $\mathcal{G} = \{g_1, \dots, g_K\}$ el conjunto de grupos (categorías de edad o sexo) y $n_k = |\mathcal{D}_{\text{train}}^{(g_k)}|$ el número de ventanas de cada grupo en el fold de entrenamiento. El target de balanceo es:

$$n^* = \min_k n_k \quad (4.1)$$

Para cada grupo g_k con $n_k > n^*$, se selecciona aleatoriamente sin reemplazo un subconjunto de n^* índices:

$$\mathcal{I}_{\text{RUS}}^{(g_k)} = \text{SAMPLE}(\mathcal{I}^{(g_k)}, n^*, \text{replace} = \text{False}) \quad (4.2)$$

En la implementación (`undersample_group`), la selección se realiza con `rng.choice(index, size=target, replace=False)`, garantizando que cada ventana original aparece como máximo una vez en el conjunto resultante. El efecto es una reducción del total de ventanas de entrenamiento, lo que puede conllevar pérdida de información en grupos grandes, pero elimina el sesgo de representación demográfica. RUS es la línea base más restrictiva del experimento: cualquier mejora observada frente a ella cuantifica el valor añadido de técnicas más sofisticadas.

Random Over-Sampling (ROS). ROS incrementa todos los grupos hasta igualar el tamaño del grupo mayoritario mediante duplicación aleatoria con reemplazo. El target es:

$$n^* = \max_k n_k \quad (4.3)$$

Para cada grupo g_k con $n_k < n^*$, se muestrean con reemplazo $n^* - n_k$ índices adicionales del propio grupo, que se concatenan a las ventanas originales:

$$\mathcal{I}_{\text{ROS}}^{(g_k)} = \mathcal{I}^{(g_k)} \cup \text{SAMPLE}(\mathcal{I}^{(g_k)}, n^* - n_k, \text{replace} = \text{True}) \quad (4.4)$$

En la implementación (`oversample_group`), la operación es `rng.choice(index, size=target, replace=True)` para grupos con $n_k < n^*$; grupos que ya superan n^* se devuelven intactos. El coste de ROS es la introducción de ventanas duplicadas: el modelo puede sobreajustarse a los patrones específicos de los pacientes con menos datos, especialmente si un único paciente representa a su grupo demográfico con pocas ventanas.

Familia guiada

Las técnicas guiadas incorporan información estructural del espacio de features o de la topología del conjunto de datos para generar muestras sintéticas más realistas o para eliminar ejemplos ambiguos en la frontera de decisión.

SMOTE (*Synthetic Minority Oversampling TEchnique*). SMOTE [19] genera muestras sintéticas por interpolación lineal en el espacio de features entre una ventana real y uno de sus vecinos más cercanos del mismo grupo. En este trabajo, la implementación propia (`smote_group`) sigue los siguientes pasos:

1. **Normalización z-score.** Las features $(x_0, \dots, x_7, y)$ se escalan antes de calcular distancias para evitar que las magnitudes absolutas de glucemia dominen el cálculo de vecindad:

$$\tilde{\mathbf{x}} = \frac{\mathbf{x} - \boldsymbol{\mu}}{\sigma} \quad (4.5)$$

donde $\boldsymbol{\mu}$ y σ son la media y desviación estándar del grupo g_k . Las dimensiones con $\sigma = 0$ se tratan como $\sigma = 1$ para evitar divisiones por cero.

2. **Búsqueda de vecinos.** Se ajusta un índice de vecinos más cercanos con métrica euclidiana sobre el espacio escalado. El número de vecinos es $k = \min(5, n_k - 1)$, lo que adapta el parámetro automáticamente a grupos con pocos ejemplos.
3. **Generación sintética.** Para cada una de las $n^* - n_k$ muestras necesarias, se elige aleatoriamente un punto base $\mathbf{x}_i$ del grupo y uno de sus k vecinos $\mathbf{x}_j$ (excluyendo el propio punto). La muestra sintética se genera como:

$$\mathbf{x}_{\text{synth}} = \mathbf{x}_i + \lambda \cdot (\mathbf{x}_j - \mathbf{x}_i), \quad \lambda \sim \mathcal{U}(0, 1) \quad (4.6)$$

La interpolación se realiza en el espacio original (no escalado), tomando la fila completa del punto base y sustituyendo únicamente las columnas de feature.

4. **Clip a límites del sensor.** Todos los valores sintéticos se recortan al rango $[v_{\min}, v_{\max}]$ del dataset correspondiente, garantizando la plausibilidad fisiológica.

El resultado es un conjunto de ventanas adicionales que mantienen la coherencia local del espacio de glucemia, sin duplicar ventanas existentes. SMOTE se usa como técnica de aumento puro: solo opera si el grupo actual tiene menos ventanas que el target.

Tomek Links. Los Tomek Links [18] son pares de ejemplos (i, j) de grupos distintos que son vecinos más cercanos mutuos, es decir, $NN(i) = j$ y $NN(j) = i$. Estos pares identifican ejemplos que se sitúan en la frontera de decisión entre grupos, precisamente donde el clasificador (en este caso, el modelo LSTM) tiene mayor dificultad para generalizar. La implementación (`find_tomek_links`) opera sobre el conjunto de entrenamiento completo (todos los grupos juntos):

1. Se normaliza la matriz de features con z-score sobre el conjunto global.
2. Se construye un índice de vecinos más cercanos con $k = 2$ (el más próximo, excluyendo el propio punto).
3. Para cada par (i, j) con $NN(i) = j$, $NN(j) = i$ y $\text{label}(i) \neq \text{label}(j)$, se marca para eliminación el ejemplo perteneciente al grupo mayoritario:

$$\text{eliminar} = \begin{cases} i & \text{si } n_{\text{label}(i)} \geq n_{\text{label}(j)} \\ j & \text{en caso contrario} \end{cases} \quad (4.7)$$

A diferencia de RUS, Tomek Links no persigue una proporción objetivo: elimina únicamente los ejemplos ruidosos o ambiguos en la frontera, sin alterar el resto del conjunto. El resultado es un conjunto de entrenamiento ligeramente más pequeño pero con una frontera de decisión más nítida. Esta técnica es la única de las diez que no recibe un target numérico sino que actúa de forma puramente selectiva.

Jittering. Jittering es una técnica de aumento basada en la adición de ruido gaussiano a ventanas existentes [72]. A diferencia de SMOTE, no requiere búsqueda de vecinos y es especialmente adecuada para señales fisiológicas donde la variabilidad local es una propiedad intrínseca de la medida. La implementación (`jitter_group`) genera $n^* - n_k$ ventanas sintéticas mediante el siguiente procedimiento:

1. Se selecciona aleatoriamente una ventana base $\mathbf{x}_i$ del grupo.
2. Se calcula la desviación estándar por feature σ_{group} sobre todas las ventanas del grupo (con $\sigma_d = 1$ si $\sigma_d = 0$).
3. Se genera ruido gaussiano proporcional a la variabilidad local:

$$\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, (\alpha \cdot \sigma_{\text{group}})^2), \quad \alpha = 0.20 \quad (4.8)$$

4. La ventana sintética es $\mathbf{x}_{\text{synth}} = \mathbf{x}_i + \boldsymbol{\varepsilon}$, con clip final a $[v_{\min}, v_{\max}]$.

El parámetro $\alpha = 0.20$ implica que el ruido añadido tiene una amplitud del 20 % de la variabilidad observada en el grupo, lo que produce perturbaciones pequeñas pero suficientes para evitar la duplicación exacta. Al estar calibrado sobre la desviación estándar del grupo, el jitter es proporcionalmente mayor en grupos con alta variabilidad (p. ej., pacientes con grandes oscilaciones glucémicas) y menor en grupos más homogéneos.

Familia híbrida

Las técnicas híbridas combinan un mecanismo de aumento con uno de reducción para preservar el número total de ventanas de entrenamiento (N_{train} original), distribuyendo ese total equitativamente entre los grupos. Esta restricción de tamaño constante hace que el efecto del balanceo sea *neutro en volumen*: el modelo LSTM recibe siempre el mismo número de ventanas, y cualquier diferencia en rendimiento se atribuye exclusivamente al cambio de distribución demográfica.

El reparto equitativo se implementa en `compute_equal_targets`: dado un total N y K grupos, cada grupo recibe $\lfloor N/K \rfloor$ ventanas, y los primeros $N \bmod K$ grupos reciben una ventana extra para que la suma sea exactamente N .

patient_aware_undersampling. Variante de RUS que introduce una restricción adicional: ningún paciente del grupo mayoritario puede quedar sin representación en el conjunto de entrenamiento tras el undersampling. La función `patient_aware_undersample_group` calcula una cuota por paciente:

$$c_{\text{patient}} = \left\lceil \frac{n^*}{P_k} \right\rceil \quad (4.9)$$

donde P_k es el número de pacientes distintos en el grupo g_k . Para cada paciente se seleccionan $\min(n_p, c_{\text{patient}})$ ventanas sin reemplazo, y si el total resultante supera n^* se aplica un segundo paso de RUS global. Esta técnica es especialmente relevante para el dataset T1DiabetesGranada, donde algunos grupos de edad tienen un número muy pequeño de pacientes representativos.

undersampling_oversampling (RUS + ROS). Combina RUS sobre los grupos mayoritarios y ROS sobre los minoritarios, asignando a todos el mismo target $n^* = \lfloor N_{\text{train}}/K \rfloor$. Los grupos con más ventanas que n^* se submuestran aleatoriamente sin reemplazo; los que tienen menos se sobremuestran con reemplazo. El resultado tiene exactamente N_{train} ventanas con distribución $\approx 1/K$ por grupo.

undersampling_smote (RUS + SMOTE). Funciona de forma análoga a la técnica anterior pero sustituye ROS por SMOTE para los grupos minoritarios. Los grupos mayoritarios se reducen con RUS hasta el target equitativo; los grupos deficitarios se amplían con muestras sintéticas generadas por interpolación k-NN. Esta técnica preserva el tamaño total y evita la duplicación exacta de ventanas minoritarias a costa de un mayor coste computacional.

smote_tomek (SMOTE + Tomek). Esta técnica, adaptada de la propuesta original de Batista et al. [20], opera en tres pasos: (1) se aumentan los grupos minoritarios con SMOTE hasta el target equitativo; (2) se aplican Tomek Links sobre el conjunto resultante para eliminar ejemplos ambiguos en la frontera; (3) si algún grupo supera su target tras la limpieza, se aplica un RUS compensatorio. El efecto neto es un conjunto de tamaño $\approx N_{\text{train}}$ con frontera de decisión más limpia que el obtenido con SMOTE puro.

oversampling_tomek (ROS + Tomek). Parte de la lógica inversa: primero se aplican Tomek Links sobre el conjunto de grupos principales para eliminar pares ruidosos, reduciendo el total en n_{removed} ventanas; después se restaura el tamaño original añadiendo n_{removed} ventanas mediante ROS equitativo entre los grupos. El resultado preserva exactamente N_{train} ventanas y combina la limpieza de frontera de Tomek con la corrección de distribución de ROS.

4.4.3. Validación formal del *pipeline* de balanceo

La corrección del pipeline de balanceo fue verificada mediante un *notebook* de validación construido específicamente para este fin, ejecutado sobre los archivos `.parquet` de salida de `2-server_balancing.py` antes de lanzar los experimentos de entrenamiento. El notebook verifica seis propiedades formales:

- 1. Efecto direccional sobre el tamaño del conjunto de entrenamiento.** Las técnicas de oversampling puro (ROS, SMOTE, Jittering) deben producir estrictamente más ventanas que el baseline no balanceado, y las de undersampling puro (RUS, Tomek Links, `patient_aware_undersampling`) deben producir estrictamente menos o igual. Las técnicas híbridas deben conservar el tamaño original con una tolerancia de ± 1 ventana (debida al redondeo en el reparto equitativo). Esta propiedad se verifica contando las filas con `split == "train"` en cada archivo de salida.
- 2. Distribución demográfica post-balanceo más equitativa.** Para cada técnica y fold, se compara la entropía de Shannon de la distribución de grupos antes y después del balanceo. Se verifica que $H_{\text{post}} \geq H_{\text{pre}}$ para técnicas orientadas al balanceo, con excepción de Tomek Links (cuyo objetivo no es la equidad sino la limpieza de frontera).
- 3. Ausencia de solapamiento de pacientes entre train y val/test.** El identificador `patient_id` de las ventanas de entrenamiento no debe aparecer en las filas de validación o test dentro del mismo archivo de salida. Esta restricción es garantizada por diseño (Group K-Fold), pero el notebook la verifica explícitamente para cada fold y técnica.
- 4. Invarianza *bit a bit* de val y test entre condiciones.** Las filas con `split` $\in \{\text{val}, \text{test}\}$ deben ser idénticas (mismo conjunto de ventanas, mismo orden, mismos valores numéricos) en los diez archivos correspondientes a la misma combinación de (dataset, fold, dimensión demográfica). Se verifica computando el hash SHA-256 de la submatriz `val+test` para cada condición y comprobando que todos los hashes coinciden.
- 5. Plausibilidad fisiológica de puntos sintéticos.** Para SMOTE y Jittering, se verifica que todos los valores de las columnas `x0-x7` e `y` en las ventanas sintéticas se encuentran dentro del rango del sensor: $[v_{\min}, v_{\max}]$ según el dataset. La ausencia de violaciones confirma el correcto funcionamiento del clip aplicado en `clip_feature_columns`.
- 6. Consistencia *cross-técnica* de val y test.** Como extensión de la propiedad 4, se verifica que los conjuntos `val` y `test` son consistentes no solo dentro del mismo fold sino también entre folds distintos, es decir, que ningún fold comparte pacientes en los conjuntos de evaluación (verificación de la partición Group K-Fold). Esta comprobación cierra el circuito de validación y garantiza que las comparaciones estadísticas entre técnicas (Friedman, Nemenyi) se realizan sobre exactamente las mismas ventanas de evaluación en todos los casos.

Todas las verificaciones se superaron sin excepciones para los tres datasets y las diez técnicas, confirmando que el pipeline cumple las propiedades de corrección necesarias para que los resultados del experimento sean interpretables y comparables entre condiciones.

4.5. Transformación de datos: generación de ventanas deslizantes

La transformación de las series temporales CGM originales en el formato de entrada requerido por el modelo LSTM es un paso crítico del *pipeline*, ya que determina la granularidad de la unidad de balanceo y la forma en que se materializan las particiones de validación cruzada. Esta sección describe el proceso de generación de ventanas y sus parámetros.

4.5.1. Parámetros de ventana

Cada instancia del conjunto de datos se construye mediante una ventana deslizante de paso unitario (*one-step sliding window*) aplicada sobre la serie temporal de glucosa de cada paciente de forma independiente. La ventana queda definida por dos parámetros fijos:

- **Historia (*History Window*, HW):** 8 mediciones consecutivas, que constituyen las variables de entrada $x_0, x_1, \dots, x_7$.
- **Horizonte de predicción (*Prediction Horizon*, PH):** evaluado en cuatro configuraciones, $PH \in \{2, 4, 6, 8\}$ mediciones, correspondientes a 30, 60, 90 y 120 minutos en DiaTrend (intervalo de 15 min/muestra) o a 10, 20, 30 y 40 minutos en datasets con frecuencia de 5 min/muestra. La variable objetivo y es la medición situada exactamente PH pasos por delante del último punto del historial.

Dado el intervalo de muestreo de 15 minutos de DiaTrend, el horizonte principal de análisis $PH=4$ (60 min) se corresponde con el margen terapéutico clínicamente aceptado para que el paciente o el sistema de lazo cerrado pueda reaccionar ante un episodio de hipoglucemia o hiperglucemia inminente. A partir de cada ventana se almacenan, además de los valores glucémicos, la fecha (`x_date_7`) y la hora (`x_time_7`) correspondientes a la última medición del historial, lo que permite trazar cada instancia a su contexto temporal original sin necesidad de conservar la serie completa.

Formalmente, dada la serie de glucosa de un paciente $\mathbf{g} = (g_1, g_2, \dots, g_T)$, la i -ésima ventana se define como:

$$\mathbf{x}^{(i)} = (g_i, g_{i+1}, \dots, g_{i+HW-1}), \quad y^{(i)} = g_{i+HW-1+PH} \quad (4.10)$$

siendo válida únicamente si ninguno de los valores implicados es NaN.

4.5.2. Restricciones de continuidad temporal

Un requisito fundamental para la validez clínica de las instancias generadas es que todas las mediciones que componen la ventana —tanto el historial como el objetivo— pertenezcan a un segmento *continuo* de registro CGM. Cruzar un hueco de datos ausentes produciría una transición glucémica artificialmente abrupta que no existe en la fisiología del paciente: el modelo recibiría, por ejemplo, el valor g_i de una tarde y g_{i+1} de la mañana siguiente, como si fuesen mediciones consecutivas separadas 15 minutos, cuando en realidad media una noche entera de datos perdidos.

La restricción de continuidad se aplica de forma implícita gracias a la codificación de ausencias como NaN en la columna `Measurement` del conjunto preprocesado. Concretamente, la función `get_windows_one_step_walk_forward` genera primero *todas* las ventanas posibles mediante `numpy.lib.stride_tricks.sliding_window_view` y, a continuación, descarta aquellas que contienen al menos un NaN en el historial ($\mathbf{x}$) o en el objetivo (y):

$$\text{ventana válida} \iff \nexists j \in \{0, \dots, HW-1\} : x_j = \text{NaN} \quad \wedge \quad y \neq \text{NaN} \quad (4.11)$$

Este mecanismo garantiza que cualquier hueco en la serie —ya sea por pérdida de señal del sensor, fallo de calibración o ausencia de datos en el dataset original— invalida de forma automática todas las ventanas que lo atraviesan, sin necesidad de identificar explícitamente los límites de cada segmento continuo. Adicionalmente, para evitar que patrones glucémicos idénticos dentro de un mismo paciente inflen artificialmente el tamaño del conjunto e introduzcan fuga de información entre particiones de validación cruzada, se elimina la duplicación intra-paciente: dos instancias se consideran duplicadas si coinciden exactamente en todos sus valores $x_0 \dots x_7$ e y

(redondeados a un decimal) y en el identificador de paciente. Se conserva únicamente la primera ocurrencia.

4.5.3. Esquema de partición: *Group K-Fold* con $K = 5$

Para respetar la independencia entre pacientes a lo largo de todo el ciclo experimental, la validación cruzada sigue un esquema *Group K-Fold* con $K = 5$ folds: cada paciente se asigna *íntegramente* a exactamente uno de los cinco subconjuntos de test, de modo que ninguna ventana de un mismo paciente aparece simultáneamente en entrenamiento y evaluación dentro de un mismo fold. Esta decisión es crítica en dominios clínicos, donde la heterogeneidad inter-paciente puede provocar sobreoptimismo severo si se permite que el modelo “recuerde” fragmentos de la curva glucémica de un paciente durante el entrenamiento y los evalúe después en el mismo fold. La asignación de pacientes a folds sigue un algoritmo voraz balanceado en dos etapas, implementado en `make_folds_greedy_splits_valanced_priority`:

1. **Asignación al subconjunto de test.** Los pacientes se ordenan de mayor a menor número de ventanas. Se procesan en bloques de tamaño $K = 5$; dentro de cada bloque se permuta aleatoriamente y se asigna un paciente a cada fold, de forma que los pacientes con mayor carga se distribuyan uniformemente entre todos los folds. Los pacientes sobrantes (cuando el total no es múltiplo de K) se asignan al fold con menor carga acumulada.
2. **Asignación al subconjunto de entrenamiento y validación.** El resto de pacientes de cada fold (los no asignados a test) se procesan en bloques de tamaño 8: por cada bloque, 7 pacientes van a entrenamiento y 1 a validación. El último bloque incompleto envía siempre al menos 1 paciente a validación. Esto garantiza una proporción aproximada de 70 %-10 %-20 % (train-val-test) tanto en número de pacientes como en número de ventanas.

La asignación resultante se codifica directamente en el fichero Parquet de ventanas añadiendo cinco columnas categóricas `fold_0`, ..., `fold_4`, cada una con valores `'train'`, `'val'` o `'test'` según corresponda a cada instancia. Esta representación permite cargar un único fichero por horizonte de predicción y seleccionar la partición deseada con un simple filtro, sin necesidad de mantener ficheros separados por fold.

Un aspecto metodológico fundamental es que **los subconjuntos de validación y test son idénticos en todas las condiciones de balanceo experimentales**: el balanceo (sobremuestreo, submuestreo, técnicas híbridas H1–H5) se aplica *exclusivamente* sobre el subconjunto `'train'` de cada fold, dejando `'val'` y `'test'` inalterados. Esto garantiza que las métricas de evaluación entre condiciones son directamente comparables, ya que se obtienen siempre sobre exactamente el mismo conjunto de instancias reales no modificadas.

La integridad de los folds generados se verifica mediante la función `validate_folds`, que comprueba: (R1) exclusividad mutua entre train, val y test dentro de cada fold; (R2) que cada paciente aparece en el conjunto de test exactamente una vez en todo el esquema de K folds; (R3) que la unión de los tres subconjuntos cubre la totalidad del conjunto de pacientes; y (R4) que la carga de test entre folds no difiere en más de un 10 % respecto a la media, como indicador de balanceo.

4.6. Análisis exploratorio de ventanas

Una vez generadas las ventanas, se realizó un segundo análisis exploratorio centrado en las propiedades de la distribución de ventanas resultante, distinto del EDA sobre la señal CGM bruta descrito en la sección 4.2. Este análisis tiene como objetivo caracterizar el desequilibrio

demográfico a nivel de ventana —la unidad de balanceo efectiva del *pipeline*— y verificar que las propiedades de las ventanas son coherentes con las restricciones metodológicas.

4.6.1. Distribución de ventanas por grupo demográfico y *fold*

4.6.2. Distribución de la variable objetivo por grupo demográfico

4.6.3. Verificación de integridad de las particiones

4.7. Arquitectura del modelo LSTM

El modelo de predicción de glucosa utilizado en este trabajo es una red LSTM de una sola capa recurrente con una capa densa de salida lineal. La elección de esta arquitectura está motivada por su consolidación en la literatura de predicción de glucosa (véase capítulo 2.3.4) y por el objetivo de este trabajo, que no es optimizar la arquitectura del modelo sino cuantificar el efecto del balanceo del conjunto de entrenamiento sobre un modelo de referencia bien establecido.

4.7.1. Especificación de la arquitectura

La arquitectura implementada en TensorFlow/Keras consta de tres capas: una capa de entrada, una capa LSTM y una capa densa de salida. La capa de entrada acepta secuencias de forma (8, 1), es decir, ocho pasos temporales consecutivos de 15 minutos cada uno (ventana de 120 minutos de historia glucémica), con una única característica por paso (la medición de glucosa en mg/dL). Sobre esta entrada opera una capa LSTM de 128 unidades ocultas con *dropout* de entrada de 0,1 y sin *recurrent dropout* (valor 0,0). Por último, la capa densa de salida está compuesta por una única neurona con función de activación lineal (**None**), lo que permite predecir directamente el valor continuo de glucosa en mg/dL.

La tabla 4.5 resume los hiperparámetros principales del modelo, y el total de parámetros entrenables asciende a 67 073¹.

Tabla 4.5: Hiperparámetros del modelo LSTM.

Hiperparámetro	Valor
Longitud de la secuencia de entrada	8 pasos (120 min)
Características por paso	1 (glucosa en mg/dL)
Unidades ocultas LSTM	128
Dropout de entrada	0,1
Recurrent dropout	0,0
Capa de salida	Dense(1), activación lineal
Parámetros entrenables totales	67 073
Framework	TensorFlow/Keras

4.7.2. Función de pérdida y optimizador

El modelo se compila con la función de pérdida RMSE (*Root Mean Squared Error*) implementada como función personalizada en TensorFlow:

$$\text{RMSE}(y, \hat{y}) = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2} \quad (4.12)$$

¹ $(4 \times 128 \times (1 + 128) + 4 \times 128) + (128 + 1) = 66\,560 + 513 = 67\,073$.

La elección del RMSE como función de pérdida responde a la misma motivación que justifica su uso como métrica primaria de evaluación: la penalización cuadrática de los errores más grandes, que en el contexto de la predicción de glucosa tienden a coincidir con los episodios clínicamente más graves —hipoglucemia severa e hiperglucemia marcada—. A diferencia del MAE, que pondera todos los errores por igual, el RMSE penaliza de forma creciente las desviaciones de mayor magnitud, lo que es coherente con el riesgo clínico asimétrico asociado a los valores extremos de glucemia.

Como optimizador se emplea Adam con los valores por defecto de Keras ($\alpha = 0,001$, $\beta_1 = 0,9$, $\beta_2 = 0,999$, $\varepsilon = 10^{-7}$), que combina el ajuste adaptativo del paso de aprendizaje por parámetro con el impulso de primer y segundo orden, mostrando una convergencia robusta en la mayoría de escenarios de aprendizaje profundo.

Durante el entrenamiento se monitorizan métricas adicionales sin influir en la optimización: el `RootMeanSquaredError` de Keras y la `ClinicalPenaltyMetric`, implementación como subclase de `tf.keras.losses.Loss` de la penalización clínica de Del Favero *et al.* [?]. Esta segunda métrica permite observar en tiempo de entrenamiento si el modelo mejora no solo en error absoluto sino también en el criterio clínico específico para glucosa.

4.7.3. Estrategia de entrenamiento

El entrenamiento se lleva a cabo con un *batch size* de 4096 muestras, un máximo de 500 épocas y un mecanismo de parada temprana (*early stopping*) con `patience = 10` épocas monitorizando la pérdida de validación (`val_loss`), restaurando los mejores pesos al finalizar (`restore_best_weights=True`).

El valor de *batch size* de 4096 se selecciona en función del tamaño típico de los conjuntos de entrenamiento en este estudio, que oscilan entre miles y varias decenas de miles de ventanas por *fold*. Un *mini-batch* de este tamaño garantiza gradientes suficientemente representativos de la distribución real de los datos en cada actualización, reduce la varianza del gradiente estocástico y permite explotar eficientemente el paralelismo de la GPU del servidor. Al mismo tiempo, es lo bastante pequeño para que el número de actualizaciones de pesos por época sea significativo incluso en los conjuntos de mayor tamaño (generados por técnicas de *oversampling*).

Para garantizar la reproducibilidad, se fijan las semillas aleatorias de NumPy, TensorFlow y el módulo `random` de Python al valor 50, y se activa la operación determinista de TensorFlow mediante la variable de entorno `TF_DETERMINISTIC_OPS=1`. Las semillas se reestablecen antes de cada experimento, de modo que cada condición experimental arranque desde el mismo estado del generador aleatorio.

Se emplean cuatro *callbacks* de Keras: `ModelCheckpoint` (guarda los mejores pesos en formato `.weights.h5`), `EarlyStopping` (detiene el entrenamiento si `val_loss` no mejora durante 10 épocas consecutivas), `TensorBoard` (registro de curvas de pérdida por época) y `CSVLogger` (histórico de métricas por época en formato `.csv`). Gracias a `restore_best_weights=True` en `EarlyStopping`, los pesos utilizados en la fase de predicción corresponden siempre al punto de mínima pérdida de validación, independientemente de en qué época se detuvo el entrenamiento.

4.7.4. Configuración del entorno de ejecución

Los experimentos se ejecutan en un servidor Linux. La información de hardware y software se registra automáticamente al inicio de cada experimento mediante la función `print_system_info()`, que consulta el `hostname`, la versión de Python, la versión de TensorFlow y los dispositivos GPU disponibles a través de `nvidia-smi`.

Los artefactos de cada experimento se organizan en una estructura de directorios que mapea biunívocamente cada directorio a una condición experimental completa:

```

/data/output/{DATASET}/{balancing_condition}/
  EXP-{fecha}-prediction-RMSE-LSTM-H8-PH4-{condition}-v{N}/
    models/
    plots/training/
    results/predictions/
    results/evaluation/metrics/
    results/evaluation/figures/
    summaries/
    readmes/

```

El sufijo `-v{N}` garantiza que la ejecución de un mismo experimento nunca sobrescribe resultados anteriores, permitiendo el versionado incremental.

El número total de entrenamientos ejecutados se obtiene del diseño experimental: $3 \text{ datasets} \times (10 \text{ técnicas de balanceo} \times 2 \text{ dimensiones de balanceo} + 1 \text{ condición original}) \times 5 \text{ folds} = 3 \times 21 \times 5 = 315$ entrenamientos. Sin embargo, la condición de balanceo por sobremuestreo según edad en el *dataset* T1DGranada no está disponible, por lo que el número final de entrenamientos ejecutados asciende a **310**.

4.8. *Pipeline* de entrenamiento y evaluación

Esta sección describe el *pipeline* completo de entrenamiento y evaluación, integrando todos los componentes descritos en las secciones anteriores. Se detalla el flujo de datos desde los archivos *parquet* de entrada hasta los archivos de métricas que alimentan el análisis estadístico del capítulo 5.

4.8.1. Modo original y modo balanceado

El script de entrenamiento (`3-train.py`) opera en dos modos según la naturaleza del archivo de entrada, gestionados por la clase `ExperimentTarget`:

Modo original. Se lee un único archivo *parquet* que contiene todas las ventanas del *dataset* con cinco columnas adicionales `fold_0 ... fold_4`. Para cada *fold* i , el script filtra las filas cuya columna `fold_i` toma el valor `'train'`, `'val'` o `'test'`, obteniendo así las particiones correspondientes. Los datos de validación y test son idénticos entre la condición original y cualquier condición balanceada, ya que el balanceo solo afecta al conjunto de entrenamiento.

Modo balanceado. Se leen cinco archivos *parquet* independientes, uno por *fold*, generados por el script de balanceo (`2b-trainset_balancing.py`). Cada archivo ya contiene una columna `'split'` con los valores `'train'`, `'val'` y `'test'`, donde el subconjunto de entrenamiento ha sido transformado por la técnica de balanceo correspondiente.

Esta separación de responsabilidades —balanceo en un script dedicado, entrenamiento en otro— mejora la reproducibilidad y la trazabilidad: el *parquet* balanceado es un artefacto intermedio verificable, independiente del proceso de entrenamiento. Cualquier auditoría puede comprobar el estado exacto del conjunto de entrenamiento sin necesidad de re-ejecutar el balanceo. Además, permite lanzar múltiples condiciones de entrenamiento en paralelo sobre los mismos archivos de entrada sin riesgo de condiciones de carrera.

4.8.2. Flujo de datos por *fold*

El proceso de entrenamiento y evaluación sigue los mismos pasos para cada uno de los cinco *folds* de validación cruzada, con independencia del modo de operación:

1. **Carga del *parquet*.** En modo original se carga el único archivo de ventanas y se filtran las filas correspondientes al *fold i* mediante la columna `fold_i`. En modo balanceado se carga directamente el archivo del *fold i*, que ya contiene la columna `'split'` con el balanceo materializado.
2. **Separación en train / val / test.** Las ventanas se dividen en tres subconjuntos según el valor de la columna de asignación (`fold_i` o `'split'`). Las columnas informativas (`patient_id`, `x_time_7`, `x_date_7`) se preservan para el conjunto de test, permitiendo la posterior desagregación por rango glucémico y paciente.
3. **Clip de valores a los límites del sensor.** Cada *dataset* tiene límites de lectura del sensor (*clipping range*) propios: DiaTrend y REPLACE-BG emplean el rango [39, 401] mg/dL, mientras que T1DGranada emplea [40, 500] mg/dL. Los valores de las columnas de entrada (`x0 ... x7`) y de la columna objetivo (`y`) se recortan a este rango antes de cualquier procesamiento.
4. **Reshape de la entrada.** Los arrays de NumPy extraídos del *DataFrame* se reconfiguran de la forma `(n_samples, 8)` a `(n_samples, 8, 1)` para satisfacer la convención de entrada de la LSTM en Keras: (muestras, pasos temporales, características).
5. **Entrenamiento con parada temprana.** La LSTM se entrena con los parámetros descritos en la sección 4.7.3. El *callback* `ModelCheckpoint` guarda los pesos del modelo en el punto de mínima pérdida de validación; `EarlyStopping` detiene el entrenamiento si esta no mejora durante 10 épocas consecutivas.
6. **Generación de predicciones sobre test.** Una vez concluido el entrenamiento, se cargan los mejores pesos guardados en disco (`.weights.h5`) sobre una nueva instancia del modelo para evitar efectos residuales del estado interno. El modelo produce predicciones sobre el conjunto de test reconfigurado a `(n_test, 8, 1)`.
7. **Evaluación por rango glucémico.** Las predicciones y los valores reales se concatenan en un *DataFrame* junto con la información de paciente y marca temporal. La función `test_by_range()` calcula métricas de rendimiento (RMSE, MAE, MAPE, MSE) y distribución en las zonas del *Clarke Error Grid* (A, B, C, D, E, A+B) de forma desagregada para cada rango glucémico definido clínicamente (TBR-2, TBR-1, TIR, TAR-1, TAR-2, ENTIRE), descrito en detalle en la sección 4.8.3.
8. **Guardado de artefactos.** Se persisten en disco: los pesos del modelo (`.weights.h5`), el histórico de entrenamiento por época (`_history.csv`), las predicciones sobre test (`.parquet`), un resumen JSON del *fold* (`summary_*.json`) con metadatos completos, y un archivo Markdown de documentación (`README_*.md`).

Tras completar los cinco *folds*, el pipeline aplica el protocolo *Metric-Then-Aggregate* (MTA): calcula las métricas por rango en cada *fold* de forma independiente y luego agrega los resultados mediante media y desviación estándar. Adicionalmente, aplica el protocolo complementario *Aggregate-Then-Metric* (ATM): concatena todas las predicciones y calcula las métricas sobre el conjunto completo, lo que sirve como referencia para detectar posibles sesgos por desbalanceo entre *folds*.

4.8.3. Evaluación por rango glucémico

La evaluación del rendimiento del modelo se realiza de forma desagregada por rango glucémico, en lugar de calcularse exclusivamente sobre el rango completo de mediciones. Esta decisión metodológica responde a la naturaleza clínica del problema: el riesgo asociado a un error de predicción no es uniforme a lo largo del espectro glucémico, sino que presenta una fuerte dependencia del valor absoluto de glucosa en que se produce dicho error.

Los rangos empleados siguen la nomenclatura estándar del *Time in Range* (TIR) propuesta por el consenso internacional [?]:

Tabla 4.6: Rangos glucémicos para la evaluación desagregada del rendimiento.

Rango	Umbral (mg/dL)	Descripción clínica
TBR-2	< 54	Hipoglucemia grave
TBR-1	54–69	Hipoglucemia clínicamente significativa
TIR	70–180	Rango objetivo (<i>time in range</i>)
TAR-1	181–250	Hiperoglucemia moderada
TAR-2	> 250	Hiperoglucemia severa
ENTIRE	Rango completo	Evaluación global

La evaluación desagregada por rango es esencial por una razón fundamental: el balanceo demográfico del conjunto de entrenamiento puede mejorar el rendimiento del modelo en determinados rangos a costa de degradarlo en otros. Esta dinámica de compensación no sería detectable si solo se dispusiera de una métrica global como el RMSE sobre el conjunto de test completo. Por ejemplo, una técnica de balanceo que mejore la representación de pacientes con hipoglucemia frecuente podría reducir el error en TBR-2 mientras incrementa ligeramente el error en TIR, donde se concentra la mayoría de las predicciones. Una métrica global ponderaría este intercambio de forma proporcional al número de muestras en cada rango, enmascarando mejoras clínicamente relevantes en los rangos más peligrosos pero menos frecuentes.

Para cada rango y cada *fold*, la función `test_by_range()` selecciona únicamente las muestras cuyo valor real (`y_test`) cae dentro del rango correspondiente y calcula sobre ellas el conjunto completo de métricas: RMSE, MAE, MAPE, MSE y distribución de puntos en las zonas A, B, C, D y E del *Clarke Error Grid* (CEG), así como el porcentaje de predicciones en las zonas clínicamente aceptables A+B. El número de muestras por rango se registra en un archivo CSV separado, lo que permite ponderar adecuadamente los resultados durante el análisis estadístico posterior.

4.8.4. Agregación de resultados y protocolo estadístico

Los resultados de los cinco *folds* de cada condición experimental se agregan siguiendo el protocolo *Metric-Then-Aggregate* (MTA): para cada combinación de (rango glucémico, métrica), se calcula la media y la desviación estándar de los cinco valores obtenidos en los *folds* individuales. Esta estrategia es preferible a la alternativa *Aggregate-Then-Metric* (ATM) —que concatena todas las predicciones antes de calcular métricas— porque proporciona una estimación de la variabilidad inter-*fold* del rendimiento, un indicador de la estabilidad del modelo frente a distintas particiones de pacientes.

Los archivos CSV de salida que alimentan el sistema de análisis estadístico presentan una estructura tabular con las columnas: **Range** (rango glucémico), **Metric** (nombre de la métrica), **Value** (valor numérico) y **Fold** (índice del *fold*), junto con información del experimento (*dataset*, condición de balanceo). El archivo plano (`mta_flat.csv`) contiene una fila por cada combinación

(*fold*, rango, métrica), mientras que el archivo de reporte (`mta_report.csv`) contiene la media y la desviación estándar agregadas.

El análisis estadístico comparativo entre condiciones experimentales —descrito en detalle en el capítulo 5— emplea los tests de Friedman y Nemenyi para comparaciones múltiples no paramétricas, el tamaño del efecto de Cohen (d) para cuantificar la magnitud de las diferencias, y el método de Borda para obtener un ranking global de condiciones de balanceo por rango glucémico.

4.8.5. Trazabilidad y reproducibilidad

El diseño del *pipeline* incorpora un conjunto de medidas que garantizan la reproducibilidad completa de los resultados y la trazabilidad de cada experimento:

Semillas fijas. Las semillas de los generadores aleatorios de NumPy, TensorFlow y el módulo `random` de Python se fijan al valor 50 antes de cada experimento (`np.random.seed(50)`, `tf.random.set_seed(50)`, `random.seed(50)`). La variable de entorno `TF_DETERMINISTIC_OPS=1` desactiva las operaciones no deterministas de TensorFlow en GPU, asegurando la reproducibilidad bit a bit de los resultados.

Versionado de experimentos. El directorio de salida de cada experimento recibe un sufijo `-v{N}` (`v1`, `v2`, ...) que se incrementa automáticamente, evitando la sobrescritura accidental de resultados previos.

Metadatos completos por *fold*. Cada *fold* genera un archivo JSON de resumen (`summary_*.json`) que registra: parámetros del experimento, condición de balanceo, límites del sensor, rutas a todos los artefactos generados, tiempos de entrenamiento y predicción, versión de Python, versión de TensorFlow, *commit* de Git, rama y URL del repositorio remoto, hostname del servidor y *timestamp* de ejecución. Esta información es suficiente para reproducir cualquier experimento de forma independiente.

Invarianza de validación y test. Los subconjuntos de validación y test son idénticos entre todas las condiciones experimentales de un mismo *dataset*, ya que el balanceo solo modifica el conjunto de entrenamiento. Esta propiedad fue verificada mediante un *notebook* de validación que comprueba la igualdad byte a byte de los identificadores de paciente y ventanas de val y test entre el modo original y cada condición balanceada.

Estructura de directorios autoexplicativa. La jerarquía `/data/output/{DATASET}/{balancing_cond}` mapea biunívocamente cada directorio a una condición experimental completa (*dataset*, técnica de balanceo, dimensión demográfica), eliminando la ambigüedad en la interpretación de los resultados.

Capítulo 5

Resultados y discusión

Aquí se discutirán los resultados, tablas de datos y gráficas.

Por ejemplo, la Tabla 5.1, muestra un ejemplo de como introducir tablas de forma limpia en el texto.

Tabla 5.1: Mi tabla grande con cabeceras en negrita

Categoría	Valor 1	Valor 2	Valor 3
Fruta 1	5	10	15
Fruta 2	8	12	18
Verdura 1	3	6	9
Verdura 2	4	7	11
Bebida 1	1	2	3
Bebida 2	6	9	12

Fíjate que tanto tablas como imágenes, deben estar previamente referenciadas en el texto, y no deben separarse mucho de éste. Fíjate también en como se crean títulos reducidos para que el texto del pie de tabla no ocupe demasiado en el índice.

Las tablas enormes como la Tabla 5.2, deben intentar colocarse en una página aparte.

Lo mismo se puede hacer con las gráficas. Pero ten cuidado de que las gráficas no se vayan lejos del texto tampoco. Vamos a poner un ejemplo para que no nos moleste la tabla anterior, vamos a forzar una nueva página.

Tabla 5.2: Mfi tabla enorme de poblaci3n

Categoría	Valor 1	Valor 2	Valor 3	Valor 4	Valor 5	Valor 6	Valor 7	Valor 8	Valor 9	Valor 10
Ecuador	5	10	15	20	25	30	35	40	45	
Nicaragua	8	12	18	24	30	36	42	48	54	
Honduras	3	6	9	12	15	18	21	24	27	
Argentina	4	7	11	15	19	23	27	31	35	
Venezuela	1	2	3	4	5	6	7	8	9	
Colombia	6	9	12	15	18	21	24	27	30	
Chile	2	4	6	8	10	12	14	16	18	
España	7	11	15	19	23	27	31	35	39	

Se deben evitar imágenes “por poner”¹, como la Figura 5.1. Que es un logotipo.



Figura 5.1: Mi logo

Por ejemplo, la Figura 5.2 sí que está correcta, y va de la misma forma que la tabla, y ahora está cerca del texto. Hemos sacrificado un poco de espacio al final de la página anterior a cambio de acercar la figura al texto. Esto solo debe hacerse en casos en que tengamos tablas y figuras que ocupen la página completa.

El tipo de extensiones ya está definido, así que no deben usarse a la hora de referenciar imágenes. Por defecto el orden es:

1. PDF: Son gráficos vectoriales con máxima calidad, bueno para esquemas y tablas.
2. PNG: Son gráficos que no pierden calidad, aunque son gráficos *raster* o matriciales. Utilízalos cuando los tonos sean planos, como en esquemas, en sustitución de los PDF cuando no tenemos opción a usar gráficos vectoriales.
3. JPEG: Con extensión **.jpg**, se suelen usar cuando son fotografías, principalmente, ya que pueden contener *artifacts*.

¹Por cierto, fíjate en cómo van las comillas. Aunque es mejor usar cursivas. Las palabras en inglés, por ejemplo, deberían ir en *cursiva*, como por ejemplo *buffer*.




Figura 5.2: Lista de distribuciones: Aquí iría una descripción de la figura para cada fila o columna, explicando los parámetros. Fíjate como el pie está recortado en el índice para que no sea extremadamente largo. Si hay una fuente, la podemos colocar aquí: <https://drive.google.com/file/d/14YN87TAF60Qq6JIuZiUz3YHn-6Pz8KHm/view?usp=sharing>

Capítulo 6

Conclusiones

Debes describir las conclusiones generales del trabajo, pero también debes cubrir qué objetivos se han cubierto. Para ello revisa la sección de [Objetivos](#) (Sección 1.2). Por último cierra el trabajo, y si tienes planes de continuar, menciona los trabajos futuros.

Bibliografía

- [1] M. A. Atkinson, G. S. Eisenbarth, and A. W. Michels, “Type 1 diabetes,” *The Lancet*, vol. 383, no. 9911, pp. 69–82, 2014.
- [2] J. Divers, E. J. Mayer-Davis, J. M. Lawrence, S. Isom, D. Dabelea, L. Dolan, G. Imperatore, S. Marcovina, D. J. Pettitt, C. Pihoker, R. F. Hamman, S. Saydah, and L. E. Wagenknecht, “Trends in incidence of type 1 and type 2 diabetes among youths — selected counties and indian reservations, united states, 2002–2015,” *MMWR. Morbidity and Mortality Weekly Report*, vol. 69, no. 6, pp. 161–165, 2020.
- [3] Sociedad Española de Diabetes, “Informe sobre la prevalencia e incidencia de la diabetes en españa.” <https://www.sediabetes.org>, 2023. Accedido en 2025.
- [4] B. Kovatchev, “Metrics for glycaemic control — from HbA1c to continuous glucose monitoring,” *Nature Reviews Endocrinology*, vol. 13, no. 7, pp. 425–436, 2019.
- [5] M. Brownlee, “The pathobiology of diabetic complications: A unifying mechanism,” *Diabetes*, vol. 54, no. 6, pp. 1615–1625, 2005.
- [6] D. C. Klonoff, D. Ahn, and A. Drincic, “Continuous glucose monitoring: a review of the technology and clinical use,” *Diabetes Research and Clinical Practice*, vol. 133, pp. 178–192, 2017.
- [7] K. Rebrin, G. M. Steil, W. P. van Antwerp, and J. J. Mastrototaro, “Subcutaneous glucose predicts plasma glucose independent of insulin: Implications for continuous monitoring,” *American Journal of Physiology — Endocrinology and Metabolism*, vol. 277, no. 3, pp. E561–E571, 2000.
- [8] T. Battelino, T. Danne, R. M. Bergenstal, *et al.*, “Clinical targets for continuous glucose monitoring data interpretation: recommendations from the international consensus on time in range,” *Diabetes Care*, vol. 42, no. 8, pp. 1593–1603, 2019.
- [9] W. L. Clarke, D. Cox, L. A. Gonder-Frederick, W. Carter, and S. L. Pohl, “Evaluating clinical accuracy of systems for self-monitoring of blood glucose,” *Diabetes Care*, vol. 10, no. 5, pp. 622–628, 1987.
- [10] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, “Learning representations by back-propagating errors,” *Nature*, vol. 323, no. 6088, pp. 533–536, 1986.
- [11] Y. Bengio, P. Simard, and P. Frasconi, “Learning long-term dependencies with gradient descent is difficult,” *IEEE Transactions on Neural Networks*, vol. 5, no. 2, pp. 157–166, 1994.
- [12] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

- [13] G. Sparacino, F. Zanderigo, S. Corazza, *et al.*, “Glucose concentration can be predicted ahead in time from continuous glucose monitoring sensor time-series,” *IEEE Transactions on Biomedical Engineering*, vol. 54, no. 5, pp. 931–937, 2007.
- [14] scikit-learn developers, “GroupKFold — scikit-learn 1.4 documentation.” https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupKFold.html, 2024. Accedido en 2025.
- [15] H. He and E. A. Garcia, “Learning from imbalanced data,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, no. 9, pp. 1263–1284, 2009.
- [16] P. Branco, L. Torgo, and R. P. Ribeiro, “A survey of predictive modelling under imbalanced distributions,” *ACM Computing Surveys*, vol. 49, no. 2, pp. 31:1–31:50, 2016.
- [17] A. Fernández, S. García, M. Galar, R. C. Prati, B. Krawczyk, and F. Herrera, *Learning from Imbalanced Data Sets*. Springer, 2018.
- [18] I. Tomek, “Two modifications of CNN,” *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 6, no. 11, pp. 769–772, 1976.
- [19] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, “Smote: Synthetic minority over-sampling technique,” *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
- [20] G. E. A. P. A. Batista, R. C. Prati, and M. C. Monard, “A study of the behavior of several methods for balancing machine learning training data,” *ACM SIGKDD Explorations Newsletter*, vol. 6, no. 1, pp. 20–29, 2004.
- [21] R. N. Bergman, Y. Z. Ider, C. R. Bowden, and C. Cobelli, “Quantitative estimation of insulin sensitivity,” *American Journal of Physiology-Endocrinology and Metabolism*, vol. 236, no. 6, pp. E667–E677, 1979.
- [22] J. Contreras, R. Espínola, F. J. Nogales, and A. J. Conejo, “ARIMA models to predict next-day electricity prices,” *IEEE Transactions on Power Systems*, vol. 18, no. 3, pp. 1014–1020, 2003. Referencia metodológica seminal para modelos ARIMA en series temporales. Para aplicación específica a glucosa, véase también Sparacino *et al.* (2007).
- [23] J. Reifman, S. Rajaraman, A. Gribok, and W. K. Ward, “Predictive monitoring for improved management of glucose levels,” *Journal of Diabetes Science and Technology*, vol. 1, no. 4, pp. 478–486, 2007.
- [24] S. M. Pappada, B. D. Cameron, P. M. Rosman, and T. J. Papadimos, “Development of a neural network for prediction of glucose concentration in type 1 diabetes patients,” *Journal of Diabetes Science and Technology*, vol. 2, no. 5, pp. 792–801, 2008.
- [25] M. Fraccaro, D. Bhatt, U. Bhatt, and M. Welling, “Prediction of blood glucose concentration in type 1 diabetes using kernel adaptive filtering,” in *Proceedings of the NIPS 2016 Workshop on Machine Learning for Health*, 2016. Disponible en: <https://arxiv.org/abs/1612.00901>.
- [26] K. Li, C. Liu, T. Zhu, P. Herrero, and P. Georgiou, “Glunet: a deep learning framework for accurate glucose forecasting,” *IEEE Journal of Biomedical and Health Informatics*, vol. 24, no. 2, pp. 414–423, 2019.

- [27] S. Mirshekarian, H. Shen, R. Bunescu, and C. Marling, “Lstms and neural attention models for blood glucose prediction: comparative experiments on real and synthetic data,” 2019.
- [28] V. Naumova, S. V. Pereverzyev, and S. Sivananthan, “A meta-learning approach to the regularized learning—case study: Blood glucose prediction,” *Neural Networks*, vol. 33, pp. 181–193, 2012.
- [29] Z. Li, S. Vyas, I. Kang, J. Wu, and A. E. Solomonides, “GluCTx: Glucose prediction leveraging transformer architecture with contextual data,” *arXiv preprint*, 2023. arXiv:2311.01232. Disponible en: <https://arxiv.org/abs/2311.01232>.
- [30] S. Oviedo, J. Vehí, R. Calm, and J. Armengol, “A review of personalized blood glucose prediction strategies for T1DM patients,” *International Journal for Numerical Methods in Biomedical Engineering*, vol. 33, no. 6, 2017.
- [31] C. D. Man, F. Micheletto, D. Lv, M. Breton, B. Kovatchev, and C. Cobelli, “The UVA/PADOVA type 1 diabetes simulator: New features,” *Journal of Diabetes Science and Technology*, vol. 8, no. 1, pp. 26–34, 2014.
- [32] C. Marling and R. Bunescu, “The OhioT1DM dataset for blood glucose level prediction: update 2020,” 2020.
- [33] F. Dubosson, J.-E. Ranvier, S. Bromuri, *et al.*, “The open D1NAMO dataset: a multi-modal dataset for research on non-invasive type 1 diabetes management,” *Informatics in Medicine Unlocked*, vol. 13, pp. 92–100, 2018.
- [34] G. Aleppo, K. L. Ruedy, T. T. Riddlesworth, *et al.*, “REPLACE-BG: A randomized trial comparing continuous glucose monitoring with and without routine blood glucose monitoring in adults with well-controlled type 1 diabetes,” *Diabetes Care*, vol. 40, no. 4, pp. 538–545, 2017.
- [35] Q. Sun, T. S. Bhatt, R. Nambhore, *et al.*, “DIATREND: A multivariate longitudinal clinical dataset of type 1 diabetes patients to advance glucose forecasting,” *Scientific Data*, vol. 10, no. 1, p. 612, 2023.
- [36] J. D. Díaz-López, R. Capel-Delgado, *et al.*, “T1diabetesgranada dataset,” 2023.
- [37] F. Mauvais-Jarvis *et al.*, “Sex differences in glucose homeostasis,” *Sex and Gender Effects in Pharmacology, Handbook of Experimental Pharmacology*, 2023.
- [38] M. Conti, I. Gironi, E. Meneghini, E. Mion, G. D. Vieste, F. Bertuzzi, and B. Pintaudi, “Sex differences in continuous glucose monitoring metrics and glucose variability in subjects with type 1 diabetes treated with advanced hybrid closed loop therapy: An observational, retrospective, one-year follow-up study,” *Journal of Clinical Medicine*, vol. 14, no. 24, p. 8823, 2025.
- [39] A. A. van der Heijden *et al.*, “Sex-based disparities in perceived versus objective glycaemic control in type 1 diabetes: a cross-sectional cohort study,” *The Lancet Diabetes & Endocrinology*, 2025. PIIS2213-8587(25)00136-6.
- [40] F. Deng *et al.*, “Deterioration in glycemic control on schooldays among children and adolescents with type 1 diabetes: a continuous glucose monitoring-based study,” *PMC9768037*, 2022.

- [41] M. Nwokolo *et al.*, “Glycaemic outcomes in people living with diabetes under 65 and over 65 years old using an intermittently scanned continuous glucose monitoring system,” *Journal of Diabetes Science and Technology*, 2024. PMC11337186.
- [42] I. Straw and H. Wu, “Investigating for bias in healthcare algorithms: a sex-stratified analysis of supervised machine learning models in liver disease prediction,” *BMJ Health & Care Informatics*, vol. 29, no. 1, 2022.
- [43] M. A. R. Lara *et al.*, “Sociodemographic bias in clinical machine learning models: a scoping review of algorithmic bias instances and mechanisms,” *Journal of Clinical Epidemiology*, 2024.
- [44] Y. Wang *et al.*, “Disparate model performance and stability in machine learning clinical support for diabetes and heart diseases,” 2024. arXiv:2412.19495.
- [45] C. Yan *et al.*, “Subpopulation-specific machine learning prognosis for underrepresented patients with double prioritized bias correction,” *Communications Medicine*, vol. 2, p. 121, 2022.
- [46] A. O. Aguilar *et al.*, “Racial disparities in continuous glucose monitoring-based 60-min glucose predictions among people with type 1 diabetes,” *medRxiv preprint*, 2024.
- [47] F. Kamiran and T. Calders, “Data preprocessing techniques for classification without discrimination,” *Knowledge and Information Systems*, vol. 33, no. 1, pp. 1–33, 2012.
- [48] I. Žliobaitė, “Measuring discrimination in algorithmic decision making,” *Data Mining and Knowledge Discovery*, vol. 31, no. 4, pp. 1060–1089, 2017.
- [49] J. Wiśniewski and P. Biecek, “fairmodels: A flexible tool for bias detection, visualization, and mitigation,” 2021. arXiv:2104.00507.
- [50] R. K. E. Bellamy *et al.*, “Ai fairness 360: An extensible toolkit for detecting, understanding, and mitigating unwanted algorithmic bias,” 2018. arXiv:1810.01943.
- [51] E. Krasanakis, E. Spyromitros-Xioufis, S. Papadopoulos, and Y. Kompatsiaris, “Adaptive sensitive reweighting to mitigate bias in fairness-aware classification,” in *Proceedings of the 2018 World Wide Web Conference (WWW)*, 2018.
- [52] M. A. Ahmad *et al.*, “Algorithm fairness in ai for medicine and healthcare,” 2021. arXiv:2110.00603.
- [53] C. Chu, S. Donato-Woodger, S. S. Khan, T. Shi, K. Leslie, S. Abbasgholizadeh-Rahimi, R. Nystrup, and A. Grenier, “Strategies to mitigate age-related bias in machine learning: Scoping review,” *JMIR Aging*, vol. 7, p. e53564, 2024.
- [54] J. Yoon, D. Jarrett, and M. van der Schaar, “Time-series generative adversarial networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.
- [55] H. Dong *et al.*, “Ts-gan: Time-series gan for sensor-based health data augmentation,” *ACM Transactions on Computing for Healthcare*, 2023.
- [56] J. Dahmen *et al.*, “A conditional gan for generating time series data for stress detection in wearable physiological sensor data,” *Sensors*, vol. 22, no. 16, p. 5969, 2022.
- [57] C. Louizos, K. Swersky, Y. Li, M. Welling, and R. Zemel, “The variational fair autoencoder,” in *International Conference on Learning Representations (ICLR)*, 2016.

- [58] H. Edwards and A. Storkey, “Censoring representations with an adversary,” in *International Conference on Learning Representations (ICLR)*, 2016.
- [59] R. Zemel, Y. Wu, K. Swersky, T. Pitassi, and C. Dwork, “Learning fair representations,” in *Proceedings of the 30th International Conference on Machine Learning (ICML)*, 2013.
- [60] J. Yang *et al.*, “Dataset representativeness and downstream task fairness,” 2024. arXiv:2407.00170.
- [61] D. Machado, V. Santos Costa, and P. Brandão, “Using balancing methods to improve glycaemia-based data mining,” in *Proceedings of the 16th International Joint Conference on Biomedical Engineering Systems and Technologies (BIOSTEC 2023), Volume 5: HEALTHINF*, pp. 188–198, 2023.
- [62] H. B. Thomsen, L. Y. Li, A. A. Isaksen, B. Lebiecka-Johansen, C. Bour, G. Fagherazzi, W. P. T. M. van Doorn, T. V. Varga, and A. Hulman, “Racial disparities in continuous glucose monitoring-based 60-min glucose predictions among people with type 1 diabetes,” *PLOS Digital Health*, vol. 4, no. 6, p. e0000918, 2025.
- [63] Y. Tashiro, J. Song, Y. Song, and S. Ermon, “CSDI: Conditional score-based diffusion models for probabilistic time series imputation,” in *Advances in Neural Information Processing Systems (NeurIPS 2021)*, vol. 34, pp. 24804–24816, 2021. Disponible en: <https://arxiv.org/abs/2107.03502>.
- [64] A. Bing *et al.*, “Healthgen: Equitable synthetic ehr generation,” *PMC*, 2022.
- [65] A. Alemán Granados, “Demographic bias in blood glucose prediction: Evaluating sex and age effects in type 1 diabetes forecasting,” trabajo de fin de grado, Universidad de Granada, 2025. Proyecto RELIEF-T1D, Hospital Universitario Virgen de las Nieves.
- [66] G. Aleppo, K. J. Ruedy, T. D. Riddlesworth, D. F. Kruger, A. L. Peters, I. Hirsch, R. M. Bergenstal, A. Bhargava, R. Rich-Haigh, R. Pop-Busui, W. H. Polonsky, L. Y. Yeoh, and R. W. Beck, “REPLACE-BG: A randomized trial comparing continuous glucose monitoring with and without routine blood glucose monitoring in adults with well-controlled type 1 diabetes,” *Diabetes Care*, vol. 40, no. 4, pp. 538–545, 2017.
- [67] Q. Sun, M. V. Jankovic, L. Bally, and S. Mougiakakou, “DiaTrend: A dataset to advance deep learning research for glucose forecasting in type 1 diabetes,” *Scientific Data*, vol. 10, no. 1, p. 150, 2023.
- [68] H. I. Fawaz, G. Forestier, J. Weber, L. Idoumghar, and P.-A. Muller, “Data augmentation using synthetic data for time series classification with deep residual networks,” in *ECML/PKDD Workshop on Advanced Analytics and Learning on Temporal Data*, 2018.
- [69] H. He, Y. Bai, E. A. Garcia, and S. Li, “Adasyn: Adaptive synthetic sampling approach for imbalanced learning,” in *Proceedings of the IEEE International Joint Conference on Neural Networks (IJCNN)*, pp. 1322–1328, 2008.
- [70] F. Dubosson, J.-E. Ranvier, S. Bromuri, J.-P. Calbimonte, J. Ruiz, and M. Schumacher, “The open DiaTrend dataset, a dataset of type 1 diabetic patient glucose time series and associated event data,” *Data in Brief*, vol. 29, p. 104978, 2020.
- [71] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollar, “Focal loss for dense object detection,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 2980–2988, 2017.

- [72] T. T. Um, F. M. J. Pfister, D. Pichler, S. Endo, M. Lang, S. Hirche, U. Fietzek, and D. Ku-
lić, “Data augmentation of wearable sensor data for Parkinson’s disease monitoring using
convolutional neural networks,” in *Proceedings of the 19th ACM International Conference
on Multimodal Interaction (ICMI)*, pp. 216–220, 2017.

Apéndice A

Ejemplo de anexo: Planificación y gestión del proyecto (opcional)

El Apéndice A puede incluirse como recomendación si se ha realizado un proyecto de tipo práctico práctico de desarrollo del software.

De forma general se puede incluir la especificación requerimientos del proyecto, la información sobre stakeholders del proyecto, la justificación (interés, oportunidad, coste/beneficio...), etc.

En cuanto a la planificación: se indicarán las diferentes tareas a desarrollar durante el proyecto ordenadas cronológicamente.

En cuanto a la descripción: breve definición de las tareas indicando su relación con los requisitos del proyecto, método de trabajo, tecnologías a utilizar para desarrollar cada tarea, posibles obstáculos y riesgos.

En cuanto a la validación: qué método se utilizará para validar el proyecto (si se trata de desarrollo de software, indicando métricas referidas a `code coverage`", etc., pruebas unitarias, etc.).

En cuanto al estudio de costes y sostenibilidad: se indicarán las horas de programador necesarias para llevarlo a cabo, gasto en recursos, bibliografía, tiempos de conexión, etc.

En cuanto a la temporización, lo suyo es un Diagrama de Gantt donde quede claro el tiempo invertido en la realización de cada una de las tareas y su secuenciación/entrelazamiento a los largo de los meses de realización del proyecto.

Finalmente se acabará justificando la sostenibilidad de los productos software generados en cuanto a costes de prueba y mantenimiento del software.

Una posible estructuración de la gestión y planificación del proyecto podría ser en las siguientes subsecciones:

A.1. Metodología/Ciclo de vida

A.2. Herramientas y plataformas utilizadas para el desarrollo del proyecto

A.3. Costes del proyecto

A.4. Gestión del proyecto. Planificación temporal. Diagrama de Gantt

A.5. Texto añadido

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras

nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetur at, consectetur sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

Morbi luctus, wisi viverra faucibus pretium, nibh est placerat odio, nec commodo wisi enim eget quam. Quisque libero justo, consectetur a, feugiat vitae, porttitor eu, libero. Suspendisse sed mauris vitae elit sollicitudin malesuada. Maecenas ultricies eros sit amet ante. Ut venenatis velit. Maecenas sed mi eget dui varius euismod. Phasellus aliquet volutpat odio. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque sit amet pede ac sem eleifend consectetur. Nullam elementum, urna vel imperdiet sodales, elit ipsum pharetra ligula, ac pretium ante justo a nulla. Curabitur tristique arcu eu metus. Vestibulum lectus. Proin mauris. Proin eu nunc eu urna hendrerit faucibus. Aliquam auctor, pede consequat laoreet varius, eros tellus scelerisque quam, pellentesque hendrerit ipsum dolor sed augue. Nulla nec lacus.

Suspendisse vitae elit. Aliquam arcu neque, ornare in, ullamcorper quis, commodo eu, libero. Fusce sagittis erat at erat tristique mollis. Maecenas sapien libero, molestie et, lobortis in, sodales eget, dui. Morbi ultrices rutrum lorem. Nam elementum ullamcorper leo. Morbi dui. Aliquam sagittis. Nunc placerat. Pellentesque tristique sodales est. Maecenas imperdiet lacinia velit. Cras non urna. Morbi eros pede, suscipit ac, varius vel, egestas non, eros. Praesent malesuada, diam id pretium elementum, eros sem dictum tortor, vel consectetur odio sem sed wisi.

Sed feugiat. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Ut pellentesque augue sed urna. Vestibulum diam eros, fringilla et, consectetur eu, nonummy id, sapien. Nullam at lectus. In sagittis ultrices mauris. Curabitur malesuada erat sit amet massa. Fusce blandit. Aliquam erat volutpat. Aliquam euismod. Aenean vel lectus. Nunc imperdiet justo nec dolor.

Etiam euismod. Fusce facilisis lacinia dui. Suspendisse potenti. In mi erat, cursus id, nonummy sed, ullamcorper eget, sapien. Praesent pretium, magna in eleifend egestas, pede pede pretium lorem, quis consectetur tortor sapien facilisis magna. Mauris quis magna varius nulla scelerisque imperdiet. Aliquam non quam. Aliquam porttitor quam a lacus. Praesent vel arcu ut tortor cursus volutpat. In vitae pede quis diam bibendum placerat. Fusce elementum convallis neque. Sed dolor orci, scelerisque ac, dapibus nec, ultricies ut, mi. Duis nec dui quis leo sagittis commodo.

Aliquam lectus. Vivamus leo. Quisque ornare tellus ullamcorper nulla. Mauris porttitor pharetra tortor. Sed fringilla justo sed mauris. Mauris tellus. Sed non leo. Nullam elementum, magna in cursus sodales, augue est scelerisque sapien, venenatis congue nulla arcu et pede. Ut suscipit enim vel sapien. Donec congue. Maecenas urna mi, suscipit in, placerat ut, vestibulum ut, massa. Fusce ultrices nulla et nisl.

Etiam ac leo a risus tristique nonummy. Donec dignissim tincidunt nulla. Vestibulum rhoncus molestie odio. Sed lobortis, justo et pretium lobortis, mauris turpis condimentum augue, nec ultricies nibh arcu pretium enim. Nunc purus neque, placerat id, imperdiet sed, pellentesque nec, nisl. Vestibulum imperdiet neque non sem accumsan laoreet. In hac habitasse platea dictumst. Etiam condimentum facilisis libero. Suspendisse in elit quis nisl aliquam dapibus. Pellentesque auctor sapien. Sed egestas sapien nec lectus. Pellentesque vel dui vel neque bibendum viverra. Aliquam porttitor nisl nec pede. Proin mattis libero vel turpis. Donec rutrum mauris et libero. Proin euismod porta felis. Nam lobortis, metus quis elementum commodo, nunc lectus elementum mauris, eget vulputate ligula tellus eu neque. Vivamus eu dolor.

Nulla in ipsum. Praesent eros nulla, congue vitae, euismod ut, commodo a, wisi. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Aenean nonummy magna non leo. Sed felis erat, ullamcorper in, dictum non, ultricies ut, lectus. Proin vel arcu a odio lobortis euismod. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Proin ut est. Aliquam odio. Pellentesque massa turpis, cursus eu, euismod nec, tempor congue, nulla. Duis viverra gravida mauris. Cras tincidunt. Curabitur eros ligula, varius ut, pulvinar in, cursus faucibus, augue.

Apéndice B

Ejemplo de anexo: Innovación (opcional)

El Apéndice B puede ser recomendable incluir en los casos en los que se realice un proyecto práctico de desarrollo del software en los que se quiera hacer referencia a la posible innovación en el marco empresarial.

En caso positivo, se recomienda una posible estructuración en las siguientes subsecciones:

B.1. Estudio del Mercado

Contenido del estudio del mercado

B.1.1. Segmentos de Clientes

Contenido sobre los segmentos de clientes

B.1.2. Competidores

Información sobre los competidores

B.2. Propuesta de Valor

Descripción de la propuesta de valor

B.3. Recursos Clave

Enumeración de los recursos clave

B.4. Actividades Clave

Descripción de las actividades clave

B.5. Socios y Alianzas Clave

Detalles sobre socios y alianzas

B.6. Estructura de Costes Prevista

Desglose de los costes estimados. Incluir aquí la estimación presupuestaria de Costes

B.7. Vías de Ingresos

Estrategias para generar ingresos

Incluir aquí la proyección de ingresos a lo largo de los primeros tres años. Incluir las vías o fuentes de financiación.

B.8. Canales de Distribución

Descripción de los canales de distribución

B.9. Relación con los Clientes

Cómo se relacionará con los clientes

B.10. Descripción del Producto Mínimo Viable

Detalles sobre el producto mínimo viable

B.11. Roadmap de Desarrollo

Planificación del desarrollo

B.12. Aspectos Legales

Consideraciones legales, licencias y patentes

B.13. Texto añadido

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis

natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetur at, consectetur sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

Morbi luctus, wisi viverra faucibus pretium, nibh est placerat odio, nec commodo wisi enim eget quam. Quisque libero justo, consectetur a, feugiat vitae, porttitor eu, libero. Suspendisse sed mauris vitae elit sollicitudin malesuada. Maecenas ultricies eros sit amet ante. Ut venenatis velit. Maecenas sed mi eget dui varius euismod. Phasellus aliquet volutpat odio. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque sit amet

pede ac sem eleifend consectetur. Nullam elementum, urna vel imperdiet sodales, elit ipsum pharetra ligula, ac pretium ante justo a nulla. Curabitur tristique arcu eu metus. Vestibulum lectus. Proin mauris. Proin eu nunc eu urna hendrerit faucibus. Aliquam auctor, pede consequat laoreet varius, eros tellus scelerisque quam, pellentesque hendrerit ipsum dolor sed augue. Nulla nec lacus.

Suspendisse vitae elit. Aliquam arcu neque, ornare in, ullamcorper quis, commodo eu, libero. Fusce sagittis erat at erat tristique mollis. Maecenas sapien libero, molestie et, lobortis in, sodales eget, dui. Morbi ultrices rutrum lorem. Nam elementum ullamcorper leo. Morbi dui. Aliquam sagittis. Nunc placerat. Pellentesque tristique sodales est. Maecenas imperdiet lacinia velit. Cras non urna. Morbi eros pede, suscipit ac, varius vel, egestas non, eros. Praesent malesuada, diam id pretium elementum, eros sem dictum tortor, vel consectetur odio sem sed wisi.

Sed feugiat. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Ut pellentesque augue sed urna. Vestibulum diam eros, fringilla et, consectetur eu, nonummy id, sapien. Nullam at lectus. In sagittis ultrices mauris. Curabitur malesuada erat sit amet massa. Fusce blandit. Aliquam erat volutpat. Aliquam euismod. Aenean vel lectus. Nunc imperdiet justo nec dolor.

Etiam euismod. Fusce facilisis lacinia dui. Suspendisse potenti. In mi erat, cursus id, nonummy sed, ullamcorper eget, sapien. Praesent pretium, magna in eleifend egestas, pede pede pretium lorem, quis consectetur tortor sapien facilisis magna. Mauris quis magna varius nulla scelerisque imperdiet. Aliquam non quam. Aliquam porttitor quam a lacus. Praesent vel arcu ut tortor cursus volutpat. In vitae pede quis diam bibendum placerat. Fusce elementum convallis neque. Sed dolor orci, scelerisque ac, dapibus nec, ultricies ut, mi. Duis nec dui quis leo sagittis commodo. Aliquam lectus. Vivamus leo. Quisque ornare tellus ullamcorper nulla. Mauris porttitor pharetra tortor. Sed fringilla justo sed mauris. Mauris tellus. Sed non leo. Nullam elementum, magna in cursus sodales, augue est scelerisque sapien, venenatis congue nulla arcu et pede. Ut suscipit enim vel sapien. Donec congue. Maecenas urna mi, suscipit in, placerat ut, vestibulum ut, massa. Fusce ultrices nulla et nisl.

Etiam ac leo a risus tristique nonummy. Donec dignissim tincidunt nulla. Vestibulum rhoncus molestie odio. Sed lobortis, justo et pretium lobortis, mauris turpis condimentum augue, nec ultricies nibh arcu pretium enim. Nunc purus neque, placerat id, imperdiet sed, pellentesque nec, nisl. Vestibulum imperdiet neque non sem accumsan laoreet. In hac habitasse platea dictumst. Etiam condimentum facilisis libero. Suspendisse in elit quis nisl aliquam dapibus. Pellentesque auctor sapien. Sed egestas sapien nec lectus. Pellentesque vel dui vel neque bibendum viverra. Aliquam porttitor nisl nec pede. Proin mattis libero vel turpis. Donec rutrum mauris et libero. Proin euismod porta felis. Nam lobortis, metus quis elementum commodo, nunc lectus elementum mauris, eget vulputate ligula tellus eu neque. Vivamus eu dolor.

Nulla in ipsum. Praesent eros nulla, congue vitae, euismod ut, commodo a, wisi. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Aenean nonummy magna non leo. Sed felis erat, ullamcorper in, dictum non, ultricies ut, lectus. Proin vel arcu a odio lobortis euismod. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Proin ut est. Aliquam odio. Pellentesque massa turpis, cursus eu, euismod nec, tempor congue, nulla. Duis viverra gravida mauris. Cras tincidunt. Curabitur eros ligula, varius ut, pulvinar in, cursus faucibus, augue.

Apéndice C

Ejemplo de anexo: Manual de usuario (opcional)

Este es un apéndice opcional, en caso de que quieras añadir un manual de usuario del software realizado.

Puedes incluir tantos capítulos de Anexos como te haga falta. Si no tienes anexos, puedes comentar las líneas en el fichero **tfm.tex**.

C.1. Texto añadido

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat.

Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetur at, consectetur sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

Morbi luctus, wisi viverra faucibus pretium, nibh est placerat odio, nec commodo wisi enim eget quam. Quisque libero justo, consectetur a, feugiat vitae, porttitor eu, libero. Suspendisse sed mauris vitae elit sollicitudin malesuada. Maecenas ultricies eros sit amet ante. Ut venenatis velit. Maecenas sed mi eget dui varius euismod. Phasellus aliquet volutpat odio. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque sit amet pede ac sem eleifend consectetur. Nullam elementum, urna vel imperdiet sodales, elit ipsum pharetra ligula, ac pretium ante justo a nulla. Curabitur tristique arcu eu metus. Vestibulum lectus. Proin mauris. Proin eu nunc eu urna hendrerit faucibus. Aliquam auctor, pede consequat laoreet varius, eros tellus scelerisque quam, pellentesque hendrerit ipsum dolor sed augue. Nulla nec lacus.

Suspendisse vitae elit. Aliquam arcu neque, ornare in, ullamcorper quis, commodo eu, libero. Fusce sagittis erat at erat tristique mollis. Maecenas sapien libero, molestie et, lobortis in, sodales eget, dui. Morbi ultrices rutrum lorem. Nam elementum ullamcorper leo. Morbi dui. Aliquam sagittis. Nunc placerat. Pellentesque tristique sodales est. Maecenas imperdiet lacinia velit. Cras non urna. Morbi eros pede, suscipit ac, varius vel, egestas non, eros. Praesent malesuada, diam id pretium elementum, eros sem dictum tortor, vel consectetur odio sem sed wisi.

Sed feugiat. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Ut pellentesque augue sed urna. Vestibulum diam eros, fringilla et, consectetur eu, no-

nummy id, sapien. Nullam at lectus. In sagittis ultrices mauris. Curabitur malesuada erat sit amet massa. Fusce blandit. Aliquam erat volutpat. Aliquam euismod. Aenean vel lectus. Nunc imperdiet justo nec dolor.

Etiam euismod. Fusce facilisis lacinia dui. Suspendisse potenti. In mi erat, cursus id, nonummy sed, ullamcorper eget, sapien. Praesent pretium, magna in eleifend egestas, pede pede pretium lorem, quis consectetur tortor sapien facilisis magna. Mauris quis magna varius nulla scelerisque imperdiet. Aliquam non quam. Aliquam porttitor quam a lacus. Praesent vel arcu ut tortor cursus volutpat. In vitae pede quis diam bibendum placerat. Fusce elementum convallis neque. Sed dolor orci, scelerisque ac, dapibus nec, ultricies ut, mi. Duis nec dui quis leo sagittis commodo. Aliquam lectus. Vivamus leo. Quisque ornare tellus ullamcorper nulla. Mauris porttitor pharetra tortor. Sed fringilla justo sed mauris. Mauris tellus. Sed non leo. Nullam elementum, magna in cursus sodales, augue est scelerisque sapien, venenatis congue nulla arcu et pede. Ut suscipit enim vel sapien. Donec congue. Maecenas urna mi, suscipit in, placerat ut, vestibulum ut, massa. Fusce ultrices nulla et nisl.

Etiam ac leo a risus tristique nonummy. Donec dignissim tincidunt nulla. Vestibulum rhoncus molestie odio. Sed lobortis, justo et pretium lobortis, mauris turpis condimentum augue, nec ultricies nibh arcu pretium enim. Nunc purus neque, placerat id, imperdiet sed, pellentesque nec, nisl. Vestibulum imperdiet neque non sem accumsan laoreet. In hac habitasse platea dictumst. Etiam condimentum facilisis libero. Suspendisse in elit quis nisl aliquam dapibus. Pellentesque auctor sapien. Sed egestas sapien nec lectus. Pellentesque vel dui vel neque bibendum viverra. Aliquam porttitor nisl nec pede. Proin mattis libero vel turpis. Donec rutrum mauris et libero. Proin euismod porta felis. Nam lobortis, metus quis elementum commodo, nunc lectus elementum mauris, eget vulputate ligula tellus eu neque. Vivamus eu dolor.

Nulla in ipsum. Praesent eros nulla, congue vitae, euismod ut, commodo a, wisi. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Aenean nonummy magna non leo. Sed felis erat, ullamcorper in, dictum non, ultricies ut, lectus. Proin vel arcu a odio lobortis euismod. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Proin ut est. Aliquam odio. Pellentesque massa turpis, cursus eu, euismod nec, tempor congue, nulla. Duis viverra gravida mauris. Cras tincidunt. Curabitur eros ligula, varius ut, pulvinar in, cursus faucibus, augue.

