



UNIVERSIDAD DE GRANADA

TRABAJO FIN DE MÁSTER
MASTER EN CIENCIA DE DATOS

Compensating for Patient Heterogeneity Bias

in Glucose Prediction Models via Data Balancing

Autor

Juan Ricardo Hernández Sánchez-Agosta (estudiante)

Director/es

Oresti Baños Legrán (tutor 1)

Claudia Villalonga Palliser (tutor 2)



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE TELECOMUNICACIÓN

Granada, 23 de julio de 2026



Compensating for Patient Heterogeneity Bias

in Glucose Prediction Models via Data Balancing

Autor

Juan Ricardo Hernández Sánchez-Agesta (estudiante)

Director/es

Oresti Baños Legrán (tutor 1)

Claudia Villalonga Palliser (tutor 2)

Compensating for Patient Heterogeneity Bias: in Glucose Prediction Models via Data Balancing

Juan Ricardo Hernández Sánchez-Agesta (estudiante)

Palabras clave: predicción de glucosa, modelos LSTM, monitorización continua de glucosa, balanceo de datos, heterogeneidad demográfica, sesgo de paciente, sobrestreo, submuestreo, SMOTE, validación cruzada por grupos, series temporales, diabetes tipo 1

Resumen

La predicción precisa de glucosa en sangre es una herramienta fundamental para la gestión de la diabetes tipo 1, permitiendo anticipar episodios de hipoglucemia e hiperglucemia y mejorar la calidad de vida de los pacientes. Los modelos de aprendizaje profundo basados en redes LSTM (*Long Short-Term Memory*) han demostrado un rendimiento destacado en este dominio, al ser capaces de capturar dependencias temporales complejas en señales de monitorización continua de glucosa (CGM). Sin embargo, la heterogeneidad demográfica inherente a las cohortes de pacientes —en particular las diferencias de edad y sexo— puede introducir sesgos sistemáticos en el entrenamiento, comprometiendo la equidad y la generalización de los modelos.

Este Trabajo Fin de Máster aborda dicho problema mediante el diseño, implementación y evaluación de un *pipeline* de equilibrado de datos aplicado exclusivamente al conjunto de entrenamiento, dentro de un esquema de validación cruzada por grupos (*Group K-Fold*) que garantiza la separación estricta entre pacientes a lo largo de todos los pliegues. El objetivo central es cuantificar si las técnicas de equilibrado basadas en atributos demográficos —edad y sexo— reducen el sesgo de paciente y mejoran el rendimiento clínico de los modelos LSTM, medido en términos de las métricas de tiempo en rango glucémico (*Time in Range*, TIR; *Time Above Range*, TAR; *Time Below Range*, TBR).

Se trabaja sobre tres conjuntos de datos de CGM: **T1DiabetesGranada** (643 pacientes, más de 30 millones de mediciones, recogidas entre 2018 y 2022 en el sistema sanitario de Granada), **REPLACE-BG** (ensayo clínico multicéntrico estadounidense) y **DiaTrend** (cohorte internacional de uso libre). Esta variedad permite evaluar la robustez de las conclusiones frente a características estructurales distintas —tamaño, densidad, distribución demográfica y patrón de datos ausentes.

La taxonomía de técnicas implementadas comprende nueve condiciones experimentales, organizadas en tres categorías: técnicas aleatorias (*random undersampling*, *random oversampling*), técnicas guiadas (*SMOTE*, *Tomek Links*) y combinaciones híbridas (*patient-aware undersampling*, *jittering*, *undersampling+oversampling*, *undersampling+SMOTE*, *SMOTE+Tomek*), cada una aplicada en dos variantes según el eje demográfico de equilibrado (edad y sexo), más una condición de control sin equilibrado. El pipeline fue validado formalmente mediante un *notebook* de verificación de restricciones que comprueba, entre otras propiedades, la invarianza de los

conjuntos de validación y test entre condiciones, la ausencia de solapamiento de pacientes y el cumplimiento del rango sensor en los puntos sintéticos generados por SMOTE.

El análisis estadístico se estructura mediante pruebas de Friedman para detectar diferencias globales entre condiciones, post-hoc de Nemenyi para comparaciones por pares, tamaños del efecto de Cohen's d y agregación de rankings mediante el método de Borda. Los resultados muestran un panorama diferenciado por conjunto de datos: **DiaTrend** es el único en el que el equilibrado produce efectos estadísticamente significativos en todos los rangos glucémicos analizados, mientras que **T1DiabetesGranada** y **REPLACE-BG** presentan una consistencia entre pliegues reducida —medida mediante la correlación de Spearman de rankings— atribuible a la heterogeneidad intrínseca de las cohortes y al patrón de datos ausentes de tipo MNAR (*Missing Not At Random*) identificado en la fase exploratoria.

En cuanto a las dimensiones demográficas, el equilibrado por **edad** supera consistentemente al equilibrado por **sexo** en términos de impacto sobre el rendimiento clínico. La técnica **Age·Oversampling** presenta la mayor mejora en TIR, aunque al coste de una degradación sistemática en TAR-1, revelando un compromiso clínico que debe ser considerado en la práctica. La agregación global mediante Borda posiciona a **Age·SMOTE** como la técnica con mejor rendimiento agregado, al ofrecer un balance favorable entre mejora en rango euglucémico y control de los efectos adversos en rangos extremos.

Este trabajo contribuye, por tanto, a la intersección entre equidad algorítmica y modelado clínico de series temporales, proporcionando evidencia empírica sobre cuándo y en qué medida el equilibrado demográfico es beneficioso, y sentando las bases metodológicas para su incorporación en sistemas de predicción de glucosa orientados a poblaciones heterogéneas.

Compensating for Patient Heterogeneity Bias: in Glucose Prediction Models via Data Balancing

Juan Ricardo Hernández Sánchez-Agosta (estudiante)

Keywords: glucose prediction, LSTM models, continuous glucose monitoring, data balancing, demographic heterogeneity, patient bias, oversampling, undersampling, SMOTE, group-wise cross-validation, time series, type 1 diabetes

Abstract

Accurate blood glucose prediction is a key tool for type 1 diabetes management, enabling anticipation of hypoglycemic and hyperglycemic episodes and improving patient quality of life. Deep learning models based on Long Short-Term Memory (LSTM) networks have shown strong performance in this domain due to their ability to capture complex temporal dependencies in continuous glucose monitoring (CGM) signals. However, the inherent demographic heterogeneity of patient cohorts — particularly differences in age and sex — can introduce systematic biases during training, undermining the fairness and generalisability of the resulting models.

This Master’s thesis addresses this problem through the design, implementation, and evaluation of a data balancing pipeline applied exclusively to the training set, within a Group K-Fold cross-validation scheme that enforces strict patient separation across all folds. The central objective is to quantify whether demographic balancing techniques — based on age and sex — reduce patient heterogeneity bias and improve the clinical performance of LSTM models, measured using glycaemic time-in-range metrics (Time in Range, TIR; Time Above Range, TAR; Time Below Range, TBR).

Three CGM datasets are used: **T1DiabetesGranada** (643 patients, over 30 million readings collected between 2018 and 2022 within the Granada healthcare system), **REPLACE-BG** (a US multicentre clinical trial), and **DiaTrend** (an international open-access cohort). This diversity allows the robustness of findings to be assessed across datasets with distinct structural characteristics — size, density, demographic distribution, and missing data patterns.

The implemented technique taxonomy comprises nine experimental conditions organised into three categories: random techniques (random undersampling, random oversampling), guided techniques (SMOTE, Tomek Links), and hybrid combinations (patient-aware undersampling, jittering, undersampling+oversampling, undersampling+SMOTE, SMOTE+Tomek), each applied in two demographic variants (age-based and sex-based), plus an unbalanced control condition. The pipeline was formally validated through a constraint-verification notebook checking, among other properties, the bit-identical invariance of validation and test sets across conditions, the absence of patient overlap, and the compliance of SMOTE-generated synthetic points with sensor measurement ranges.

The statistical analysis is structured using Friedman tests to detect global differences across conditions, Nemenyi post-hoc tests for pairwise comparisons, Cohen’s d effect sizes, and Borda count ranking aggregation. Results reveal a dataset-dependent picture: **DiaTrend** is the only dataset in which balancing yields statistically significant effects across all analysed glycaemic ranges, while **T1DiabetesGranada** and **REPLACE-BG** exhibit low fold-level ranking consistency — measured via Spearman correlation — attributable to intrinsic cohort heterogeneity and the Missing Not At Random (MNAR) missingness pattern identified during the exploratory phase.

Regarding demographic dimensions, **age-based** balancing consistently outperforms **sex-based** balancing in terms of clinical impact. **Age-Oversampling** achieves the greatest TIR impro-

vement, albeit at the cost of systematic TAR-1 degradation, revealing a clinical trade-off that must be carefully considered in practice. Global Borda aggregation positions **Age•SMOTE** as the best-performing technique overall, offering a favourable balance between improvement in the euglycaemic range and control of adverse effects in extreme ranges.

This work therefore contributes to the intersection of algorithmic fairness and clinical time-series modelling, providing empirical evidence on when and to what extent demographic balancing is beneficial, and laying the methodological groundwork for its incorporation into glucose prediction systems designed for heterogeneous patient populations.

Yo, **Juan Ricardo Hernández Sánchez-Agesta** (estudiante), alumno del **MÁSTER DE CIENCIA DE DATOS E INGENIERÍA DE COMPUTADORES**, con DNI **78154358-J**, autorizo la ubicación de la siguiente copia de mi Trabajo Fin de Máster en la biblioteca del centro para que pueda ser consultada por las personas que lo deseen.

Fdo: *Juan Ricardo Hernández Sánchez-Agesta (estudiante)*

Granada a 23 de julio de 2026.

D. **Oresti Baños Legrán (tutor 1)**, Profesor del Área de Ingeniería de Computadores, Automática y Robótica del Departamento Ingeniería de Computadores, Automática y Robótica de la Universidad de Granada.

D. **Claudia Villalonga Palliser (tutor 2)**, Profesor del Área de Ingeniería de Computadores, Automática y Robótica del Departamento de Ingeniería de Computadores, Automática y Robótica de la Universidad de Granada.

Informan:

Que el presente trabajo, titulado *Compensating for Patient Heterogeneity Bias, in Glucose Prediction Models via Data Balancing*, ha sido realizado bajo su supervisión por **Juan Ricardo Hernández Sánchez-Agosta (estudiante)**, y autorizamos la defensa de dicho trabajo ante el tribunal que corresponda.

Y para que conste, expiden y firman el presente informe en Granada a 23 de julio de 2026.

Los directores:

Oresti Baños Legrán (tutor 1) Claudia Villalonga Palliser (tutor 2)

Yo, **Juan Ricardo Hernández Sánchez-Agesta** (estudiante), alumno del **MÁSTER DE CIENCIA DE DATOS E INGENIERÍA DE COMPUTADORES** de la **Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación de la Universidad de Granada**, con DNI **78154358-J**, declaro explícitamente que el trabajo presentado es original, entendido en el sentido que no he utilizado ninguna fuente sin citarla debidamente.

Fdo: **Juan Ricardo Hernández Sánchez-Agesta** (estudiante)

Granada, 23 de julio de 2026.

Agradecimientos

Poner aquí los agradecimientos.

Índice general

1. Introducción	1
1.1. Motivación	2
1.2. Objetivos	2
1.3. Estructura del trabajo	3
2. Estado del arte	5
2.1. Introducción	5
2.2. Diabetes Tipo 1 y monitorización continua de glucosa: contexto necesario	6
2.2.1. Diabetes Mellitus Tipo 1	6
2.2.2. Monitorización continua de glucosa (CGM)	6
2.2.3. <i>Datasets</i> utilizados en este trabajo	6
2.2.4. Predicción de glucosa mediante LSTM: formulación del problema	7
2.3. Diferencias fisiológicas por sexo y edad en la dinámica glucémica	7
2.3.1. Diferencias por sexo	7
2.3.2. Diferencias por edad	8
2.4. Desequilibrio demográfico en <i>datasets</i> clínicos y su impacto en el aprendizaje automático	8
2.4.1. Desequilibrio demográfico frente a desequilibrio de clase	8
2.4.2. Evidencia de disparidad de rendimiento por subgrupo demográfico en modelos clínicos	9
2.5. Técnicas de mitigación del desequilibrio demográfico	10
2.5.1. Reponderado de muestras (<i>Reweighting</i>)	10
2.5.2. Remuestreo dirigido por grupo demográfico	10
2.5.3. Generación sintética condicionada mediante redes generativas adversarias temporales	11
2.5.4. Aprendizaje de representaciones invariantes al atributo demográfico . . .	12
2.5.5. Validación cruzada con muestreo estratificado por grupo demográfico . . .	12
2.5.6. Comparativa de técnicas	13
2.5.7. Discusión y técnica seleccionada	13
2.6. Brechas en la literatura y motivación del presente trabajo	13
3. Desarrollo del TFM	15
3.1. Cómo colocar tablas y figuras	15
4. Resultados y discusión	17
5. Conclusiones	21
Bibliografía	25

A. Ejemplo de anexo: Planificación y gestión del proyecto (opcional)	27
A.1. Metodología/Ciclo de vida	28
A.2. Herramientas y plataformas utilizadas para el desarrollo del proyecto	28
A.3. Costes del proyecto	28
A.4. Gestión del proyecto. Planificación temporal. Diagrama de Gantt	28
A.5. Texto añadido	28
B. Ejemplo de anexo: Innovación (opcional)	31
B.1. Estudio del Mercado	31
B.1.1. Segmentos de Clientes	31
B.1.2. Competidores	31
B.2. Propuesta de Valor	31
B.3. Recursos Clave	31
B.4. Actividades Clave	31
B.5. Socios y Alianzas Clave	31
B.6. Estructura de Costes Prevista	32
B.7. Vías de Ingresos	32
B.8. Canales de Distribución	32
B.9. Relación con los Clientes	32
B.10. Descripción del Producto Mínimo Viable	32
B.11. Roadmap de Desarrollo	32
B.12. Aspectos Legales	32
B.13. Texto añadido	32
C. Ejemplo de anexo: Manual de usuario (opcional)	35
C.1. Texto añadido	35

Índice de figuras

4.1. Mi logo	19
4.2. Lista de distribuciones	19

Índice de tablas

2.1. <i>Datasets</i> utilizados en este trabajo y disponibilidad de variables demográficas. . .	7
2.2. Comparativa de técnicas para la mitigación del desequilibrio demográfico.	13
4.1. Tabla grande	17
4.2. Tabla enorme	18

Capítulo 1

Introducción

La diabetes mellitus tipo 1 (DM1) es una enfermedad crónica de carácter autoinmune que afecta a millones de personas en todo el mundo y que se caracteriza por la destrucción de las células beta del páncreas, impidiendo la producción endógena de insulina. A diferencia de otras enfermedades crónicas con una dinámica relativamente estable, la DM1 somete al paciente a una gestión terapéutica diaria de alta complejidad: la concentración de glucosa en sangre fluctúa de forma continua en respuesta a la insulina exógena, la ingesta, el ejercicio físico, el estrés y otros factores fisiológicos. El desafío clínico central es anticipar estas fluctuaciones con suficiente antelación para que el paciente pueda actuar antes de que se produzcan episodios de hipoglucemia o hiperglucemia, que pueden tener consecuencias agudas graves a corto plazo y complicaciones crónicas severas a largo plazo.

Los sistemas de monitorización continua de glucosa (CGM, por sus siglas en inglés) han transformado el seguimiento clínico de la DM1, al generar señales de alta frecuencia —una medición cada 5 o 15 minutos— que capturan la dinámica glucémica con una resolución imposible mediante los métodos tradicionales de glucometría capilar. Esta riqueza temporal ha impulsado el desarrollo de modelos predictivos basados en aprendizaje automático que estiman el valor futuro de glucosa a partir de la trayectoria reciente de la señal. Entre estas arquitecturas, las redes neuronales recurrentes de tipo LSTM (*Long Short-Term Memory*) han ocupado un lugar consolidado por su capacidad de aprender dependencias temporales de largo alcance directamente de la secuencia bruta, sin necesidad de ingeniería manual de características.

Sin embargo, el rendimiento de un modelo LSTM de predicción de glucosa no depende únicamente de su arquitectura ni de la calidad de la señal CGM en sí misma: depende también de la composición del conjunto de datos con el que se entrena. Los *datasets* de investigación en DM1 disponibles públicamente son, por construcción, muestras de conveniencia clínica. Sus distribuciones demográficas no son uniformes: algunos *datasets* presentan una mayoría de pacientes de un determinado sexo o de un rango etario concreto, lo que se traduce en una asimetría estructural en el número de ventanas de entrenamiento disponibles por grupo demográfico. Esta asimetría puede inducir que el modelo aprenda preferentemente la dinámica glucémica del subgrupo mayoritario, degradando su capacidad predictiva para los subgrupos infrarrepresentados.

La cuestión de si esta composición demográfica del conjunto de entrenamiento afecta de forma medible y corregible al rendimiento predictivo de un modelo LSTM constituye la pregunta central de este Trabajo Fin de Máster. Se trata de una pregunta que la literatura ha comenzado a explorar en el dominio amplio del aprendizaje automático clínico, pero que permanece escasamente estudiada en el contexto específico de la predicción de glucosa mediante CGM, lo que delimita y justifica la contribución de este trabajo.

1.1. Motivación

La motivación de este trabajo surge de la intersección de dos líneas de inquietud: una de carácter personal, derivada del interés por aplicar técnicas de ciencia de datos a problemas con impacto clínico real; y otra de carácter técnico, derivada de una limitación metodológica concreta identificada en la literatura existente.

Desde el punto de vista personal, la predicción de glucosa en DM1 representa un problema de modelado especialmente rico: combina series temporales de alta frecuencia con contexto clínico complejo, heterogeneidad interindividual pronunciada y consecuencias potencialmente graves de los errores de predicción. Es, además, un dominio en el que la brecha entre el rendimiento agregado de un modelo y su rendimiento en subgrupos específicos puede traducirse en diferencias reales en la calidad del cuidado que reciben los pacientes. Trabajar en este dominio con las herramientas propias de la ingeniería de datos y el aprendizaje automático, y hacerlo con rigor estadístico, constituye una motivación genuina que subyace a todas las decisiones de diseño de este trabajo.

Desde el punto de vista técnico, la motivación surge de una observación concreta: la equidad algorítmica en salud —el estudio sistemático de si los modelos de aprendizaje automático producen rendimientos dispares en función de características demográficas de los pacientes— ha recibido creciente atención en la literatura, pero ha operado mayoritariamente sobre datos tabulares en los que cada observación corresponde a un paciente o a un episodio clínico discreto. El problema de la predicción de series temporales mediante ventana deslizante introduce una complicación estructural que no ha sido tratada explícitamente en la literatura revisada: la unidad de balanceo no es el paciente sino la ventana. Un mismo paciente con una serie temporal larga puede generar órdenes de magnitud más ventanas de entrenamiento que otro paciente con una serie corta, incluso cuando ambos pertenecen nominalmente al mismo grupo demográfico. Esta distinción entre balanceo a nivel de paciente y balanceo a nivel de ventana es metodológicamente relevante y constituye una de las contribuciones de diseño de este trabajo.

Adicionalmente, la elección de las dimensiones demográficas de estudio —sexo y edad— está motivada por evidencia fisiológica consolidada: tanto el sexo como la edad están asociados a patrones de dinámica glucémica distinguibles. Las diferencias hormonales entre hombres y mujeres, así como la evolución de la respuesta insulínica a lo largo de la vida, producen perfiles CGM sistémicamente distintos entre subgrupos, lo que hace esperable —y justifica estudiar empíricamente— que un modelo LSTM entrenado sobre una composición demográficamente sesgada aprenda de forma subóptima para los subgrupos infrarrepresentados.

Por último, existe una motivación de relevancia práctica e inmediata: el *dataset* T1DiabetesGranada, generado en el Hospital Universitario Virgen de las Nieves de Granada con más de 643 pacientes y más de 30 millones de mediciones registradas entre 2018 y 2022, es uno de los tres conjuntos de datos sobre los que se trabaja en este TFM. Incorporar un recurso de investigación local de esta envergadura, y contribuir a entender sus propiedades estadísticas y sus implicaciones para el entrenamiento de modelos predictivos, añade una dimensión de relevancia territorial y clínica directa a la investigación.

1.2. Objetivos

El objetivo general de este trabajo es cuantificar empíricamente el impacto de las técnicas de balanceo demográfico —aplicadas sobre las dimensiones de sexo y edad— en el rendimiento predictivo de un modelo LSTM de predicción de glucosa entrenado sobre datos CGM, y determinar bajo qué condiciones dicho balanceo produce mejoras clínicamente relevantes.

De este objetivo general se derivan los siguientes objetivos específicos:

1. **Diseñar e implementar un *pipeline* de balanceo demográfico** que opere exclusivamente sobre el conjunto de entrenamiento de cada *fold* en un esquema de validación cruzada por grupos (*Group K-Fold*), garantizando la separación estricta de pacientes entre particiones y la invarianza bit a bit de los conjuntos de validación y test entre condiciones experimentales.
2. **Implementar y validar una taxonomía de diez técnicas de balanceo**, clasificadas en tres familias: técnicas aleatorias (*random undersampling*, *random oversampling*), técnicas guiadas (*SMOTE*, *Tomek Links*) y combinaciones híbridas (*patient-aware undersampling*, *jittering*, *undersampling + oversampling*, *undersampling + SMOTE*, *SMOTE + Tomek*, *oversampling + Tomek Links*), aplicadas en dos variantes demográficas (edad y sexo) más una condición de control sin balanceo.
3. **Evaluar el efecto del balanceo demográfico sobre el rendimiento global del modelo LSTM**, medido mediante métricas de error de predicción (RMSE, MAE) y métricas de la *Clarke Error Grid* (zonas A, B, A+B), desagregadas por rango glucémico (TBR-2, TBR-1, TIR, TAR-1, TAR-2, rango completo).
4. **Comparar el impacto del balanceo por edad frente al balanceo por sexo** y determinar cuál de las dos dimensiones demográficas produce un efecto mayor y más consistente sobre el rendimiento predictivo.
5. **Caracterizar la robustez de los resultados entre *datasets***, evaluando si los efectos observados son consistentes a través de los tres conjuntos de datos (T1DiabetesGranada, REPLACE-BG, DiaTrend) o si dependen de propiedades estructurales específicas de cada cohorte, como el tamaño muestral, el patrón de datos ausentes o la distribución demográfica intrínseca.
6. **Identificar la técnica de balanceo con mejor rendimiento agregado** mediante un análisis estadístico formal que incluya pruebas de Friedman, comparaciones *post-hoc* de Nemenyi, tamaños del efecto de Cohen's *d* y agregación de *rankings* mediante el método de Borda.
7. **Describir las limitaciones metodológicas y los compromisos clínicos** identificados en los resultados, en particular aquellos casos en que la mejora en un rango glucémico conlleva una degradación en otro, con el objetivo de proporcionar una base de evidencia honesta para la toma de decisiones sobre la incorporación de balanceo demográfico en sistemas de predicción clínica.

1.3. Estructura del trabajo

El presente trabajo se organiza en seis capítulos, cuya estructura refleja la progresión lógica desde la fundamentación teórica hasta las conclusiones empíricas.

El capítulo 1.3 ([Estructura del trabajo](#)) establece el marco teórico y bibliográfico del trabajo. Se introduce el contexto clínico de la DM1 y de los sistemas CGM, se revisa la evidencia fisiológica de que el sexo y la edad modulan la dinámica glucémica, se examina la literatura sobre desequilibrio demográfico en *datasets* clínicos y su impacto documentado en el rendimiento de modelos de aprendizaje automático, y se revisan las técnicas del estado del arte para la mitigación de este desequilibrio. El capítulo concluye identificando las tres brechas concretas que este trabajo aborda.

El capítulo de metodología describe el diseño experimental completo: la arquitectura del modelo LSTM utilizado, el esquema de validación cruzada por grupos, el proceso de generación de

ventanas deslizantes a partir de las señales CGM, la implementación de las diez técnicas de balanceo demográfico y el proceso de validación formal del *pipeline* mediante un *notebook* de verificación de restricciones. Se describen igualmente las métricas de evaluación empleadas y el protocolo estadístico utilizado para el análisis comparativo.

El capítulo de resultados y discusión presenta los resultados experimentales siguiendo una estructura analítica en embudo: se parte de una visión global del efecto del balanceo agregado sobre todos los *datasets* y rangos glucémicos, y se desciende progresivamente hacia el análisis por *dataset*, por dimensión demográfica, por rango glucémico y por técnica individual. Los resultados de los tests de Friedman, los *rankings* de Nemenyi y la agregación de Borda se presentan en este capítulo, junto con la discusión de los compromisos clínicos identificados y la caracterización de la robustez entre *datasets*.

Finalmente, el capítulo 5 ([Conclusiones](#)) recoge las conclusiones del trabajo, contrastando los resultados obtenidos con los objetivos específicos enumerados en la sección 1.2, e identifica las líneas de trabajo futuro más directamente motivadas por los resultados y las limitaciones encontradas.

Capítulo 2

Estado del arte

2.1. Introducción

La predicción de glucosa en pacientes con Diabetes Mellitus Tipo 1 (DM1) a partir de datos de monitorización continua (CGM) es un problema bien establecido en la intersección del aprendizaje automático y la medicina de precisión. Los sistemas CGM generan series temporales de alta resolución que permiten entrenar modelos de *forecasting*, entre los que las redes LSTM (*Long Short-Term Memory*) ocupan un lugar consolidado por su capacidad de aprender dependencias temporales directamente de la secuencia sin extracción manual de características [1, 2].

El presente trabajo no aborda el problema, ya extensamente estudiado en la literatura, del desequilibrio entre clases glucémicas (hipoglucemia, normoglucemia, hiperglucemia). Aborda una pregunta distinta y, hasta donde se ha podido determinar en la revisión bibliográfica realizada, escasamente explorada en el dominio de la predicción de glucosa: **¿cómo afecta la composición demográfica —sexo y edad— del conjunto de entrenamiento al rendimiento predictivo de un modelo LSTM, y puede corregirse mediante técnicas de balanceo aplicadas a las ventanas de entrenamiento?**

Esta pregunta es conceptualmente distinta de la del desequilibrio de clase. Un conjunto de entrenamiento puede estar perfectamente equilibrado en términos de hipoglucemia/normoglucemia/hiperglucemia y, sin embargo, estar compuesto en su mayoría por ventanas procedentes de pacientes de un único sexo o de un rango etario concreto. Cuando esto ocurre, un modelo LSTM —que minimiza una pérdida agregada sobre el conjunto de entrenamiento— tiende a ajustar sus representaciones internas preferentemente a la dinámica glucémica del subgrupo mayoritario, lo que puede traducirse en un rendimiento predictivo desigual entre subgrupos demográficos, con independencia de cuál sea la distribución de clase glucémica.

El presente capítulo se organiza en torno a esta pregunta. En primer lugar, se introduce el contexto clínico y tecnológico estrictamente necesario para situar el problema: qué es la DM1, qué es un sistema CGM y cuáles son los *datasets* utilizados en este trabajo. En segundo lugar, se revisa la evidencia fisiológica y clínica de que el sexo y la edad modulan de forma demostrable la dinámica glucémica, lo que motiva por qué estas dos variables son objeto de estudio. En tercer lugar, se examina la literatura sobre desequilibrio demográfico en *datasets* clínicos y su impacto documentado en el rendimiento de modelos de aprendizaje automático. En cuarto lugar, se revisan las técnicas del estado del arte para la mitigación de este desequilibrio, evaluando su compatibilidad con la restricción metodológica central de este trabajo: el balanceo debe materializarse exclusivamente como una transformación de las ventanas de entrenamiento, sin modificar la arquitectura ni el procedimiento de entrenamiento del modelo LSTM. El capítulo concluye identificando las brechas concretas que este trabajo aborda.

2.2. Diabetes Tipo 1 y monitorización continua de glucosa: contexto necesario

2.2.1. Diabetes Mellitus Tipo 1

La Diabetes Mellitus Tipo 1 es una enfermedad autoinmune caracterizada por la destrucción selectiva de las células beta del páncreas, que resulta en una deficiencia absoluta de insulina y obliga a los pacientes a depender de la administración exógena de insulina para la supervivencia [3]. La gestión glucémica diaria es una tarea continua que depende del equilibrio entre la insulina administrada, la ingesta de carbohidratos, la actividad física y otros factores fisiológicos, lo que produce perfiles glucémicos altamente variables tanto entre pacientes como dentro de un mismo paciente a lo largo del tiempo [4]. Es precisamente esta variabilidad la que motiva el uso de modelos predictivos: anticipar la trayectoria glucémica de un paciente permite intervenir antes de que se produzcan desviaciones clínicamente relevantes.

2.2.2. Monitorización continua de glucosa (CGM)

Los sistemas CGM miden la concentración de glucosa en el líquido intersticial mediante electrodos enzimáticos subcutáneos, con frecuencias de muestreo de 5 a 15 minutos en los sistemas comerciales y en los *datasets* de investigación más utilizados [5]. Esta frecuencia produce series temporales de alta densidad: un único paciente seguido durante meses genera decenas de miles de puntos, lo que hace de los datos CGM un sustrato natural para el entrenamiento de modelos de series temporales como LSTM. La señal CGM presenta además un patrón de ausencia de datos no aleatorio (*Missing Not at Random*, MNAR): los periodos sin registro tienden a concentrarse en torno a eventos clínicos relevantes (cambios de sensor, hospitalizaciones, descompensaciones), por lo que cualquier transformación de los datos —incluido el balanceo demográfico de ventanas— debe respetar los límites de los segmentos continuos de registro para no generar transiciones glucémicas artificialmente abruptas [6].

2.2.3. *Datasets* utilizados en este trabajo

Este trabajo utiliza tres *datasets* públicos de investigación en DM1, seleccionados por incluir registro CGM de alta resolución junto con variables demográficas de sexo y edad a nivel de paciente, condición indispensable para el objetivo del trabajo.

DiaTrend [7]: cohorte de 54 pacientes con DM1 con seguimiento CGM de hasta 7 años, sin anotaciones de insulina ni carbohidratos, pero con variables demográficas disponibles. Es el *dataset* de menor tamaño muestral de los tres, lo que lo hace especialmente sensible a la concentración de ventanas en un número reducido de pacientes por grupo demográfico.

REPLACE-BG [8]: ensayo clínico aleatorizado con 226 participantes con DM1, datos CGM de 26 semanas y variables demográficas detalladas (edad, sexo, duración de la enfermedad, HbA1c). Es el único de los tres *datasets* con un diseño de ensayo clínico controlado, lo que le confiere una distribución demográfica más homogénea por construcción, aunque persisten desequilibrios entre subgrupos específicos de edad y sexo.

T1DiabetesGranada [9]: *dataset* de 643 pacientes con DM1 atendidos en el Hospital Universitario Virgen de las Nieves (Granada), con muestreo CGM a 15 minutos durante seguimientos de hasta 4 años. Es el mayor de los tres en número de pacientes, lo que en principio favorece una representación demográfica más rica, si bien presenta fragmentación temporal significativa en los registros de algunos pacientes.

La tabla 2.1 resume las características de los tres *datasets* desde la perspectiva relevante para este trabajo: tamaño muestral y disponibilidad de las variables demográficas objeto de estudio. A

diferencia de las comparativas habituales en la literatura de CGM, que enfatizan el ratio de desequilibrio entre clases glucémicas, aquí se prioriza la información sobre composición demográfica, que es la variable que este trabajo manipula.

Tabla 2.1: *Datasets* utilizados en este trabajo y disponibilidad de variables demográficas.

Dataset	Pacientes	Muestreo	Seguimiento	Variables demográficas
DiaTrend	54	5 min	≤ 7 años	Sexo, edad
REPLACE-BG	226	5 min	26 sem	Sexo, edad, HbA1c, duración
T1DGranada	643	15 min	≤ 4 años	Sexo, edad

2.2.4. Predicción de glucosa mediante LSTM: formulación del problema

Este trabajo formula la predicción glucémica como un problema de regresión temporal: dado un historial de mediciones CGM de longitud fija $\{g_{t-n}, \dots, g_t\}$ (*Historical Window*, HW), se estima el valor de glucosa en un instante futuro g_{t+PH} , donde PH es el horizonte de predicción (*Prediction Horizon*). Concretamente, este trabajo utiliza $HW = 8$ mediciones y $PH = 4$ mediciones, equivalente a una hora de horizonte de predicción a una frecuencia de muestreo de 15 minutos, un horizonte clínicamente relevante por ofrecer margen suficiente para ajustes terapéuticos preventivos [10].

Las redes LSTM [1] han sido ampliamente utilizadas para esta tarea por su capacidad de aprender la dinámica no lineal de la glucosa directamente de la secuencia bruta, superando a los modelos autorregresivos clásicos y a los modelos de aprendizaje automático con extracción manual de características en horizontes de 30 a 60 minutos [2, 11]. Si bien arquitecturas alternativas como las redes convolucionales temporales o los *Transformers* han mostrado resultados competitivos en la literatura reciente de *forecasting* glucémico, este trabajo no compara arquitecturas: utiliza un modelo LSTM ya validado como componente fijo del *pipeline* experimental, sobre el cual se evalúa exclusivamente el efecto de las transformaciones aplicadas a los datos de entrada.

Es importante precisar el alcance metodológico de este trabajo, que condiciona la revisión de técnicas que sigue en las secciones siguientes: el balanceo estudiado debe materializarse exclusivamente como una transformación de las ventanas de entrenamiento —generadas mediante ventana deslizante a partir de las series CGM originales— sin modificar en ningún caso la arquitectura del modelo LSTM, su función de pérdida, ni el procedimiento de entrenamiento o de validación cruzada *patient-wise* ya establecido. Esta restricción excluye de antemano cualquier técnica que opere mediante modificación del modelo (*in-processing*), como se discute en la sección 2.5.4.

2.3. Diferencias fisiológicas por sexo y edad en la dinámica glucémica

Antes de revisar las técnicas de balanceo demográfico, es necesario establecer la premisa fisiológica que justifica su pertinencia: si el sexo y la edad no tuvieran ninguna relación demostrable con la dinámica glucémica, equilibrar su representación en el conjunto de entrenamiento carecería de motivación clínica. La evidencia disponible indica lo contrario.

2.3.1. Diferencias por sexo

La DM1 presenta una predominancia masculina documentada en su incidencia, y la literatura ha identificado dimorfismo sexual en la homeostasis de la glucosa derivado de factores fisiológicos

como las hormonas sexuales, la distribución de masa grasa y muscular, y diferencias cromosómicas [12]. Conti et al. [13] evaluaron de forma prospectiva, en una cohorte de 176 adultos con DM1 tratados con sistemas de circuito cerrado híbrido avanzado, las diferencias por sexo en métricas CGM y variabilidad glucémica a lo largo de un año de seguimiento, encontrando diferencias sistemáticas en el control glucémico entre hombres y mujeres pese a recibir idéntica terapia. En la misma línea, un estudio publicado en *The Lancet Diabetes & Endocrinology* documentó disparidades por sexo entre el control glucémico percibido por el paciente y el control glucémico objetivo medido por CGM, señalando explícitamente la necesidad de investigar más a fondo el papel del sexo en la heterogeneidad fisiopatológica de la enfermedad [14].

2.3.2. Diferencias por edad

La dinámica glucémica difiere también de forma sustancial entre grupos etarios. En el extremo pediátrico y adolescente, un estudio sobre control glucémico en horario escolar encontró que las niñas presentaban un riesgo significativamente mayor de deterioro del control glucémico nocturno que los niños ($OR = 3.26$, $IC_{95} \% 1.17-9.72$) [15], lo que sugiere además una interacción entre edad y sexo en la dinámica glucémica. En el extremo de mayor edad, un estudio sobre 2.260 pacientes adultos con diabetes comparó el control glucémico entre pacientes de hasta 65 años y mayores de 65 años, encontrando que solo el 23.2% de los pacientes más jóvenes alcanzaba su objetivo individualizado de *Time in Range*, frente al 69% de los pacientes mayores de 65 años [16]. Esta diferencia tan marcada no solo confirma que la edad modula el comportamiento glucémico observable en CGM, sino que advierte de que la relación entre edad y control glucémico no es monótona ni trivial, reforzando la necesidad de un análisis empírico específico —como el que realiza este trabajo— en lugar de asumir un patrón de antemano.

En conjunto, esta evidencia fisiológica y clínica establece que tanto el sexo como la edad están asociados a patrones de dinámica glucémica distinguibles, lo que proporciona la motivación necesaria para estudiar si un modelo LSTM entrenado sobre una composición demográfica desequilibrada generaliza peor a los subgrupos infrarrepresentados, cuestión que se aborda en la sección siguiente desde la perspectiva del aprendizaje automático.

2.4. Desequilibrio demográfico en *datasets* clínicos y su impacto en el aprendizaje automático

2.4.1. Desequilibrio demográfico frente a desequilibrio de clase

El desarrollo de modelos de aprendizaje automático en contextos sanitarios plantea un problema distinto del desequilibrio de clases. Mientras que el desequilibrio de clases hace referencia a la proporción desigual entre las categorías de la variable objetivo, el desequilibrio demográfico se refiere a la proporción desigual de observaciones pertenecientes a distintos grupos poblacionales —sexo, edad, entre otros— dentro del conjunto de entrenamiento, con independencia de cuál sea la variable objetivo del modelo. Un modelo puede estar perfectamente equilibrado respecto a su variable de predicción y, sin embargo, sufrir un desequilibrio demográfico severo si la mayoría de las observaciones provienen de un único subgrupo. Cuando esto ocurre, los algoritmos de aprendizaje —especialmente las redes neuronales recurrentes, que ajustan sus parámetros minimizando una función de pérdida agregada sobre el conjunto de entrenamiento— tienden a ajustar sus representaciones internas preferentemente a la dinámica del subgrupo mayoritario, lo que puede traducirse en una degradación sistemática del rendimiento predictivo en los subgrupos infrarrepresentados [17, 18].

Una revisión sistemática publicada en el *Journal of Clinical Epidemiology* identificó múltiples mecanismos por los cuales el sesgo se introduce en modelos clínicos, señalando el reponderado

de muestras como una de las estrategias de mitigación más eficaces, con un 83 % de efectividad reportada en los estudios analizados [18]. Straw y Wu [17] demostraron en un estudio de predicción de enfermedad hepática que modelos entrenados sin considerar el desequilibrio por sexo presentaban disparidades de rendimiento sistemáticas entre subgrupos, replicando inequidades clínicas ya documentadas en la literatura médica.

2.4.2. Evidencia de disparidad de rendimiento por subgrupo demográfico en modelos clínicos

La pregunta de si la composición demográfica del entrenamiento afecta al rendimiento de un modelo predictivo ha sido investigada de forma directa en varios trabajos recientes, que constituyen la evidencia más relevante para motivar el presente TFM.

Wang et al. [19] realizaron el estudio más directamente comparable a la pregunta de investigación de este trabajo fuera del dominio específico de CGM. Analizando datos de más de 25.000 individuos con enfermedades crónicas —incluyendo diabetes— procedentes de siete *datasets* distintos, encontraron disparidades de rendimiento predictivo sistemáticas por sexo, favoreciendo la precisión en pacientes varones, y disparidades más acusadas por edad, con mejor precisión en pacientes jóvenes y un comportamiento inconsistente en pacientes de mayor edad, asociado a mayor complejidad de los datos en ese subgrupo. Un hallazgo central de este trabajo, directamente relevante para la interpretación de los resultados del presente TFM, es que **la paridad demográfica en la composición del *dataset* no garantiza por sí sola la paridad en el rendimiento del modelo resultante**: incluso conjuntos de datos demográficamente equilibrados pueden producir modelos con disparidad de rendimiento, lo que sugiere que el balanceo de representación es una condición necesaria pero no necesariamente suficiente.

Un segundo trabajo, centrado en pronóstico clínico de mortalidad y supervivencia oncológica, propuso un método de corrección de sesgo de representación (*double prioritized bias correction*) y lo comparó sistemáticamente contra ocho técnicas de muestreo existentes —incluyendo SMOTE y ADASYN— para mitigar disparidades de rendimiento por edad y raza [20]. Un resultado especialmente relevante de este trabajo es la observación explícita de que **las técnicas estándar de remuestreo de clase no están diseñadas para abordar sesgos de subgrupo demográfico**, ya que muestrean toda la clase minoritaria de la variable objetivo sin diferenciar a qué subgrupo demográfico pertenece cada observación. Esta distinción es exactamente la que separa las técnicas de balanceo de clase, ya extensamente estudiadas en la literatura de CGM, de las técnicas de balanceo demográfico que son objeto de este trabajo.

En el dominio específico de la predicción de glucosa mediante CGM, Ovalle et al. [21] constituyen la referencia más directamente comparable a la metodología de este trabajo: entrenaron modelos LSTM para predecir glucosa a 60 minutos a partir de datos CGM, evaluando la disparidad de rendimiento (medida en RMSE) entre subgrupos raciales en función de la composición demográfica del conjunto de entrenamiento. La arquitectura del problema —modelo LSTM, horizonte de predicción de 60 minutos, evaluación de disparidad por subgrupo demográfico derivada de la composición del entrenamiento— es metodológicamente equivalente a la del presente trabajo. La diferencia sustancial es la variable de estratificación: mientras que Ovalle et al. estudian la raza, este trabajo estudia el sexo y la edad, dos dimensiones demográficas no exploradas en dicho estudio y que, como se ha mostrado en la sección 2.3, cuentan con fundamento fisiológico propio independiente del de la raza.

2.5. Técnicas de mitigación del desequilibrio demográfico

Esta sección revisa las familias de técnicas disponibles en la literatura para corregir el desequilibrio en la representación de subgrupos demográficos dentro de un conjunto de entrenamiento, evaluando para cada una su fundamento teórico, su aplicabilidad a las dimensiones de sexo y edad, sus ventajas y limitaciones, el riesgo de introducir nuevos sesgos, y su compatibilidad con la restricción metodológica establecida en la sección 2.2.4: el balanceo debe operar exclusivamente sobre las ventanas de entrenamiento, sin modificar el modelo LSTM ni su procedimiento de entrenamiento.

2.5.1. Reponderado de muestras (*Reweighting*)

El reponderado, propuesto originalmente por Kamiran y Calders [22], es una técnica de preprocesado que asigna un peso distinto a cada observación del conjunto de entrenamiento en función de su pertenencia a un grupo demográfico, de modo que el grupo infrarrepresentado adquiere mayor influencia relativa en la función de pérdida durante el entrenamiento, sin necesidad de alterar físicamente el número de observaciones del *dataset*.

Para un atributo sensible $a \in A$ (p.ej. sexo) y una observación con dicho atributo, el peso de reponderado se calcula como el cociente entre la probabilidad teórica de observar esa combinación de grupo bajo independencia estadística y la probabilidad empírica observada en los datos:

$$w(a) = \frac{P_{\text{teórica}}(a)}{P_{\text{empírica}}(a)} = \frac{1/|A|}{n_a/N} \quad (2.1)$$

donde n_a es el número de observaciones del grupo a y N el número total de observaciones. Los grupos infrarrepresentados reciben así un peso $w(a) > 1$, mientras que los sobrerrepresentados reciben $w(a) < 1$ [23, 24].

La aplicabilidad a balanceo por sexo es directa: basta con calcular $w(\text{sexo})$ para cada paciente y propagar ese peso a sus ventanas de entrenamiento. La aplicabilidad a balanceo por edad es igualmente directa tras la discretización de la edad en grupos etarios, siguiendo el mismo procedimiento de cálculo.

Entre sus ventajas destaca que no requiere eliminar ni duplicar observaciones físicamente, por lo que preserva la totalidad de la información original y no introduce datos sintéticos ni redundancia exacta; es además computacionalmente trivial y fácilmente auditable. Su limitación principal es que su aplicación estándar requiere que el algoritmo de entrenamiento acepte un parámetro de peso por muestra (`sample_weight`) en la función de pérdida, lo cual constituye una modificación del proceso de entrenamiento. Dado que en este trabajo el balanceo debe producirse exclusivamente como una transformación de los datos de entrada —sin alterar el *script* de entrenamiento—, el reponderado puro **no es aplicable** salvo que se aproxime mediante remuestreo proporcional a los pesos calculados, lo que lo convierte funcionalmente en una variante de *oversampling/undersampling* guiado por pesos (sección 2.5.2).

El riesgo de introducir sesgos es bajo si los pesos se derivan directamente de las proporciones observadas; el riesgo principal es la inflación de varianza en la estimación del gradiente cuando los pesos son muy extremos, lo que puede desestabilizar el entrenamiento [25]. Esta técnica está ampliamente utilizada en el ecosistema de *IBM AI Fairness 360* [26] y ha sido evaluada extensamente como técnica de referencia en estudios de equidad clínica [18].

2.5.2. Remuestreo dirigido por grupo demográfico

El remuestreo dirigido por grupo constituye la contrapartida basada en remuestreo del reponderado: en lugar de asignar pesos, se duplican (*oversampling*) o eliminan (*undersampling*) físicamente observaciones del conjunto de entrenamiento hasta alcanzar la proporción demográfica

deseada [24, 22]. Esta es la familia de técnicas a la que pertenecen *Random Oversampling*, *Random Undersampling*, *Patient-Aware Undersampling*, *SMOTE* y *Jittering*, ya implementadas en este trabajo, aplicadas no sobre la distribución de clase glucémica sino sobre el número de ventanas pertenecientes a cada grupo demográfico (sexo o grupo de edad).

La aplicabilidad a balanceo por sexo y por edad es directa en ambos casos, ya que la técnica opera sobre cualquier variable de agrupación categórica, sin distinción conceptual entre sexo y grupo etario. Su principal ventaja es la compatibilidad total con un *pipeline* en el que el balanceo debe materializarse como una transformación de los datos de entrada sin modificar el proceso de entrenamiento posterior. Su limitación es estructural: el *undersampling* reduce el volumen de datos disponibles, mientras que el *oversampling* introduce redundancia exacta, con el consiguiente riesgo de sobreajuste.

El riesgo de introducir sesgos está documentado extensamente en la literatura [25, 27]: el remuestreo uniforme corrige la proporción global del grupo, pero puede mantener o incluso amplificar la concentración de las muestras añadidas en un subconjunto reducido de individuos del grupo minoritario, un riesgo de pseudo-replicación particularmente relevante en *datasets* de tamaño muestral reducido como DiaTrend (sección 2.2.3). Este es precisamente el motivo de la implementación de *Patient-Aware Undersampling* en este trabajo, que introduce un límite de contribución máxima por paciente al remuestreo. En el dominio específico de sesgo por edad, la revisión de Chu et al. [28] en *JMIR Aging* describe el caso de un estudio de neuroimagen en el que se duplicaron muestras de grupos etarios sobrerrepresentados para igualar la representación de grupos etarios minoritarios, si bien los propios autores señalan que un sesgo residual persistió tras el balanceo, una observación directamente relevante para la interpretación de los resultados de este trabajo. De forma convergente, Yan et al. [20] mostraron empíricamente que las técnicas de remuestreo estándar de clase (incluido SMOTE) ofrecen una mitigación limitada de la disparidad por subgrupo demográfico precisamente por no diferenciar el subgrupo dentro de la clase remuestreada, motivando la necesidad de aplicar el remuestreo directamente sobre la variable demográfica, como se hace en este trabajo.

2.5.3. Generación sintética condicionada mediante redes generativas adversarias temporales

TimeGAN [29] combina un *autoencoder* con una arquitectura GAN y un componente supervisado adicional que preserva explícitamente la dinámica temporal de las secuencias generadas, a diferencia de las GAN convencionales que tratan cada muestra como independiente. El modelo aprende conjuntamente un espacio latente, mediante codificador y decodificador, y una dinámica de transición en dicho espacio, optimizando simultáneamente una pérdida adversaria, una pérdida de reconstrucción y una pérdida supervisada de predicción del siguiente paso temporal. La aplicabilidad a balanceo por sexo y por edad requiere adaptación mediante generación condicionada: el generador debe condicionarse a la etiqueta de grupo demográfico del paciente de origen, de forma que las ventanas sintéticas generadas hereden las características temporales del subgrupo infrarrepresentado. A diferencia de la duplicación exacta (*oversampling*) o la interpolación lineal (SMOTE), esta familia de técnicas genera muestras sintéticas nuevas que preservan estadísticamente la autocorrelación y las propiedades distribucionales de la serie temporal original, reduciendo el riesgo de sobreajuste por redundancia. Su limitación principal es que requiere entrenar un modelo generativo adicional e independiente del modelo LSTM de predicción, lo que añade una capa sustancial de complejidad: definición de arquitectura, criterios de convergencia y validación de la plausibilidad fisiológica de las series generadas. El riesgo de *mode collapse* —en el que el generador produce variantes poco diversas de un número reducido de patrones— es una limitación documentada de forma recurrente en la literatura de GAN aplicadas a series temporales fisiológicas [30, 31].

El riesgo de introducir sesgos es relevante en este caso: si el conjunto de entrenamiento del propio modelo generativo está, a su vez, desequilibrado o es de tamaño reducido para el grupo minoritario, el modelo generativo puede aprender una representación pobre de la variabilidad real de ese grupo y generar muestras sintéticas poco diversas, amplificando en lugar de corregir el sesgo original. En el dominio de sensores corporales (*wearables*), TS-GAN [30] y un estudio de detección de estrés mediante GAN condicionales con arquitectura LSTM [31] confirman la viabilidad técnica de generar series fisiológicas sintéticas de calidad suficiente para aumentar el entrenamiento de modelos de clasificación, si bien ninguno de los dos trabajos evalúa explícitamente el sexo o la edad como variable de balanceo.

2.5.4. Aprendizaje de representaciones invariantes al atributo demográfico

En lugar de intervenir sobre los datos de entrada, esta familia de técnicas modifica el proceso de entrenamiento del propio modelo predictivo añadiendo un clasificador adversario que intenta predecir el atributo demográfico sensible a partir de la representación interna aprendida por la red. El modelo principal se entrena para minimizar simultáneamente su pérdida de predicción y maximizar la pérdida del adversario, de modo que la representación interna se vuelve progresivamente menos informativa respecto al atributo sensible [32, 33, 34].

Su aplicabilidad a balanceo por sexo y por edad es conceptualmente directa, dado que el atributo adversario puede ser cualquier variable categórica. Su ventaja es que no requiere alterar la composición del conjunto de datos, actuando directamente sobre el sesgo de representación interna del modelo, lo que en ciertos contextos resulta más eficaz que el preprocesado de datos puro [35]. Su limitación, sin embargo, es decisiva para este trabajo: es por definición una técnica de *in-processing*, que exige modificar la arquitectura y el proceso de entrenamiento del modelo LSTM, lo que la sitúa **fuera del alcance metodológico** de este trabajo, en el que el balanceo debe materializarse exclusivamente como una transformación previa de los datos de entrada sin modificar el *script* de entrenamiento existente (sección 2.2.4).

El entrenamiento adversario es además notoriamente inestable y puede degradar significativamente la utilidad predictiva del modelo si el término de regularización adversaria domina sobre la pérdida principal [35]. Louizos et al. [32] (*Variational Fair Autoencoder*) y Edwards y Storkey [33] introducen los fundamentos de esta familia de técnicas; en el ámbito médico se ha documentado su aplicación a detección de deterioro cognitivo leve a partir de datos de sensores mediante representaciones federadas adversarialmente depuradas, un caso de uso con cierta similitud estructural al de este trabajo por tratarse de datos de sensores fisiológicos [27].

2.5.5. Validación cruzada con muestreo estratificado por grupo demográfico

Esta técnica no corrige el desequilibrio dentro de un *fold*, sino que garantiza que la composición demográfica del conjunto de entrenamiento sea representativa de la composición demográfica global del *dataset*, evitando que el proceso de partición en *folds* introduzca o amplifique un desequilibrio adicional al ya presente en los datos originales [36].

Su aplicabilidad a balanceo por sexo y por edad es directa, aunque en el contexto de este trabajo es complementaria y no sustitutiva de las técnicas de balanceo propiamente dichas: el objetivo no es solo evitar un desequilibrio accidental introducido por la partición de *folds*, sino corregir activamente un desequilibrio estructural ya presente en el *dataset* original. Su principal ventaja es el bajo coste de implementación y un riesgo metodológico mínimo, ya que no introduce ninguna observación sintética ni elimina información real. Su limitación es que, por sí sola, no resuelve el problema central de este trabajo: si la población de pacientes está intrínsecamente desequilibrada en número de ventanas por grupo demográfico, una partición estratificada simplemente replicará ese desequilibrio de forma proporcional en cada *fold*, sin corregirlo.

Yang et al. [36] comparan explícitamente el muestreo aleatorio estratificado con estrategias de muestreo orientadas a la equidad en un *dataset* de cuidados intensivos, mostrando cómo la proporción de cada subgrupo demográfico en el conjunto de entrenamiento condiciona directamente la disparidad de rendimiento observada por subgrupo en edad, sexo y etnia.

2.5.6. Comparativa de técnicas

La tabla 2.2 resume las seis familias de técnicas revisadas según su tipo, su capacidad de conservar la dinámica temporal de las ventanas, su adecuación a las dimensiones de sexo y edad estudiadas en este trabajo, su complejidad de implementación y la evidencia disponible en el dominio sanitario.

Tabla 2.2: Comparativa de técnicas para la mitigación del desequilibrio demográfico.

Técnica	Tipo	Conserva dinámi- ca tem- poral	Sexo	Edad	Complejidad	Evidencia <i>Health-care</i>
Reponderado	Pre-procesado	Sí	Sí	Sí	Baja	Alta
Remuestreo dirigido por grupo	Pre-procesado	Depende	Sí	Sí	Baja	Alta
GAN temporal condicionada	Generativa	Sí	Sí	Sí	Alta	Media
Representaciones invariantes (adversarial)	In-processing	N/A	Sí	Sí	Alta	Alta
CV estratificada por grupo	Estructural	Sí	Sí	Sí	Baja	Media

2.5.7. Discusión y técnica seleccionada

Por completar

2.6. Brechas en la literatura y motivación del presente trabajo

La revisión anterior permite identificar tres brechas específicas que motivan y delimitan la contribución de este trabajo.

Primera brecha: ausencia de estudios de disparidad por sexo y edad específicamente en predicción de glucosa mediante CGM. La evidencia de disparidad de rendimiento por subgrupo demográfico está bien establecida en el ámbito amplio de las enfermedades crónicas [19] y, dentro del dominio específico de CGM y LSTM, existe un precedente metodológico directo centrado en disparidad racial [21]. Sin embargo, no se ha identificado en la revisión realizada ningún trabajo que evalúe sistemáticamente la disparidad de rendimiento por sexo o por edad en modelos LSTM de predicción de glucosa, pese a que la sección 2.3 establece que ambas variables están asociadas a diferencias fisiológicas demostrables en la dinámica glucémica. Esta es la brecha principal que este trabajo aborda.

Segunda brecha: las técnicas de remuestreo estándar no diferencian subgrupo demográfico dentro de la clase remuestreada. Yan et al. [20] demostraron empíricamente que técnicas de remuestreo ampliamente utilizadas, incluyendo SMOTE y ADASYN, ofrecen una mitigación limitada de la disparidad de rendimiento por subgrupo demográfico precisamente porque fueron diseñadas para corregir el desequilibrio de la variable objetivo, no la composición demográfica del conjunto de entrenamiento. Este trabajo aplica explícitamente estas técnicas sobre la variable demográfica —sexo o grupo de edad— en lugar de sobre la variable objetivo, una distinción metodológica que la literatura revisada señala como necesaria pero que rara vez se implementa y evalúa de forma sistemática.

Tercera brecha: ausencia de balanceo demográfico a nivel de ventana temporal en literatura de *fairness* clínica. La literatura de equidad algorítmica en salud opera mayoritariamente sobre observaciones tabulares independientes, en las que cada fila corresponde a un paciente o a un episodio clínico discreto [19, 20, 18]. En el contexto de series temporales generadas mediante ventana deslizante, la unidad de balanceo no es el paciente sino la ventana, y un mismo paciente con una serie temporal larga puede generar órdenes de magnitud más ventanas que otro paciente con una serie corta, incluso perteneciendo ambos al mismo grupo demográfico nominal. No se ha identificado en la literatura revisada un tratamiento explícito de esta distinción entre balanceo a nivel de paciente y balanceo a nivel de ventana en el contexto de predicción de series temporales clínicas.

Este trabajo se sitúa en la intersección no cubierta de estas tres líneas: aplica un conjunto sistemático de técnicas de balanceo demográfico —algunas ya consolidadas en la literatura de *fairness* general, adaptadas aquí a la unidad de ventana temporal— para evaluar empíricamente, en tres *datasets* públicos de DM1 y mediante un modelo LSTM ya validado, si la corrección de la composición demográfica del conjunto de entrenamiento por sexo y por edad mejora el rendimiento predictivo y reduce la disparidad entre subgrupos en la predicción de glucosa a una hora vista.

Capítulo 3

Desarrollo del TFM

En esta parte describirás el trabajo desarrollado, y utilizarás las secciones que creas conveniente para explicarlo.

3.1. Cómo colocar tablas y figuras

Por ejemplo, en esta sección se explica como colocar tablas y figuras en $\text{\LaTeX}$. Al escribir un documento en $\text{\LaTeX}$, es importante saber cómo posicionar correctamente imágenes y tablas. $\text{\LaTeX}$ ofrece varias opciones para controlar la posición de estos elementos en la página. Por ejemplo, se puede utilizar las opciones “h”, “t”, “b”, “p”, “!” para indicar que la imagen debe ser colocada “aquí” (*here*), en la parte superior (*top*) o inferior (*bottom*) de la página, en una página separada (*page*) o en la posición exacta especificada (!), respectivamente.

Tanto las imágenes como las tablas son consideradas como “objetos flotantes” en $\text{\LaTeX}$. Esto significa que $\text{\LaTeX}$ intentará posicionarlos en la página de la mejor manera posible, teniendo en cuenta el flujo del texto y el espacio disponible. En algunos casos, esto puede resultar en un posicionamiento inesperado de los objetos flotantes.

Para tener un mayor control sobre el flotado de imágenes y tablas, se pueden utilizar los paquetes `\usepackage{float}` y `\usepackage{caption}`. Estos paquetes ofrecen opciones adicionales para controlar la posición y el comportamiento de los objetos flotantes. Por ejemplo, se puede utilizar la opción “H” para forzar a $\text{\LaTeX}$ a colocar el objeto flotante exactamente en la posición especificada, sin ajustes.

Revisa esta web para más información: https://www.overleaf.com/learn/latex/Positioning_images_and_tables.

Capítulo 4

Resultados y discusión

Aquí se discutirán los resultados, tablas de datos y gráficas.

Por ejemplo, la Tabla 4.1, muestra un ejemplo de como introducir tablas de forma limpia en el texto.

Tabla 4.1: Mi tabla grande con cabeceras en negrita

Categoría	Valor 1	Valor 2	Valor 3
Fruta 1	5	10	15
Fruta 2	8	12	18
Verdura 1	3	6	9
Verdura 2	4	7	11
Bebida 1	1	2	3
Bebida 2	6	9	12

Fíjate que tanto tablas como imágenes, deben estar previamente referenciadas en el texto, y no deben separarse mucho de éste. Fíjate también en como se crean títulos reducidos para que el texto del pie de tabla no ocupe demasiado en el índice.

Las tablas enormes como la Tabla 4.2, deben intentar colocarse en una página aparte.

Lo mismo se puede hacer con las gráficas. Pero ten cuidado de que las gráficas no se vayan lejos del texto tampoco. Vamos a poner un ejemplo para que no nos moleste la tabla anterior, vamos a forzar una nueva página.

Tabla 4.2: Mfi tabla enorme de poblaci3n

Categoría	Valor 1	Valor 2	Valor 3	Valor 4	Valor 5	Valor 6	Valor 7	Valor 8	Valor 9	Valor 10
Ecuador	5	10	15	20	25	30	35	40	45	
Nicaragua	8	12	18	24	30	36	42	48	54	
Honduras	3	6	9	12	15	18	21	24	27	
Argentina	4	7	11	15	19	23	27	31	35	
Venezuela	1	2	3	4	5	6	7	8	9	
Colombia	6	9	12	15	18	21	24	27	30	
Chile	2	4	6	8	10	12	14	16	18	
España	7	11	15	19	23	27	31	35	39	

Se deben evitar imágenes “por poner”¹, como la Figura 4.1. Que es un logotipo.



Figura 4.1: Mi logo

Por ejemplo, la Figura 4.2 sí que está correcta, y va de la misma forma que la tabla, y ahora está cerca del texto. Hemos sacrificado un poco de espacio al final de la página anterior a cambio de acercar la figura al texto. Esto solo debe hacerse en casos en que tengamos tablas y figuras que ocupen la página completa.




Figura 4.2: Lista de distribuciones: Aquí iría una descripción de la figura para cada fila o columna, explicando los parámetros. Fíjate como el pie está recortado en el índice para que no sea extremadamente largo. Si hay una fuente, la podemos colocar aquí: <https://drive.google.com/file/d/14YN87TAF60Qq6JIuZiUz3YHn-6Pz8KHm/view?usp=sharing>

El tipo de extensiones ya está definido, así que no deben usarse a la hora de referenciar imágenes. Por defecto el orden es:

1. PDF: Son gráficos vectoriales con máxima calidad, bueno para esquemas y tablas.
2. PNG: Son gráficos que no pierden calidad, aunque son gráficos *raster* o matriciales. Utilízalos cuando los tonos sean planos, como en esquemas, en sustitución de los PDF cuando no

¹Por cierto, fíjate en cómo van las comillas. Aunque es mejor usar cursivas. Las palabras en inglés, por ejemplo, deberían ir en *cursiva*, como por ejemplo *buffer*.

tenemos opción a usar gráficos vectoriales.

3. JPEG: Con extensión **.jpg**, se suelen usar cuando son fotografías, principalmente, ya que pueden contener *artifacts*.

Capítulo 5

Conclusiones

Debes describir las conclusiones generales del trabajo, pero también debes cubrir qué objetivos se han cubierto. Para ello revisa la sección de [Objetivos](#) (Sección 1.2). Por último cierra el trabajo, y si tienes planes de continuar, menciona los trabajos futuros.

Bibliografía

- [1] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [2] S. Mirshekarian, H. Shen, R. Bunescu, and C. Marling, “Lstms and neural attention models for blood glucose prediction: comparative experiments on real and synthetic data,” 2019.
- [3] M. A. Atkinson, G. S. Eisenbarth, and A. W. Michels, “Type 1 diabetes,” *The Lancet*, vol. 383, no. 9911, pp. 69–82, 2014.
- [4] B. Kovatchev, “Metrics for glycaemic control — from HbA1c to continuous glucose monitoring,” *Nature Reviews Endocrinology*, vol. 13, no. 7, pp. 425–436, 2019.
- [5] D. C. Klonoff, D. Ahn, and A. Drincic, “Continuous glucose monitoring: a review of the technology and clinical use,” *Diabetes Research and Clinical Practice*, vol. 133, pp. 178–192, 2017.
- [6] R. J. A. Little and D. B. Rubin, *Statistical Analysis with Missing Data*. Wiley, 3rd ed., 2019.
- [7] Q. Sun, T. S. Bhatt, R. Nambhore, *et al.*, “DIATREND: A multivariate longitudinal clinical dataset of type 1 diabetes patients to advance glucose forecasting,” *Scientific Data*, vol. 10, no. 1, p. 612, 2023.
- [8] G. Aleppo, K. L. Ruedy, T. T. Riddlesworth, *et al.*, “REPLACE-BG: A randomized trial comparing continuous glucose monitoring with and without routine blood glucose monitoring in adults with well-controlled type 1 diabetes,” *Diabetes Care*, vol. 40, no. 4, pp. 538–545, 2017.
- [9] J. D. Díaz-López, R. Capel-Delgado, *et al.*, “T1diabetesgranada dataset,” 2023.
- [10] G. Sparacino, F. Zanderigo, S. Corazza, *et al.*, “Glucose concentration can be predicted ahead in time from continuous glucose monitoring sensor time-series,” *IEEE Transactions on Biomedical Engineering*, vol. 54, no. 5, pp. 931–937, 2007.
- [11] S. Oviedo, J. Vehí, R. Calm, and J. Armengol, “A review of personalized blood glucose prediction strategies for T1DM patients,” *International Journal for Numerical Methods in Biomedical Engineering*, vol. 33, no. 6, 2017.
- [12] F. Mauvais-Jarvis *et al.*, “Sex differences in glucose homeostasis,” *Sex and Gender Effects in Pharmacology, Handbook of Experimental Pharmacology*, 2023.
- [13] M. Conti, I. Gironi, E. Meneghini, E. Mion, G. D. Vieste, F. Bertuzzi, and B. Pintaudi, “Sex differences in continuous glucose monitoring metrics and glucose variability in subjects with

- type 1 diabetes treated with advanced hybrid closed loop therapy: An observational, retrospective, one-year follow-up study,” *Journal of Clinical Medicine*, vol. 14, no. 24, p. 8823, 2025.
- [14] A. A. van der Heijden *et al.*, “Sex-based disparities in perceived versus objective glycaemic control in type 1 diabetes: a cross-sectional cohort study,” *The Lancet Diabetes & Endocrinology*, 2025. PIIS2213-8587(25)00136-6.
 - [15] F. Deng *et al.*, “Deterioration in glycemic control on schooldays among children and adolescents with type 1 diabetes: a continuous glucose monitoring-based study,” *PMC9768037*, 2022.
 - [16] M. Nwokolo *et al.*, “Glycaemic outcomes in people living with diabetes under 65 and over 65 years old using an intermittently scanned continuous glucose monitoring system,” *Journal of Diabetes Science and Technology*, 2024. PMC11337186.
 - [17] I. Straw and H. Wu, “Investigating for bias in healthcare algorithms: a sex-stratified analysis of supervised machine learning models in liver disease prediction,” *BMJ Health & Care Informatics*, vol. 29, no. 1, 2022.
 - [18] M. A. R. Lara *et al.*, “Sociodemographic bias in clinical machine learning models: a scoping review of algorithmic bias instances and mechanisms,” *Journal of Clinical Epidemiology*, 2024.
 - [19] Y. Wang *et al.*, “Disparate model performance and stability in machine learning clinical support for diabetes and heart diseases,” 2024. arXiv:2412.19495.
 - [20] C. Yan *et al.*, “Subpopulation-specific machine learning prognosis for underrepresented patients with double prioritized bias correction,” *Communications Medicine*, vol. 2, p. 121, 2022.
 - [21] A. O. Aguilar *et al.*, “Racial disparities in continuous glucose monitoring-based 60-min glucose predictions among people with type 1 diabetes,” *medRxiv preprint*, 2024.
 - [22] F. Kamiran and T. Calders, “Data preprocessing techniques for classification without discrimination,” *Knowledge and Information Systems*, vol. 33, no. 1, pp. 1–33, 2012.
 - [23] I. Žliobaitė, “Measuring discrimination in algorithmic decision making,” *Data Mining and Knowledge Discovery*, vol. 31, no. 4, pp. 1060–1089, 2017.
 - [24] J. Wiśniewski and P. Biecek, “fairmodels: A flexible tool for bias detection, visualization, and mitigation,” 2021. arXiv:2104.00507.
 - [25] E. Krasanakis, E. Spyromitros-Xioufis, S. Papadopoulos, and Y. Kompatsiaris, “Adaptive sensitive reweighting to mitigate bias in fairness-aware classification,” in *Proceedings of the 2018 World Wide Web Conference (WWW)*, 2018.
 - [26] R. K. E. Bellamy *et al.*, “Ai fairness 360: An extensible toolkit for detecting, understanding, and mitigating unwanted algorithmic bias,” 2018. arXiv:1810.01943.
 - [27] M. A. Ahmad *et al.*, “Algorithm fairness in ai for medicine and healthcare,” 2021. arXiv:2110.00603.
 - [28] C. Chu, S. Donato-Woodger, S. S. Khan, T. Shi, K. Leslie, S. Abbasgholizadeh-Rahimi, R. Nyrup, and A. Grenier, “Strategies to mitigate age-related bias in machine learning: Scoping review,” *JMIR Aging*, vol. 7, p. e53564, 2024.

- [29] J. Yoon, D. Jarrett, and M. van der Schaar, “Time-series generative adversarial networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.
- [30] H. Dong *et al.*, “Ts-gan: Time-series gan for sensor-based health data augmentation,” *ACM Transactions on Computing for Healthcare*, 2023.
- [31] J. Dahmen *et al.*, “A conditional gan for generating time series data for stress detection in wearable physiological sensor data,” *Sensors*, vol. 22, no. 16, p. 5969, 2022.
- [32] C. Louizos, K. Swersky, Y. Li, M. Welling, and R. Zemel, “The variational fair autoencoder,” in *International Conference on Learning Representations (ICLR)*, 2016.
- [33] H. Edwards and A. Storkey, “Censoring representations with an adversary,” in *International Conference on Learning Representations (ICLR)*, 2016.
- [34] R. Zemel, Y. Wu, K. Swersky, T. Pitassi, and C. Dwork, “Learning fair representations,” in *Proceedings of the 30th International Conference on Machine Learning (ICML)*, 2013.
- [35] M. Du, F. Yang, N. Zou, and X. Hu, “Fairness in deep learning: A computational perspective,” 2019. arXiv:1908.08843.
- [36] J. Yang *et al.*, “Dataset representativeness and downstream task fairness,” 2024. arXiv:2407.00170.

Apéndice A

Ejemplo de anexo: Planificación y gestión del proyecto (opcional)

El Apéndice A puede incluirse como recomendación si se ha realizado un proyecto de tipo práctico práctico de desarrollo del software.

De forma general se puede incluir la especificación requerimientos del proyecto, la información sobre stakeholders del proyecto, la justificación (interés, oportunidad, coste/beneficio...), etc.

En cuanto a la planificación: se indicarán las diferentes tareas a desarrollar durante el proyecto ordenadas cronológicamente.

En cuanto a la descripción: breve definición de las tareas indicando su relación con los requisitos del proyecto, método de trabajo, tecnologías a utilizar para desarrollar cada tarea, posibles obstáculos y riesgos.

En cuanto a la validación: qué método se utilizará para validar el proyecto (si se trata de desarrollo de software, indicando métricas referidas a `code coverage`", etc., pruebas unitarias, etc.).

En cuanto al estudio de costes y sostenibilidad: se indicarán las horas de programador necesarias para llevarlo a cabo, gasto en recursos, bibliografía, tiempos de conexión, etc.

En cuanto a la temporización, lo suyo es un Diagrama de Gantt donde quede claro el tiempo invertido en la realización de cada una de las tareas y su secuenciación/entrelazamiento a los largo de los meses de realización del proyecto.

Finalmente se acabará justificando la sostenibilidad de los productos software generados en cuanto a costes de prueba y mantenimiento del software.

Una posible estructuración de la gestión y planificación del proyecto podría ser en las siguientes subsecciones:

A.1. Metodología/Ciclo de vida

A.2. Herramientas y plataformas utilizadas para el desarrollo del proyecto

A.3. Costes del proyecto

A.4. Gestión del proyecto. Planificación temporal. Diagrama de Gantt

A.5. Texto añadido

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras

nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetur at, consectetur sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

Morbi luctus, wisi viverra faucibus pretium, nibh est placerat odio, nec commodo wisi enim eget quam. Quisque libero justo, consectetur a, feugiat vitae, porttitor eu, libero. Suspendisse sed mauris vitae elit sollicitudin malesuada. Maecenas ultricies eros sit amet ante. Ut venenatis velit. Maecenas sed mi eget dui varius euismod. Phasellus aliquet volutpat odio. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque sit amet pede ac sem eleifend consectetur. Nullam elementum, urna vel imperdiet sodales, elit ipsum pharetra ligula, ac pretium ante justo a nulla. Curabitur tristique arcu eu metus. Vestibulum lectus. Proin mauris. Proin eu nunc eu urna hendrerit faucibus. Aliquam auctor, pede consequat laoreet varius, eros tellus scelerisque quam, pellentesque hendrerit ipsum dolor sed augue. Nulla nec lacus.

Suspendisse vitae elit. Aliquam arcu neque, ornare in, ullamcorper quis, commodo eu, libero. Fusce sagittis erat at erat tristique mollis. Maecenas sapien libero, molestie et, lobortis in, sodales eget, dui. Morbi ultrices rutrum lorem. Nam elementum ullamcorper leo. Morbi dui. Aliquam sagittis. Nunc placerat. Pellentesque tristique sodales est. Maecenas imperdiet lacinia velit. Cras non urna. Morbi eros pede, suscipit ac, varius vel, egestas non, eros. Praesent malesuada, diam id pretium elementum, eros sem dictum tortor, vel consectetur odio sem sed wisi.

Sed feugiat. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Ut pellentesque augue sed urna. Vestibulum diam eros, fringilla et, consectetur eu, nonummy id, sapien. Nullam at lectus. In sagittis ultrices mauris. Curabitur malesuada erat sit amet massa. Fusce blandit. Aliquam erat volutpat. Aliquam euismod. Aenean vel lectus. Nunc imperdiet justo nec dolor.

Etiam euismod. Fusce facilisis lacinia dui. Suspendisse potenti. In mi erat, cursus id, nonummy sed, ullamcorper eget, sapien. Praesent pretium, magna in eleifend egestas, pede pede pretium lorem, quis consectetur tortor sapien facilisis magna. Mauris quis magna varius nulla scelerisque imperdiet. Aliquam non quam. Aliquam porttitor quam a lacus. Praesent vel arcu ut tortor cursus volutpat. In vitae pede quis diam bibendum placerat. Fusce elementum convallis neque. Sed dolor orci, scelerisque ac, dapibus nec, ultricies ut, mi. Duis nec dui quis leo sagittis commodo.

Aliquam lectus. Vivamus leo. Quisque ornare tellus ullamcorper nulla. Mauris porttitor pharetra tortor. Sed fringilla justo sed mauris. Mauris tellus. Sed non leo. Nullam elementum, magna in cursus sodales, augue est scelerisque sapien, venenatis congue nulla arcu et pede. Ut suscipit enim vel sapien. Donec congue. Maecenas urna mi, suscipit in, placerat ut, vestibulum ut, massa. Fusce ultrices nulla et nisl.

Etiam ac leo a risus tristique nonummy. Donec dignissim tincidunt nulla. Vestibulum rhoncus molestie odio. Sed lobortis, justo et pretium lobortis, mauris turpis condimentum augue, nec ultricies nibh arcu pretium enim. Nunc purus neque, placerat id, imperdiet sed, pellentesque nec, nisl. Vestibulum imperdiet neque non sem accumsan laoreet. In hac habitasse platea dictumst. Etiam condimentum facilisis libero. Suspendisse in elit quis nisl aliquam dapibus. Pellentesque auctor sapien. Sed egestas sapien nec lectus. Pellentesque vel dui vel neque bibendum viverra. Aliquam porttitor nisl nec pede. Proin mattis libero vel turpis. Donec rutrum mauris et libero. Proin euismod porta felis. Nam lobortis, metus quis elementum commodo, nunc lectus elementum mauris, eget vulputate ligula tellus eu neque. Vivamus eu dolor.

Nulla in ipsum. Praesent eros nulla, congue vitae, euismod ut, commodo a, wisi. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Aenean nonummy magna non leo. Sed felis erat, ullamcorper in, dictum non, ultricies ut, lectus. Proin vel arcu a odio lobortis euismod. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Proin ut est. Aliquam odio. Pellentesque massa turpis, cursus eu, euismod nec, tempor congue, nulla. Duis viverra gravida mauris. Cras tincidunt. Curabitur eros ligula, varius ut, pulvinar in, cursus faucibus, augue.

Apéndice B

Ejemplo de anexo: Innovación (opcional)

El Apéndice B puede ser recomendable incluir en los casos en los que se realice un proyecto práctico de desarrollo del software en los que se quiera hacer referencia a la posible innovación en el marco empresarial.

En caso positivo, se recomienda una posible estructuración en las siguientes subsecciones:

B.1. Estudio del Mercado

Contenido del estudio del mercado

B.1.1. Segmentos de Clientes

Contenido sobre los segmentos de clientes

B.1.2. Competidores

Información sobre los competidores

B.2. Propuesta de Valor

Descripción de la propuesta de valor

B.3. Recursos Clave

Enumeración de los recursos clave

B.4. Actividades Clave

Descripción de las actividades clave

B.5. Socios y Alianzas Clave

Detalles sobre socios y alianzas

B.6. Estructura de Costes Prevista

Desglose de los costes estimados. Incluir aquí la estimación presupuestaria de Costes

B.7. Vías de Ingresos

Estrategias para generar ingresos

Incluir aquí la proyección de ingresos a lo largo de los primeros tres años. Incluir las vías o fuentes de financiación.

B.8. Canales de Distribución

Descripción de los canales de distribución

B.9. Relación con los Clientes

Cómo se relacionará con los clientes

B.10. Descripción del Producto Mínimo Viable

Detalles sobre el producto mínimo viable

B.11. Roadmap de Desarrollo

Planificación del desarrollo

B.12. Aspectos Legales

Consideraciones legales, licencias y patentes

B.13. Texto añadido

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis

natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetur at, consectetur sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

Morbi luctus, wisi viverra faucibus pretium, nibh est placerat odio, nec commodo wisi enim eget quam. Quisque libero justo, consectetur a, feugiat vitae, porttitor eu, libero. Suspendisse sed mauris vitae elit sollicitudin malesuada. Maecenas ultricies eros sit amet ante. Ut venenatis velit. Maecenas sed mi eget dui varius euismod. Phasellus aliquet volutpat odio. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque sit amet

pede ac sem eleifend consectetur. Nullam elementum, urna vel imperdiet sodales, elit ipsum pharetra ligula, ac pretium ante justo a nulla. Curabitur tristique arcu eu metus. Vestibulum lectus. Proin mauris. Proin eu nunc eu urna hendrerit faucibus. Aliquam auctor, pede consequat laoreet varius, eros tellus scelerisque quam, pellentesque hendrerit ipsum dolor sed augue. Nulla nec lacus.

Suspendisse vitae elit. Aliquam arcu neque, ornare in, ullamcorper quis, commodo eu, libero. Fusce sagittis erat at erat tristique mollis. Maecenas sapien libero, molestie et, lobortis in, sodales eget, dui. Morbi ultrices rutrum lorem. Nam elementum ullamcorper leo. Morbi dui. Aliquam sagittis. Nunc placerat. Pellentesque tristique sodales est. Maecenas imperdiet lacinia velit. Cras non urna. Morbi eros pede, suscipit ac, varius vel, egestas non, eros. Praesent malesuada, diam id pretium elementum, eros sem dictum tortor, vel consectetur odio sem sed wisi.

Sed feugiat. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Ut pellentesque augue sed urna. Vestibulum diam eros, fringilla et, consectetur eu, nonummy id, sapien. Nullam at lectus. In sagittis ultrices mauris. Curabitur malesuada erat sit amet massa. Fusce blandit. Aliquam erat volutpat. Aliquam euismod. Aenean vel lectus. Nunc imperdiet justo nec dolor.

Etiam euismod. Fusce facilisis lacinia dui. Suspendisse potenti. In mi erat, cursus id, nonummy sed, ullamcorper eget, sapien. Praesent pretium, magna in eleifend egestas, pede pede pretium lorem, quis consectetur tortor sapien facilisis magna. Mauris quis magna varius nulla scelerisque imperdiet. Aliquam non quam. Aliquam porttitor quam a lacus. Praesent vel arcu ut tortor cursus volutpat. In vitae pede quis diam bibendum placerat. Fusce elementum convallis neque. Sed dolor orci, scelerisque ac, dapibus nec, ultricies ut, mi. Duis nec dui quis leo sagittis commodo. Aliquam lectus. Vivamus leo. Quisque ornare tellus ullamcorper nulla. Mauris porttitor pharetra tortor. Sed fringilla justo sed mauris. Mauris tellus. Sed non leo. Nullam elementum, magna in cursus sodales, augue est scelerisque sapien, venenatis congue nulla arcu et pede. Ut suscipit enim vel sapien. Donec congue. Maecenas urna mi, suscipit in, placerat ut, vestibulum ut, massa. Fusce ultrices nulla et nisl.

Etiam ac leo a risus tristique nonummy. Donec dignissim tincidunt nulla. Vestibulum rhoncus molestie odio. Sed lobortis, justo et pretium lobortis, mauris turpis condimentum augue, nec ultricies nibh arcu pretium enim. Nunc purus neque, placerat id, imperdiet sed, pellentesque nec, nisl. Vestibulum imperdiet neque non sem accumsan laoreet. In hac habitasse platea dictumst. Etiam condimentum facilisis libero. Suspendisse in elit quis nisl aliquam dapibus. Pellentesque auctor sapien. Sed egestas sapien nec lectus. Pellentesque vel dui vel neque bibendum viverra. Aliquam porttitor nisl nec pede. Proin mattis libero vel turpis. Donec rutrum mauris et libero. Proin euismod porta felis. Nam lobortis, metus quis elementum commodo, nunc lectus elementum mauris, eget vulputate ligula tellus eu neque. Vivamus eu dolor.

Nulla in ipsum. Praesent eros nulla, congue vitae, euismod ut, commodo a, wisi. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Aenean nonummy magna non leo. Sed felis erat, ullamcorper in, dictum non, ultricies ut, lectus. Proin vel arcu a odio lobortis euismod. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Proin ut est. Aliquam odio. Pellentesque massa turpis, cursus eu, euismod nec, tempor congue, nulla. Duis viverra gravida mauris. Cras tincidunt. Curabitur eros ligula, varius ut, pulvinar in, cursus faucibus, augue.

Apéndice C

Ejemplo de anexo: Manual de usuario (opcional)

Este es un apéndice opcional, en caso de que quieras añadir un manual de usuario del software realizado.

Puedes incluir tantos capítulos de Anexos como te haga falta. Si no tienes anexos, puedes comentar las líneas en el fichero **tfm.tex**.

C.1. Texto añadido

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat.

Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetur at, consectetur sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

Morbi luctus, wisi viverra faucibus pretium, nibh est placerat odio, nec commodo wisi enim eget quam. Quisque libero justo, consectetur a, feugiat vitae, porttitor eu, libero. Suspendisse sed mauris vitae elit sollicitudin malesuada. Maecenas ultricies eros sit amet ante. Ut venenatis velit. Maecenas sed mi eget dui varius euismod. Phasellus aliquet volutpat odio. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque sit amet pede ac sem eleifend consectetur. Nullam elementum, urna vel imperdiet sodales, elit ipsum pharetra ligula, ac pretium ante justo a nulla. Curabitur tristique arcu eu metus. Vestibulum lectus. Proin mauris. Proin eu nunc eu urna hendrerit faucibus. Aliquam auctor, pede consequat laoreet varius, eros tellus scelerisque quam, pellentesque hendrerit ipsum dolor sed augue. Nulla nec lacus.

Suspendisse vitae elit. Aliquam arcu neque, ornare in, ullamcorper quis, commodo eu, libero. Fusce sagittis erat at erat tristique mollis. Maecenas sapien libero, molestie et, lobortis in, sodales eget, dui. Morbi ultrices rutrum lorem. Nam elementum ullamcorper leo. Morbi dui. Aliquam sagittis. Nunc placerat. Pellentesque tristique sodales est. Maecenas imperdiet lacinia velit. Cras non urna. Morbi eros pede, suscipit ac, varius vel, egestas non, eros. Praesent malesuada, diam id pretium elementum, eros sem dictum tortor, vel consectetur odio sem sed wisi.

Sed feugiat. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Ut pellentesque augue sed urna. Vestibulum diam eros, fringilla et, consectetur eu, no-

nummy id, sapien. Nullam at lectus. In sagittis ultrices mauris. Curabitur malesuada erat sit amet massa. Fusce blandit. Aliquam erat volutpat. Aliquam euismod. Aenean vel lectus. Nunc imperdiet justo nec dolor.

Etiam euismod. Fusce facilisis lacinia dui. Suspendisse potenti. In mi erat, cursus id, nonummy sed, ullamcorper eget, sapien. Praesent pretium, magna in eleifend egestas, pede pede pretium lorem, quis consectetur tortor sapien facilisis magna. Mauris quis magna varius nulla scelerisque imperdiet. Aliquam non quam. Aliquam porttitor quam a lacus. Praesent vel arcu ut tortor cursus volutpat. In vitae pede quis diam bibendum placerat. Fusce elementum convallis neque. Sed dolor orci, scelerisque ac, dapibus nec, ultricies ut, mi. Duis nec dui quis leo sagittis commodo. Aliquam lectus. Vivamus leo. Quisque ornare tellus ullamcorper nulla. Mauris porttitor pharetra tortor. Sed fringilla justo sed mauris. Mauris tellus. Sed non leo. Nullam elementum, magna in cursus sodales, augue est scelerisque sapien, venenatis congue nulla arcu et pede. Ut suscipit enim vel sapien. Donec congue. Maecenas urna mi, suscipit in, placerat ut, vestibulum ut, massa. Fusce ultrices nulla et nisl.

Etiam ac leo a risus tristique nonummy. Donec dignissim tincidunt nulla. Vestibulum rhoncus molestie odio. Sed lobortis, justo et pretium lobortis, mauris turpis condimentum augue, nec ultricies nibh arcu pretium enim. Nunc purus neque, placerat id, imperdiet sed, pellentesque nec, nisl. Vestibulum imperdiet neque non sem accumsan laoreet. In hac habitasse platea dictumst. Etiam condimentum facilisis libero. Suspendisse in elit quis nisl aliquam dapibus. Pellentesque auctor sapien. Sed egestas sapien nec lectus. Pellentesque vel dui vel neque bibendum viverra. Aliquam porttitor nisl nec pede. Proin mattis libero vel turpis. Donec rutrum mauris et libero. Proin euismod porta felis. Nam lobortis, metus quis elementum commodo, nunc lectus elementum mauris, eget vulputate ligula tellus eu neque. Vivamus eu dolor.

Nulla in ipsum. Praesent eros nulla, congue vitae, euismod ut, commodo a, wisi. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Aenean nonummy magna non leo. Sed felis erat, ullamcorper in, dictum non, ultricies ut, lectus. Proin vel arcu a odio lobortis euismod. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Proin ut est. Aliquam odio. Pellentesque massa turpis, cursus eu, euismod nec, tempor congue, nulla. Duis viverra gravida mauris. Cras tincidunt. Curabitur eros ligula, varius ut, pulvinar in, cursus faucibus, augue.

