



UNIVERSIDAD DE GRANADA

TRABAJO FIN DE MÁSTER
MASTER EN CIENCIA DE DATOS

Compensating for Patient Heterogeneity Bias

in Glucose Prediction Models via Data Balancing

Autor

Juan Ricardo Hernández Sánchez-Agosta (estudiante)

Director/es

Oresti Baños Legrán (tutor 1)

Claudia Villalonga Palliser (tutor 2)



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE TELECOMUNICACIÓN

Granada, 3 de agosto de 2026



Compensating for Patient Heterogeneity Bias

in Glucose Prediction Models via Data Balancing

Autor

Juan Ricardo Hernández Sánchez-Agesta (estudiante)

Director/es

Oresti Baños Legrán (tutor 1)
Claudia Villalonga Palliser (tutor 2)

Compensating for Patient Heterogeneity Bias: in Glucose Prediction Models via Data Balancing

Juan Ricardo Hernández Sánchez-Agosta (estudiante)

Palabras clave: diabetes mellitus tipo 1, predicción de glucosa, monitorización continua de glucosa (CGM), LSTM, balanceo demográfico, equidad algorítmica, series temporales, validación cruzada por grupos.

Resumen

La predicción de glucosa en sangre es una herramienta clave en la gestión de la diabetes mellitus tipo 1 (DM1), ya que permite anticipar episodios de hipoglucemia e hiperglucemia y mejorar la calidad de vida de los pacientes. Los modelos de aprendizaje profundo basados en redes LSTM (*Long Short-Term Memory*) han demostrado un rendimiento sólido en este dominio gracias a su capacidad de capturar dependencias temporales complejas en señales de monitorización continua de glucosa (CGM). Sin embargo, la heterogeneidad demográfica de las cohortes disponibles —en particular las diferencias de edad y sexo— puede introducir sesgos sistemáticos en el entrenamiento, comprometiendo la equidad y la generalización de estos modelos hacia subgrupos infrarrepresentados.

Este Trabajo Fin de Máster parte de la hipótesis de que equilibrar la composición demográfica del conjunto de entrenamiento mejora el rendimiento clínico de un modelo LSTM de predicción de glucosa, especialmente para los subgrupos minoritarios. Para contrastarla, se diseña e implementa un *pipeline* experimental de balanceo aplicado exclusivamente a los pliegues de entrenamiento en un esquema de validación cruzada por grupos (*Group K-Fold*), que garantiza la separación estricta de pacientes entre particiones. Se evalúa una taxonomía de técnicas de balanceo —organizadas en familias aleatorias, guiadas e híbridas— aplicadas sobre dos dimensiones demográficas (edad y sexo) más una condición de control sin balanceo, en tres conjuntos de datos de CGM con características estructurales distintas: **T1DiabetesGranada** (643 pacientes, más de 30 millones de mediciones), **REPLACE-BG** y **DiaTrend**.

El análisis estadístico combina pruebas de Friedman, comparaciones *post-hoc* de Nemenyi, tamaños del efecto de Cohen's *d* y agregación de *rankings* mediante el método de Borda, con el fin de determinar si el balanceo demográfico produce efectos significativos y consistentes, y en qué condiciones resulta beneficioso desde una perspectiva clínica.

Compensating for Patient Heterogeneity Bias: in Glucose Prediction Models via Data Balancing

Juan Ricardo Hernández Sánchez-Agosta (estudiante)

Keywords: type 1 diabetes mellitus, blood glucose prediction, continuous glucose monitoring (CGM), LSTM, demographic balancing, algorithmic fairness, time series, group cross-validation.

Abstract

Blood glucose prediction is a key tool in the management of type 1 diabetes mellitus (T1DM), enabling the anticipation of hypoglycaemic and hyperglycaemic episodes and improving patients' quality of life. Deep learning models based on LSTM (*Long Short-Term Memory*) networks have demonstrated strong performance in this domain owing to their ability to capture complex temporal dependencies in continuous glucose monitoring (CGM) signals. However, the demographic heterogeneity inherent to available patient cohorts —particularly differences in age and sex— may introduce systematic biases during training, compromising the fairness and generalisation of these models towards underrepresented subgroups.

This Master's Thesis starts from the hypothesis that demographically balancing the training set improves the clinical performance of an LSTM-based glucose prediction model, especially for minority subgroups. To test this hypothesis, an experimental balancing *pipeline* is designed and implemented, applied exclusively to the training folds within a patient-wise cross-validation scheme (*Group K-Fold*) that enforces strict patient separation across partitions. A taxonomy of balancing techniques —organised into random, guided, and hybrid families— is evaluated across two demographic dimensions (age and sex) alongside an unbalanced control condition, on three CGM datasets with distinct structural characteristics: **T1DiabetesGranada** (643 patients, over 30 million readings), **REPLACE-BG**, and **DiaTrend**.

The statistical analysis combines Friedman tests, Nemenyi *post-hoc* comparisons, Cohen's *d* effect sizes, and Borda count ranking aggregation, with the aim of determining whether demographic balancing produces significant and consistent effects, and under which conditions it proves beneficial from a clinical standpoint.

Keywords: type 1 diabetes mellitus, blood glucose prediction, continuous glucose monitoring (CGM), LSTM, demographic balancing, algorithmic fairness, time series, group cross-validation.

Yo, **Juan Ricardo Hernández Sánchez-Agesta** (estudiante), alumno del **MÁSTER DE CIENCIA DE DATOS E INGENIERÍA DE COMPUTADORES**, con DNI **78154358-J**, autorizo la ubicación de la siguiente copia de mi Trabajo Fin de Máster en la biblioteca del centro para que pueda ser consultada por las personas que lo deseen.

Fdo: *Juan Ricardo Hernández Sánchez-Agesta (estudiante)*

Granada a 3 de agosto de 2026.

D. **Oresti Baños Legrán (tutor 1)**, Profesor del Área de Ingeniería de Computadores, Automática y Robótica del Departamento Ingeniería de Computadores, Automática y Robótica de la Universidad de Granada.

D. **Claudia Villalonga Palliser (tutor 2)**, Profesor del Área de Ingeniería de Computadores, Automática y Robótica del Departamento de Ingeniería de Computadores, Automática y Robótica de la Universidad de Granada.

Informan:

Que el presente trabajo, titulado *Compensating for Patient Heterogeneity Bias, in Glucose Prediction Models via Data Balancing*, ha sido realizado bajo su supervisión por **Juan Ricardo Hernández Sánchez-Agosta (estudiante)**, y autorizamos la defensa de dicho trabajo ante el tribunal que corresponda.

Y para que conste, expiden y firman el presente informe en Granada a 3 de agosto de 2026.

Los directores:

Oresti Baños Legrán (tutor 1) Claudia Villalonga Palliser (tutor 2)

Yo, **Juan Ricardo Hernández Sánchez-Agesta** (estudiante), alumno del **MÁSTER DE CIENCIA DE DATOS E INGENIERÍA DE COMPUTADORES** de la **Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación de la Universidad de Granada**, con DNI **78154358-J**, declaro explícitamente que el trabajo presentado es original, entendido en el sentido que no he utilizado ninguna fuente sin citarla debidamente.

Fdo: **Juan Ricardo Hernández Sánchez-Agesta** (estudiante)

Granada, 3 de agosto de 2026.

Agradecimientos

Poner aquí los agradecimientos.

Índice general

1. Introducción	1
1.1. Motivación	2
1.2. Objetivos	2
1.3. Estructura del trabajo	3
2. Fundamentación teórica	5
2.1. Contexto clínico: DM1 y monitorización continua de glucosa	5
2.1.1. Diabetes mellitus tipo 1: fisiopatología y desafíos de gestión	5
2.1.2. Monitorización continua de glucosa: principio de funcionamiento y métricas clínicas	6
2.1.3. Métricas de error en predicción de glucosa	7
2.2. Aprendizaje profundo para series temporales: redes LSTM	7
2.2.1. Redes neuronales recurrentes: motivación y limitaciones	7
2.2.2. Redes LSTM: arquitectura y mecanismo de puertas	8
2.2.3. Predicción de glucosa como regresión temporal con ventana deslizante	8
2.2.4. Validación cruzada por grupos en datos de pacientes	9
2.3. <i>Imbalanced learning</i> y desequilibrio demográfico	9
2.3.1. Desequilibrio de clase: definición y consecuencias	9
2.3.2. Técnicas de remuestreo en <i>imbalanced learning</i>	9
2.3.3. Extensión al desequilibrio demográfico	10
2.3.4. Métricas de evaluación en contexto de desequilibrio	10
3. Estado del arte	13
3.1. Modelos de predicción de glucosa	13
3.1.1. Modelos fisiológicos y basados en ecuaciones	13
3.1.2. Métodos estadísticos de series temporales	14
3.1.3. Aprendizaje automático clásico	14
3.1.4. Aprendizaje profundo: CNN y LSTM	14
3.1.5. Tendencias actuales	14
3.2. <i>Datasets</i> para la predicción de glucosa	15
3.2.1. Categorías generales de <i>datasets</i>	15
3.2.2. Repositorios abiertos y sus limitaciones	15
3.2.3. <i>Datasets</i> utilizados en este trabajo	16
3.3. Diferencias por sexo y edad en la dinámica glucémica	16
3.3.1. Diferencias por sexo	16
3.3.2. Diferencias por edad	17
3.4. Desequilibrio demográfico en modelos clínicos	17
3.4.1. Desequilibrio demográfico frente a desequilibrio de clase	17
3.4.2. Evidencia de disparidad de rendimiento por subgrupo	17

3.4.3. Técnicas de mitigación del desequilibrio demográfico	18
3.5. Técnicas de balanceo en series temporales y datos médicos	20
3.5.1. Balanceo en datos de series temporales: estado de la cuestión	20
3.5.2. Balanceo demográfico en series temporales fisiológicas	21
3.5.3. Generación sintética de series temporales fisiológicas	22
3.6. Brechas en la literatura y motivación del trabajo	23
4. Desarrollo del trabajo	25
4.1. Recopilación y descripción de los datos	25
4.1.1. Criterios de selección de los <i>datasets</i>	25
4.1.2. T1DiabetesGranada	25
4.1.3. REPLACE-BG	25
4.1.4. DiaTrend	25
4.1.5. Estructura unificada de datos de entrada	25
4.2. Análisis exploratorio de datos	25
4.2.1. Distribución demográfica de los <i>datasets</i>	26
4.2.2. Distribución de la señal CGM	26
4.2.3. Análisis de datos ausentes	26
4.2.4. Análisis de separabilidad demográfica	26
4.3. Detección y cuantificación del desequilibrio demográfico	26
4.3.1. Desequilibrio a nivel de paciente frente a nivel de ventana	26
4.3.2. Desequilibrio por dimensión demográfica y <i>fold</i>	26
4.4. Investigación de técnicas de balanceo para series temporales	26
4.4.1. Criterios de selección de técnicas	26
4.4.2. Taxonomía de técnicas implementadas	26
4.4.3. Validación formal del <i>pipeline</i> de balanceo	26
4.5. Transformación de datos: generación de ventanas deslizantes	26
4.5.1. Parámetros de ventana	27
4.5.2. Restricciones de continuidad temporal	27
4.5.3. Esquema de partición: <i>Group K-Fold</i> con $K = 5$	27
4.6. Análisis exploratorio de ventanas	27
4.6.1. Distribución de ventanas por grupo demográfico y <i>fold</i>	27
4.6.2. Distribución de la variable objetivo por grupo demográfico	27
4.6.3. Verificación de integridad de las particiones	27
4.7. Arquitectura del modelo LSTM	27
4.7.1. Especificación de la arquitectura	27
4.7.2. Función de pérdida y optimizador	27
4.7.3. Estrategia de entrenamiento	27
4.7.4. Configuración del entorno de ejecución	27
4.8. <i>Pipeline</i> de entrenamiento y evaluación	27
4.8.1. Modo original y modo balanceado	27
4.8.2. Flujo de datos por <i>fold</i>	27
4.8.3. Evaluación por rango glucémico	27
4.8.4. Agregación de resultados y protocolo estadístico	27
4.8.5. Trazabilidad y reproducibilidad	27
5. Resultados y discusión	29
6. Conclusiones	33

Bibliografía	39
A. Ejemplo de anexo: Planificación y gestión del proyecto (opcional)	41
A.1. Metodología/Ciclo de vida	42
A.2. Herramientas y plataformas utilizadas para el desarrollo del proyecto	42
A.3. Costes del proyecto	42
A.4. Gestión del proyecto. Planificación temporal. Diagrama de Gantt	42
A.5. Texto añadido	42
B. Ejemplo de anexo: Innovación (opcional)	45
B.1. Estudio del Mercado	45
B.1.1. Segmentos de Clientes	45
B.1.2. Competidores	45
B.2. Propuesta de Valor	45
B.3. Recursos Clave	45
B.4. Actividades Clave	45
B.5. Socios y Alianzas Clave	45
B.6. Estructura de Costes Prevista	46
B.7. Vías de Ingresos	46
B.8. Canales de Distribución	46
B.9. Relación con los Clientes	46
B.10. Descripción del Producto Mínimo Viable	46
B.11. Roadmap de Desarrollo	46
B.12. Aspectos Legales	46
B.13. Texto añadido	46
C. Ejemplo de anexo: Manual de usuario (opcional)	49
C.1. Texto añadido	49

Índice de figuras

5.1. Mi logo	31
5.2. Lista de distribuciones	32

Índice de tablas

3.1. <i>Datasets</i> utilizados en este trabajo y disponibilidad de variables demográficas. . .	16
3.2. Comparativa de técnicas para la mitigación del desequilibrio demográfico.	20
5.1. Tabla grande	29
5.2. Tabla enorme	30

Capítulo 1

Introducción

La diabetes mellitus tipo 1 (DM1) es una enfermedad crónica de carácter autoinmune que afecta a millones de personas en todo el mundo y que se caracteriza por la destrucción de las células beta del páncreas, impidiendo la producción endógena de insulina. A diferencia de otras enfermedades crónicas con una dinámica relativamente estable, la DM1 somete al paciente a una gestión terapéutica diaria de alta complejidad: la concentración de glucosa en sangre fluctúa de forma continua en respuesta a la insulina exógena, la ingesta, el ejercicio físico, el estrés y otros factores fisiológicos. El desafío clínico central es anticipar estas fluctuaciones con suficiente antelación para que el paciente pueda actuar antes de que se produzcan episodios de hipoglucemia o hiperglucemia, que pueden tener consecuencias agudas graves a corto plazo y complicaciones crónicas severas a largo plazo.

Los sistemas de monitorización continua de glucosa (CGM, por sus siglas en inglés) han transformado el seguimiento clínico de la DM1, al generar señales de alta frecuencia —una medición cada 5 o 15 minutos— que capturan la dinámica glucémica con una resolución imposible mediante los métodos tradicionales de glucometría capilar. Esta riqueza temporal ha impulsado el desarrollo de modelos predictivos basados en aprendizaje automático que estiman el valor futuro de glucosa a partir de la trayectoria reciente de la señal. Entre estas arquitecturas, las redes neuronales recurrentes de tipo LSTM (*Long Short-Term Memory*) han ocupado un lugar consolidado por su capacidad de aprender dependencias temporales de largo alcance directamente de la secuencia bruta, sin necesidad de ingeniería manual de características.

Sin embargo, el rendimiento de un modelo LSTM de predicción de glucosa no depende únicamente de su arquitectura ni de la calidad de la señal CGM en sí misma: depende también de la composición del conjunto de datos con el que se entrena. Los *datasets* de investigación en DM1 disponibles públicamente son, por construcción, muestras de conveniencia clínica. Sus distribuciones demográficas no son uniformes: algunos *datasets* presentan una mayoría de pacientes de un determinado sexo o de un rango etario concreto, lo que se traduce en una asimetría estructural en el número de ventanas de entrenamiento disponibles por grupo demográfico. Esta asimetría puede inducir que el modelo aprenda preferentemente la dinámica glucémica del subgrupo mayoritario, degradando su capacidad predictiva para los subgrupos infrarrepresentados.

La cuestión de si esta composición demográfica del conjunto de entrenamiento afecta de forma medible y corregible al rendimiento predictivo de un modelo LSTM constituye la pregunta central de este Trabajo Fin de Máster. Se trata de una pregunta que la literatura ha comenzado a explorar en el dominio amplio del aprendizaje automático clínico, pero que permanece escasamente estudiada en el contexto específico de la predicción de glucosa mediante CGM, lo que delimita y justifica la contribución de este trabajo.

1.1. Motivación

La motivación de este trabajo surge de la intersección de dos líneas de inquietud: una de carácter personal, derivada del interés por aplicar técnicas de ciencia de datos a problemas con impacto clínico real; y otra de carácter técnico, derivada de una limitación metodológica concreta identificada en la literatura existente.

Desde el punto de vista personal, la predicción de glucosa en DM1 representa un problema de modelado especialmente rico: combina series temporales de alta frecuencia con contexto clínico complejo, heterogeneidad interindividual pronunciada y consecuencias potencialmente graves de los errores de predicción. Es, además, un dominio en el que la brecha entre el rendimiento agregado de un modelo y su rendimiento en subgrupos específicos puede traducirse en diferencias reales en la calidad del cuidado que reciben los pacientes. Trabajar en este dominio con las herramientas propias de la ingeniería de datos y el aprendizaje automático, y hacerlo con rigor estadístico, constituye una motivación genuina que subyace a todas las decisiones de diseño de este trabajo.

Desde el punto de vista técnico, la motivación surge de una observación concreta: la equidad algorítmica en salud —el estudio sistemático de si los modelos de aprendizaje automático producen rendimientos dispares en función de características demográficas de los pacientes— ha recibido creciente atención en la literatura, pero ha operado mayoritariamente sobre datos tabulares en los que cada observación corresponde a un paciente o a un episodio clínico discreto. El problema de la predicción de series temporales mediante ventana deslizante introduce una complicación estructural que no ha sido tratada explícitamente en la literatura revisada: la unidad de balanceo no es el paciente sino la ventana. Un mismo paciente con una serie temporal larga puede generar órdenes de magnitud más ventanas de entrenamiento que otro paciente con una serie corta, incluso cuando ambos pertenecen nominalmente al mismo grupo demográfico. Esta distinción entre balanceo a nivel de paciente y balanceo a nivel de ventana es metodológicamente relevante y constituye una de las contribuciones de diseño de este trabajo.

Adicionalmente, la elección de las dimensiones demográficas de estudio —sexo y edad— está motivada por evidencia fisiológica consolidada: tanto el sexo como la edad están asociados a patrones de dinámica glucémica distinguibles. Las diferencias hormonales entre hombres y mujeres, así como la evolución de la respuesta insulínica a lo largo de la vida, producen perfiles CGM sistémicamente distintos entre subgrupos, lo que hace esperable —y justifica estudiar empíricamente— que un modelo LSTM entrenado sobre una composición demográficamente sesgada aprenda de forma subóptima para los subgrupos infrarrepresentados.

Por último, existe una motivación de relevancia práctica e inmediata: el *dataset* T1DiabetesGranada, generado en el Hospital Universitario Virgen de las Nieves de Granada con más de 643 pacientes y más de 30 millones de mediciones registradas entre 2018 y 2022, es uno de los tres conjuntos de datos sobre los que se trabaja en este TFM. Incorporar un recurso de investigación local de esta envergadura, y contribuir a entender sus propiedades estadísticas y sus implicaciones para el entrenamiento de modelos predictivos, añade una dimensión de relevancia territorial y clínica directa a la investigación.

1.2. Objetivos

El objetivo general de este trabajo es cuantificar empíricamente el impacto de las técnicas de balanceo demográfico —aplicadas sobre las dimensiones de sexo y edad— en el rendimiento predictivo de un modelo LSTM de predicción de glucosa entrenado sobre datos CGM, y determinar bajo qué condiciones dicho balanceo produce mejoras clínicamente relevantes.

De este objetivo general se derivan los siguientes objetivos específicos:

1. **Diseñar e implementar un *pipeline* de balanceo demográfico** que opere exclusivamente sobre el conjunto de entrenamiento de cada *fold* en un esquema de validación cruzada por grupos (*Group K-Fold*), garantizando la separación estricta de pacientes entre particiones y la invarianza bit a bit de los conjuntos de validación y test entre condiciones experimentales.
2. **Implementar y validar una taxonomía de diez técnicas de balanceo**, clasificadas en tres familias: técnicas aleatorias (*random undersampling*, *random oversampling*), técnicas guiadas (*SMOTE*, *Tomek Links*) y combinaciones híbridas (*patient-aware undersampling*, *jittering*, *undersampling + oversampling*, *undersampling + SMOTE*, *SMOTE + Tomek*, *oversampling + Tomek Links*), aplicadas en dos variantes demográficas (edad y sexo) más una condición de control sin balanceo.
3. **Evaluar el efecto del balanceo demográfico sobre el rendimiento global del modelo LSTM**, medido mediante métricas de error de predicción (RMSE, MAE) y métricas de la *Clarke Error Grid* (zonas A, B, A+B), desagregadas por rango glucémico (TBR-2, TBR-1, TIR, TAR-1, TAR-2, rango completo).
4. **Comparar el impacto del balanceo por edad frente al balanceo por sexo** y determinar cuál de las dos dimensiones demográficas produce un efecto mayor y más consistente sobre el rendimiento predictivo.
5. **Caracterizar la robustez de los resultados entre *datasets***, evaluando si los efectos observados son consistentes a través de los tres conjuntos de datos (T1DiabetesGranada, REPLACE-BG, DiaTrend) o si dependen de propiedades estructurales específicas de cada cohorte, como el tamaño muestral, el patrón de datos ausentes o la distribución demográfica intrínseca.
6. **Identificar la técnica de balanceo con mejor rendimiento agregado** mediante un análisis estadístico formal que incluya pruebas de Friedman, comparaciones *post-hoc* de Nemenyi, tamaños del efecto de Cohen's *d* y agregación de *rankings* mediante el método de Borda.
7. **Describir las limitaciones metodológicas y los compromisos clínicos** identificados en los resultados, en particular aquellos casos en que la mejora en un rango glucémico conlleva una degradación en otro, con el objetivo de proporcionar una base de evidencia honesta para la toma de decisiones sobre la incorporación de balanceo demográfico en sistemas de predicción clínica.

1.3. Estructura del trabajo

El presente trabajo se organiza en seis capítulos, cuya estructura refleja la progresión lógica desde la fundamentación teórica hasta las conclusiones empíricas.

El capítulo 2.3.4 ([Métricas de evaluación en contexto de desequilibrio](#)) establece el marco teórico y bibliográfico del trabajo. Se introduce el contexto clínico de la DM1 y de los sistemas CGM, se revisa la evidencia fisiológica de que el sexo y la edad modulan la dinámica glucémica, se examina la literatura sobre desequilibrio demográfico en *datasets* clínicos y su impacto documentado en el rendimiento de modelos de aprendizaje automático, y se revisan las técnicas del estado del arte para la mitigación de este desequilibrio. El capítulo concluye identificando las tres brechas concretas que este trabajo aborda.

El capítulo de metodología describe el diseño experimental completo: la arquitectura del modelo LSTM utilizado, el esquema de validación cruzada por grupos, el proceso de generación de

ventanas deslizantes a partir de las señales CGM, la implementación de las diez técnicas de balanceo demográfico y el proceso de validación formal del *pipeline* mediante un *notebook* de verificación de restricciones. Se describen igualmente las métricas de evaluación empleadas y el protocolo estadístico utilizado para el análisis comparativo.

El capítulo de resultados y discusión presenta los resultados experimentales siguiendo una estructura analítica en embudo: se parte de una visión global del efecto del balanceo agregado sobre todos los *datasets* y rangos glucémicos, y se desciende progresivamente hacia el análisis por *dataset*, por dimensión demográfica, por rango glucémico y por técnica individual. Los resultados de los tests de Friedman, los *rankings* de Nemenyi y la agregación de Borda se presentan en este capítulo, junto con la discusión de los compromisos clínicos identificados y la caracterización de la robustez entre *datasets*.

Finalmente, el capítulo 6 ([Conclusiones](#)) recoge las conclusiones del trabajo, contrastando los resultados obtenidos con los objetivos específicos enumerados en la sección 1.2, e identifica las líneas de trabajo futuro más directamente motivadas por los resultados y las limitaciones encontradas.

Capítulo 2

Fundamentación teórica

Este capítulo proporciona la base conceptual necesaria para comprender el problema abordado en este trabajo y las decisiones metodológicas que lo articulan. Se organiza en tres bloques.

El primer bloque (sección 2.1) desarrolla el contexto clínico de la diabetes mellitus tipo 1 y de los sistemas CGM, incluyendo las métricas clínicas y de error que articulan la evaluación de los modelos predictivos.

El segundo bloque (sección 2.2) expone las bases del aprendizaje profundo para series temporales, con especial atención a las redes LSTM: su arquitectura, su mecanismo de puertas y la formulación del problema de predicción de glucosa como regresión temporal con ventana deslizante.

El tercer bloque (sección 2.3) introduce los fundamentos del *imbalanced learning*, explica su extensión al desequilibrio de composición demográfica del conjunto de entrenamiento y revisa las métricas de evaluación pertinentes en este contexto.

2.1. Contexto clínico: DM1 y monitorización continua de glucosa

2.1.1. Diabetes mellitus tipo 1: fisiopatología y desafíos de gestión

La diabetes mellitus tipo 1 (DM1) es una enfermedad autoinmune crónica caracterizada por la destrucción selectiva de las células beta de los islotes de Langerhans del páncreas, mediada por linfocitos T autorreactivos [1]. La consecuencia directa de esta destrucción es la deficiencia absoluta de insulina: el páncreas pierde progresivamente —y en la mayoría de los casos de forma irreversible— su capacidad de producir la hormona responsable de facilitar la captación de glucosa por los tejidos periféricos. A diferencia de la diabetes tipo 2, en la que la resistencia a la insulina y el déficit relativo de producción constituyen los mecanismos fisiopatológicos predominantes, la DM1 convierte al paciente en dependiente de la administración exógena de insulina desde el momento del diagnóstico y de forma permanente.

La prevalencia global de la DM1 se estima en torno a 8,75 millones de personas, con una incidencia creciente en las últimas décadas especialmente en países de renta alta [2]. En España, los datos del registro nacional estiman una prevalencia de entre 0,3 y 0,5 casos por cada 100 habitantes, con una incidencia anual de entre 10 y 17 nuevos casos por cada 100.000 habitantes menores de 15 años [3].

El desafío clínico central en la DM1 no es únicamente la deficiencia de insulina en sí misma, sino la enorme variabilidad de los requerimientos de insulina exógena a lo largo del día y entre días. La glucosa en sangre fluctúa en respuesta a múltiples factores: la cantidad y composición de los alimentos ingeridos, el tipo e intensidad del ejercicio físico, el estrés psicológico, la fase del ciclo

menstrual en mujeres, las enfermedades intercurrentes y la farmacocinética de la propia insulina administrada, entre otros [4]. Esta variabilidad multifactorial convierte la gestión glucémica diaria en una tarea de control continuo que exige al paciente —o a los sistemas automáticos que le asisten— tomar decisiones clínicas frecuentes y adaptadas al contexto, a menudo con información incompleta o retardada.

Las consecuencias clínicas de una gestión subóptima son bidireccionales. La **hipoglucemia** —concentración de glucosa en sangre inferior a 70 mg/dL en su nivel 1, e inferior a 54 mg/dL en el nivel 2 con riesgo vital inmediato— es la complicación aguda más temida: puede producir alteración de la consciencia, convulsiones y, en casos extremos, la muerte. La **hiperglucemia sostenida** —definida clínicamente por tiempos prolongados por encima de 180 mg/dL— produce a largo plazo complicaciones microvasculares y macrovasculares graves, incluyendo retinopatía, nefropatía, neuropatía periférica y enfermedad cardiovascular [5]. El objetivo terapéutico es, por tanto, mantener la glucosa dentro de un rango euglucémico de seguridad —convencionalmente 70–180 mg/dL, denominado *Time in Range* (TIR)— durante el mayor tiempo posible, minimizando simultáneamente el tiempo en hipoglucemia y el tiempo en hiperglucemia.

La gestión glucémica es, en definitiva, un problema de control dinámico bajo incertidumbre: el paciente o el sistema que le asiste debe anticipar la trayectoria futura de la glucosa con suficiente antelación para actuar de forma preventiva antes de que se produzca una desviación clínicamente relevante. Esta necesidad de anticipación es precisamente la que motiva el desarrollo de modelos de predicción de glucosa.

2.1.2. Monitorización continua de glucosa: principio de funcionamiento y métricas clínicas

Los sistemas de monitorización continua de glucosa (CGM, del inglés *Continuous Glucose Monitoring*) miden la concentración de glucosa de forma automática y continuada mediante electrodos enzimáticos subcutáneos que detectan la glucosa en el líquido intersticial. A diferencia de la glucometría capilar tradicional, los sistemas CGM generan señales de alta frecuencia con periodos de muestreo de entre 5 y 15 minutos [6]. Un paciente con seguimiento CGM durante un año acumula entre 35.000 y 105.000 puntos de medición, lo que hace de estos datos un sustrato natural para el entrenamiento de modelos de series temporales.

Es importante precisar que la señal CGM no mide directamente la glucosa en sangre (glucosa plasmática), sino la glucosa en el líquido intersticial. Existe un retardo fisiológico de entre 5 y 15 minutos entre ambas señales durante los periodos de cambio rápido de glucosa —como tras la ingesta o durante el ejercicio— denominado *lag* intersticial [7]. Este retardo introduce una fuente de error sistemático en las predicciones a corto plazo que los modelos basados en CGM deben compensar implícitamente.

Las métricas clínicas estándar derivadas de la señal CGM están formalizadas en el consenso del *Ambulatory Glucose Profile* (AGP) y en las recomendaciones de la *Advanced Technologies and Treatments for Diabetes* (ATTD) [8]. Las más relevantes para este trabajo son:

- ***Time in Range* (TIR)**: porcentaje de tiempo con glucosa entre 70 y 180 mg/dL. Métrica primaria de control glucémico en la práctica clínica moderna.
- ***Time Below Range nivel 1* (TBR-1)**: porcentaje de tiempo con glucosa entre 54 y 69 mg/dL (hipoglucemia clínicamente significativa).
- ***Time Below Range nivel 2* (TBR-2)**: porcentaje de tiempo con glucosa inferior a 54 mg/dL (hipoglucemia grave con riesgo vital).
- ***Time Above Range nivel 1* (TAR-1)**: porcentaje de tiempo con glucosa entre 181 y 250 mg/dL (hiperglucemia moderada).

- **Time Above Range nivel 2 (TAR-2)**: porcentaje de tiempo con glucosa superior a 250 mg/dL (hiperglucemia severa).

En el contexto de la evaluación de modelos predictivos, el rendimiento se mide frecuentemente mediante la *Clarke Error Grid* (CEG) [9], una representación bidimensional que clasifica las predicciones en cinco zonas (A–E) según su consecuencia clínica. La zona A agrupa las predicciones clínicamente exactas (error relativo inferior al 20 %); las zonas C, D y E corresponden a errores con consecuencias clínicas crecientes, incluyendo decisiones terapéuticas potencialmente peligrosas.

2.1.3. Métricas de error en predicción de glucosa

La evaluación cuantitativa de los modelos de predicción de glucosa utiliza métricas de error estándar en regresión. Las más empleadas en la literatura son:

- **RMSE** (*Root Mean Squared Error*): raíz cuadrada del error cuadrático medio, expresada en mg/dL. Penaliza los errores grandes de forma cuadrática, lo que la hace especialmente sensible a los errores en rangos extremos (hipoglucemia severa, hiperglucemia severa). Es la métrica de referencia dominante en la literatura de predicción de glucosa.
- **MAE** (*Mean Absolute Error*): media del valor absoluto de los errores, expresada en mg/dL. Más robusta frente a valores atípicos y directamente interpretable como el error medio esperado.
- **MAPE** (*Mean Absolute Percentage Error*): error porcentual absoluto medio. Adimensional, pero con inestabilidad numérica en rangos de hipoglucemia severa, donde el denominador se aproxima a cero.

La elección del RMSE como métrica primaria en este trabajo —siguiendo la convención dominante en la literatura— responde a su sensibilidad diferencial hacia los errores clínicamente más graves: una predicción errónea en hipoglucemia severa produce un error cuadrático desproporcionadamente mayor que un error de pequeña magnitud clínica, lo que se traduce en una penalización implícita de los errores más peligrosos.

2.2. Aprendizaje profundo para series temporales: redes LSTM

2.2.1. Redes neuronales recurrentes: motivación y limitaciones

Las redes neuronales recurrentes (RNN, del inglés *Recurrent Neural Networks*) son una familia de arquitecturas de aprendizaje profundo diseñadas para procesar secuencias de longitud arbitraria mediante la introducción de conexiones recurrentes: la salida —o un resumen interno— del paso temporal t se retroalimenta como entrada adicional en el paso $t + 1$, de modo que la red mantiene un estado oculto $\mathbf{h}_t$ que actúa como memoria comprimida de la historia de la secuencia hasta el instante t [10].

Formalmente, la actualización del estado oculto en una RNN estándar en el instante t se expresa como:

$$\mathbf{h}_t = f(\mathbf{W}_h \mathbf{h}_{t-1} + \mathbf{W}_x \mathbf{x}_t + \mathbf{b}) \quad (2.1)$$

donde $\mathbf{x}_t$ es el vector de entrada en el instante t , $\mathbf{W}_h$ y $\mathbf{W}_x$ son matrices de pesos entrenables, $\mathbf{b}$ es un vector de sesgo y f es una función de activación no lineal (habitualmente $\tanh$). La predicción se obtiene aplicando una transformación lineal al estado oculto: $\hat{y}_t = \mathbf{W}_y \mathbf{h}_t + \mathbf{b}_y$.

La limitación fundamental de las RNN estándar reside en el entrenamiento mediante retropropagación a través del tiempo (*Backpropagation Through Time*, BPTT): el gradiente involucra productos reiterados de la matriz jacobiana de la función de transición. Cuando la secuencia es larga, este producto puede converger exponencialmente a cero (*vanishing gradient*) o crecer exponencialmente (*exploding gradient*), impidiendo en la práctica que la red aprenda dependencias temporales de largo alcance [11, ?].

2.2.2. Redes LSTM: arquitectura y mecanismo de puertas

Las redes *Long Short-Term Memory* (LSTM), propuestas por Hochreiter y Schmidhuber en 1997 [12], resuelven el problema del gradiente evanescente mediante la introducción de una celda de memoria $\mathbf{c}_t$ con flujo de gradiente controlado y un sistema de *puertas* (*gates*) que regulan de forma diferenciable qué información se retiene, qué información se descarta y qué información nueva se incorpora en cada paso temporal.

Puerta de olvido (*forget gate*, $\mathbf{f}_t$): determina qué fracción de la celda de memoria anterior $\mathbf{c}_{t-1}$ se conserva:

$$\mathbf{f}_t = \sigma(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \quad (2.2)$$

Puerta de entrada (*input gate*, $\mathbf{i}_t$) y **candidato de celda** ($\tilde{\mathbf{c}}_t$): determinan qué nueva información se escribe en la celda de memoria:

$$\mathbf{i}_t = \sigma(\mathbf{W}_i[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i), \quad \tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_c[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c) \quad (2.3)$$

Actualización de la celda: combina la información retenida y la nueva información candidata:

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t \quad (2.4)$$

donde $\odot$ denota el producto elemento a elemento (*Hadamard product*).

Puerta de salida (*output gate*, $\mathbf{o}_t$): filtra la información de la celda de memoria que se propaga al estado oculto:

$$\mathbf{o}_t = \sigma(\mathbf{W}_o[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o), \quad \mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t) \quad (2.5)$$

La clave del mecanismo es que la celda $\mathbf{c}_t$ se actualiza mediante suma —no multiplicación— de la información nueva, lo que permite que el gradiente fluya a través de la secuencia sin atenuarse de forma multiplicativa. Este flujo de gradiente no obstruido habilita a las LSTM para capturar dependencias temporales de largo alcance, una propiedad esencial para modelar la dinámica glucémica, en la que patrones ocurridos horas antes pueden seguir influyendo en la señal CGM observada mucho tiempo después.

2.2.3. Predicción de glucosa como regresión temporal con ventana deslizante

En el contexto de este trabajo, la predicción de glucosa se formula como un problema de regresión de un paso a horizonte fijo: dado un historial de mediciones CGM de longitud fija $\{g_{t-n+1}, \dots, g_t\}$ —denominado *Historical Window* (HW)— se estima el valor de glucosa en un instante futuro $\hat{g}_{t+PH}$, donde PH es el horizonte de predicción (*Prediction Horizon*). Este trabajo utiliza $HW = 8$ mediciones y $PH = 4$ mediciones, lo que corresponde a una ventana de observación de 2 horas y un horizonte de predicción de 1 hora a una frecuencia de muestreo de 15 minutos (T1DiabetesGranada), y de 40 minutos de observación con 20 minutos de horizonte a 5 minutos de muestreo (DiaTrend, REPLACE-BG). El horizonte de una hora es clínicamente relevante por ofrecer margen suficiente para ajustes terapéuticos preventivos antes de que se produzca una desviación glucémica [13].

El proceso de generación de instancias de entrenamiento se realiza mediante **ventana deslizante** (*sliding window*): para cada posición t válida en la serie de un paciente, se extrae una ventana

de entrada $\mathbf{x}^{(t)} = [g_{t-n+1}, \dots, g_t]$ y un valor objetivo $y^{(t)} = g_{t+PH}$. Esta formulación introduce una propiedad estructural relevante: la unidad de análisis no es el paciente sino la ventana. Un paciente con una serie de alta densidad puede aportar decenas de miles de ventanas; un paciente con una serie fragmentada puede aportar apenas unos centenares. Esta disparidad en la contribución de ventanas entre pacientes —independiente de la distribución demográfica del *dataset*— constituye por sí misma una forma de desequilibrio de representación en el conjunto de entrenamiento.

2.2.4. Validación cruzada por grupos en datos de pacientes

La validación cruzada estándar (*K-Fold*) distribuye las observaciones aleatoriamente entre los *folds*, lo que en el contexto de series temporales CGM producidas por ventana deslizante introduce *data leakage*: ventanas del mismo paciente —y frecuentemente ventanas temporalmente contiguas— pueden aparecer simultáneamente en el conjunto de entrenamiento y en el de validación del mismo *fold*. Este solapamiento produce una estimación artificialmente optimista del rendimiento del modelo.

La **validación cruzada por grupos** (*Group K-Fold*) resuelve este problema garantizando que ningún paciente aparece simultáneamente en el conjunto de entrenamiento y en el de validación de un mismo *fold*: todos los pacientes se asignan íntegramente a un único *fold* [14]. Esta estrategia produce una evaluación más pesimista pero más realista del rendimiento sobre pacientes no vistos durante el entrenamiento, que es el escenario clínico relevante.

En este trabajo se utiliza un esquema de 5-fold *Group K-Fold*, con la restricción adicional de que el conjunto de test permanece fijo e idéntico en todas las condiciones experimentales (con y sin balanceo, para todas las técnicas), de modo que las diferencias de rendimiento observadas sean atribuibles exclusivamente a las transformaciones aplicadas al conjunto de entrenamiento.

2.3. *Imbalanced learning* y desequilibrio demográfico

2.3.1. Desequilibrio de clase: definición y consecuencias

El aprendizaje sobre datos desequilibrados (*imbalanced learning*) estudia cómo diseñar, entrenar y evaluar modelos cuando las clases de la variable objetivo tienen frecuencias muy dispares. En la formulación clásica del problema, el desequilibrio de clase se produce cuando la clase mayoritaria representa una fracción dominante del conjunto de entrenamiento mientras que la clase minoritaria —a menudo la más relevante desde el punto de vista del dominio— representa una fracción marginal [15].

Las consecuencias del desequilibrio de clase en el entrenamiento son bien conocidas: un modelo que minimiza una función de pérdida agregada sobre un conjunto de entrenamiento desequilibrado tiende a aprender preferentemente la distribución de la clase mayoritaria. En clasificación, esto se manifiesta como sesgo sistemático hacia la clase dominante. En regresión —el tipo de problema abordado en este trabajo— el efecto es análogo: el modelo aprende preferentemente la distribución de los valores objetivo más frecuentes, produciendo predicciones menos precisas para los valores que aparecen con menor frecuencia, aunque estos sean clínicamente los más relevantes [16].

2.3.2. Técnicas de remuestreo en *imbalanced learning*

Las estrategias para mitigar el impacto del desequilibrio de clase pueden clasificarse en tres niveles: preprocesado de los datos (*pre-processing*), modificación del proceso de entrenamiento

(*in-processing*) y postprocesado de las predicciones (*post-processing*) [17]. Las técnicas de preprocesado son las más compatibles con el requisito metodológico de este trabajo —el balanceo debe materializarse exclusivamente como una transformación de los datos de entrada— y son las más estudiadas en la literatura.

Dentro de las técnicas de preprocesado, las de **remuestreo** son las más utilizadas:

Undersampling (submuestreo): reduce el tamaño de la clase mayoritaria eliminando observaciones. La estrategia más simple es el submuestreo aleatorio (*Random Undersampling*, RUS). Estrategias más sofisticadas, como *Tomek Links* [18], identifican y eliminan selectivamente los pares de observaciones de clases opuestas que son vecinos mutuos en el espacio de características. La limitación principal del *undersampling* es la pérdida de información.

Oversampling (sobremuestreo): aumenta el tamaño de la clase minoritaria generando nuevas observaciones. La técnica más influyente es SMOTE (*Synthetic Minority Oversampling Technique*) [19], que genera observaciones sintéticas interpolando linealmente entre observaciones reales de la clase minoritaria y sus k vecinos más cercanos. Su limitación es la introducción de puntos sintéticos que pueden no respetar la distribución real de la clase minoritaria.

Técnicas híbridas: combinan *undersampling* y *oversampling* de forma secuencial. *SMOTE+Tomek* aplica SMOTE para aumentar la clase minoritaria y a continuación elimina mediante *Tomek Links* los pares ruidosos en la frontera de decisión [20].

2.3.3. Extensión al desequilibrio demográfico

El problema abordado en este trabajo no es el desequilibrio de clase en su formulación clásica —desequilibrio entre clases glucémicas (hipoglucemia, normoglucemia, hiperglucemia)—, sino un tipo de desequilibrio cualitativamente diferente: el **desequilibrio de composición demográfica** del conjunto de entrenamiento. Este problema surge cuando la proporción de ventanas de entrenamiento procedentes de distintos grupos demográficos —definidos por sexo o por grupo de edad— es muy dispar, no porque los pacientes de distintos grupos tengan dinámicas glucémicas intrínsecamente distintas en frecuencia, sino porque el *dataset* contiene más pacientes de algunos grupos que de otros, o porque los pacientes de distintos grupos tienen series CGM de longitud o densidad diferente.

La distinción conceptual es importante: en el desequilibrio de clase clásico, la variable desequilibrada es la etiqueta de clase que el modelo intenta predecir. En el desequilibrio demográfico, la variable desequilibrada es un atributo del sujeto que produjo los datos, no el valor que el modelo predice. Un modelo que minimiza el error de predicción sobre un conjunto demográficamente desequilibrado aprende preferentemente la dinámica glucémica del subgrupo mayoritario, produciendo predicciones sistemáticamente menos precisas para los subgrupos infrarrepresentados. Las técnicas de remuestreo clásicas no fueron diseñadas para corregir este tipo de desequilibrio. La adaptación de estas técnicas al desequilibrio demográfico requiere redefinir la unidad de remuestreo: en lugar de operar sobre la distribución de la variable objetivo, se opera sobre la distribución de la variable demográfica. Esta redefinición es precisamente lo que diferencia metodológicamente el *pipeline* de balanceo demográfico implementado en este trabajo de la aplicación directa de las técnicas estándar de *imbalanced learning*.

2.3.4. Métricas de evaluación en contexto de desequilibrio

La evaluación del rendimiento de modelos entrenados sobre datos desequilibrados requiere métricas que sean sensibles a la disparidad de rendimiento entre subgrupos, y no únicamente al rendimiento medio agregado. En el contexto de regresión, un modelo puede obtener un RMSE global bajo mientras produce predicciones sistemáticamente peores para el subgrupo demográfico minoritario, sin que esta disparidad sea detectable en la métrica agregada. Por este motivo, el

análisis estadístico de este trabajo examina tanto el rendimiento global como el rendimiento desagregado por rango glucémico y por subgrupo demográfico.

El protocolo estadístico formal utilizado —pruebas de Friedman, comparaciones *post-hoc* de Nemenyi, tamaños del efecto de Cohen's d y agregación de *rankings* mediante el método de Borda— responde a la necesidad de comparar simultáneamente múltiples técnicas sobre múltiples *datasets* y rangos glucémicos, controlando el error de tipo I en comparaciones múltiples. La elección de pruebas no paramétricas está motivada por la imposibilidad de asumir normalidad en las distribuciones de error entre *folds* para todas las condiciones experimentales.

Capítulo 3

Estado del arte

Este capítulo revisa la evidencia científica sobre tres líneas de investigación cuya confluencia define el presente trabajo: la predicción de glucosa mediante modelos de series temporales, los sesgos demográficos en modelos clínicos de aprendizaje automático y las técnicas para su mitigación. La revisión no tiene por objeto explicar los conceptos que sustentan estas líneas —tratados en el capítulo anterior— sino identificar la frontera del conocimiento actual y las brechas que este trabajo aborda.

Se organiza en cuatro secciones. La sección 3.1 revisa el estado del arte en modelos de predicción de glucosa. La sección 3.2 describe los *datasets* disponibles y sus limitaciones para el análisis de subgrupos. La sección 3.3 establece la evidencia fisiológica y clínica de que el sexo y la edad modulan la dinámica glucémica. La sección 3.4 revisa la literatura sobre desequilibrio demográfico y técnicas de mitigación. La sección 3.5 revisa la literatura sobre técnicas de balanceo aplicadas específicamente a series temporales y datos médicos. El capítulo concluye con la identificación de las brechas específicas que motivan este trabajo.

3.1. Modelos de predicción de glucosa

A lo largo de las últimas décadas se han propuesto para la predicción de glucosa en sangre en pacientes con DM1 metodologías muy diversas, cuya progresión refleja tanto la evolución de las herramientas computacionales como la mayor disponibilidad de datos CGM. Esta sección revisa las principales familias de modelos que han conformado el estado del arte, con énfasis en su rendimiento comparado y en los aspectos no resueltos que motivan el presente trabajo.

3.1.1. Modelos fisiológicos y basados en ecuaciones

Los primeros intentos de predicción de glucosa se apoyaron en modelos fisiológicos que describen la dinámica de la glucosa y la insulina mediante sistemas de ecuaciones diferenciales [21]. Los modelos más conocidos son los modelos mínimos de regulación glucosa-insulina, que capturan el efecto de la sensibilidad a la insulina, la producción hepática de glucosa y la absorción de hidratos de carbono. Estos modelos ofrecen resultados interpretables y una comprensión mecanicista de la enfermedad, pero presentan limitaciones importantes: requieren calibración individual, son costosos de diseñar y carecen de escalabilidad cuando se incorporan nuevas variables. Pese a estas limitaciones, los modelos basados en ecuaciones han servido históricamente como *baseline* de referencia y continúan utilizándose en enfoques híbridos.

3.1.2. Métodos estadísticos de series temporales

Con el crecimiento de los datos CGM, los investigadores adoptaron técnicas de predicción estadística. El modelo ARIMA (*AutoRegressive Integrated Moving Average*) [22] ha sido durante décadas el estándar en análisis de series temporales y se ha aplicado a la captura de la estructura autorregresiva de la glucosa, a veces con órdenes adaptativos para abordar la no estacionariedad. Aunque interpretables y eficientes computacionalmente, estos modelos tienen dificultades para capturar dependencias no lineales y de largo alcance. Otros métodos estadísticos, como los filtros de Kalman [23] y los filtros bayesianos, también han sido aplicados con resultados variables. En general, estos enfoques alcanzan una precisión moderada para horizontes cortos (15–30 minutos) pero se degradan significativamente cuando el horizonte se amplía.

3.1.3. Aprendizaje automático clásico

La introducción de algoritmos de aprendizaje automático ofreció mayor flexibilidad para capturar relaciones no lineales. Los algoritmos más empleados incluyen la regresión de vectores de soporte (SVR) [24], los bosques aleatorios (RF), los procesos gaussianos (GP) [25] y las máquinas de aprendizaje extremo (ELM). Entre estos, los procesos gaussianos han atraído interés por su naturaleza probabilística y su capacidad para cuantificar la incertidumbre predictiva. Sin embargo, estos métodos suelen requerir características diseñadas manualmente (tendencias pasadas de glucosa, marcadores de ingesta o dosis de insulina) y no pueden explotar directamente secuencias largas en bruto. Su rendimiento es también sensible al tamaño y calidad del *dataset*, lo que ha limitado su adopción generalizada en los últimos años.

3.1.4. Aprendizaje profundo: CNN y LSTM

La última década ha estado dominada por el aprendizaje profundo, impulsado por la mayor disponibilidad de datos y los avances en arquitecturas neuronales. Estos modelos aprenden representaciones automáticamente a partir de secuencias CGM en bruto, sin requerir extracción manual de características.

Las dos familias de arquitecturas de aprendizaje profundo más utilizadas en predicción de glucosa son las redes convolucionales (CNN) y las redes recurrentes (RNN), especialmente LSTM y GRU. Las CNN unidimensionales capturan patrones temporales locales en las trayectorias de glucosa; las CNN dilatadas extienden el campo receptivo sin aumentar el número de parámetros [26]. Los modelos LSTM y GRU retienen por diseño memoria de estados pasados y capturan dependencias secuenciales. Los modelos LSTM personalizados —entrenados individualmente para cada paciente— han demostrado superar en algunos casos a los modelos globales, mientras que otros enfoques han intentado entrenar LSTM generalizados capaces de manejar cohortes heterogéneas [27].

Varios trabajos han explorado también modelos de conjunto (*ensemble*) [28], que combinan las salidas de múltiples algoritmos para mejorar la robustez, y más recientemente arquitecturas *Transformer* aplicadas a predicción glucémica [29]. Estos modelos reportan mejoras incrementales respecto a las LSTM en algunos benchmarks, aunque a costa de una mayor complejidad computacional y de una menor interpretabilidad.

3.1.5. Tendencias actuales

La evidencia disponible permite identificar las siguientes tendencias consolidadas en la literatura reciente:

- Las arquitecturas basadas en LSTM permanecen como el enfoque dominante para la predicción de glucosa a corto plazo (15–60 minutos), con un rendimiento bien documentado en múltiples *datasets* públicos.
- Los modelos híbridos que combinan distintas arquitecturas neuronales, o integran elementos fisiológicos y basados en datos, son cada vez más frecuentes.
- El interés por los modelos personalizados —que adaptan sus parámetros a la dinámica específica de cada paciente— contrasta con el de los modelos generalizables desplegados sobre poblaciones amplias [30].
- A pesar de los avances técnicos, la mayoría de los trabajos se centra en minimizar el error de predicción medio, sin explorar cómo se distribuye ese error entre distintos subgrupos de pacientes. La equidad (*fairness*), la interpretabilidad y la usabilidad clínica permanecen como dimensiones sistemáticamente subexploradas.

En resumen, la trayectoria de los modelos de predicción de glucosa ha evolucionado de métodos interpretativos pero rígidos hacia arquitecturas de aprendizaje profundo altamente flexibles. El reto pendiente no es únicamente mejorar la precisión bruta, sino comprender cómo se comportan estos modelos en distintas poblaciones de pacientes, un aspecto central para este trabajo.

3.2. *Datasets* para la predicción de glucosa

La calidad y diversidad del *dataset* juegan un papel decisivo en el éxito y la generalización de los modelos de predicción de glucosa. Esta sección revisa el panorama de *datasets* disponibles, con énfasis en sus limitaciones para el análisis de subgrupos demográficos.

3.2.1. Categorías generales de *datasets*

Los *datasets* empleados en la literatura pueden clasificarse en dos categorías principales:

Los ***datasets in-silico*** se generan mediante simuladores fisiológicos validados, siendo el más utilizado el simulador UVA/Padova T1D [31], aceptado por la FDA como sustituto de algunos ensayos clínicos. Los datos *in-silico* pueden generarse en grandes volúmenes bajo condiciones controladas, pero los pacientes simulados no capturan plenamente la complejidad de la DM1 real, por lo que los modelos entrenados exclusivamente sobre datos sintéticos frecuentemente no generalizan a entornos clínicos.

Los ***datasets del mundo real*** se obtienen directamente de pacientes con dispositivos CGM, ya sea en condiciones controladas de ensayo clínico o durante la vida libre. Son más representativos de la variabilidad real, pero más costosos y difíciles de recopilar; muchos permanecen privados y los públicos presentan limitaciones en tamaño, duración o diversidad clínica.

3.2.2. Repositorios abiertos y sus limitaciones

La disponibilidad de repositorios abiertos ha sido clave para acelerar la investigación en este campo, al permitir la reproducibilidad de resultados y proporcionar *benchmarks* comunes. Los repositorios clásicos más utilizados incluyen OhioT1DM [32] y D1NAMO [33], que involucran típicamente decenas de pacientes y semanas de datos. Aunque valiosos para el desarrollo de modelos, su reducido tamaño limita la evaluación de la generalización a subpoblaciones específicas. Esta limitación motiva la necesidad de *datasets* más amplios y diversos, capaces de capturar la variabilidad glucémica entre grupos de edad, sexos y distintos entornos clínicos. El presente trabajo se apoya en tres repositorios de este tipo.

3.2.3. *Datasets* utilizados en este trabajo

REPLACE-BG [34]: ensayo clínico aleatorizado realizado en Estados Unidos con el objetivo de evaluar si los adultos con DM1 que utilizan CGM podían reemplazar de forma segura las mediciones capilares rutinarias. El *dataset* incluye registros CGM de 226 adultos recogidos durante 182 días en un entorno altamente estructurado y controlado. Desde la perspectiva de este trabajo, REPLACE-BG es valioso porque representa condiciones de ensayo clínico estandarizadas, aunque esto implica que la variabilidad es limitada respecto a los datos de vida libre y que la diversidad demográfica es más estrecha que en *datasets* poblacionales.

DiaTrend [35]: repositorio que agrega registros de dos estudios liderados por Dartmouth: *Digital SMD* (2019), con 17 adultos de 25 a 74 años, y *SweetGoals* (en curso), con 37 adultos jóvenes de 19 a 29 años. En total, DiaTrend incluye 54 adultos con DM1, con una media de 510 días de datos CGM y de bomba de insulina por participante. La composición de la cohorte es especialmente relevante para este trabajo: incluye adultos jóvenes con mayor variabilidad glucémica y participantes de mayor edad con patrones más estables, permitiendo comparaciones entre grupos de edad.

T1DiabetesGranada [36]: uno de los mayores *datasets* abiertos de registros CGM para DM1 publicados hasta la fecha. Recogido en la Unidad Clínica de Endocrinología y Nutrición del Hospital Universitario San Cecilio (Granada, España), incluye más de 22 millones de mediciones de glucosa de 736 pacientes a lo largo de un periodo de cuatro años. A diferencia de REPLACE-BG o DiaTrend, este *dataset* refleja la práctica clínica rutinaria bajo condiciones de vida real. Su gran escala y diversidad demográfica lo hacen especialmente adecuado para analizar el rendimiento de los modelos predictivos entre subgrupos.

La tabla 3.1 resume las características de los tres *datasets* desde la perspectiva relevante para este trabajo.

Tabla 3.1: *Datasets* utilizados en este trabajo y disponibilidad de variables demográficas.

Dataset	Pacientes	Muestreo	Seguimiento	Variables demográficas
DiaTrend	54	5 min	≤ 7 años	Sexo, edad
REPLACE-BG	226	5 min	26 sem	Sexo, edad, HbA1c, duración
T1DGranada	643	15 min	≤ 4 años	Sexo, edad

3.3. Diferencias por sexo y edad en la dinámica glucémica

Antes de revisar las técnicas de balanceo demográfico, es necesario establecer la premisa fisiológica que justifica su pertinencia: si el sexo y la edad no tuvieran ninguna relación demostrable con la dinámica glucémica, equilibrar su representación en el conjunto de entrenamiento carecería de motivación clínica. La evidencia disponible indica lo contrario.

3.3.1. Diferencias por sexo

La DM1 presenta una predominancia masculina documentada en su incidencia [2], y la literatura ha identificado dimorfismo sexual en la homeostasis de la glucosa derivado de factores fisiológicos como las hormonas sexuales, la distribución de masa grasa y muscular y diferencias cromosómicas [37]. Conti et al. [38] evaluaron de forma prospectiva, en una cohorte de 176 adultos con DM1 tratados con sistemas de circuito cerrado híbrido avanzado, las diferencias por sexo en métricas CGM y variabilidad glucémica a lo largo de un año de seguimiento, encontrando diferencias sistemáticas en el control glucémico entre hombres y mujeres pese a recibir idéntica terapia.

En la misma línea, un estudio publicado en *The Lancet Diabetes & Endocrinology* documentó disparidades por sexo entre el control glucémico percibido por el paciente y el objetivo medido por CGM, señalando explícitamente la necesidad de investigar más a fondo el papel del sexo en la heterogeneidad fisiopatológica de la enfermedad [39].

3.3.2. Diferencias por edad

La dinámica glucémica difiere también de forma sustancial entre grupos etarios. En el extremo pediátrico y adolescente, un estudio sobre control glucémico en horario escolar encontró que las niñas presentaban un riesgo significativamente mayor de deterioro del control glucémico nocturno que los niños ($OR = 3.26$, $IC95\% 1.17-9.72$) [40], lo que sugiere además una interacción entre edad y sexo en la dinámica glucémica. En el extremo de mayor edad, un estudio sobre 2.260 pacientes adultos con diabetes comparó el control glucémico entre pacientes de hasta 65 años y mayores de 65 años, encontrando que solo el 23,2% de los pacientes más jóvenes alcanzaba su objetivo individualizado de TIR, frente al 69% de los pacientes mayores de 65 años [41]. Esta diferencia confirma que la edad modula el comportamiento glucémico observable en CGM y advierte de que la relación entre edad y control glucémico no es monótona ni trivial.

En conjunto, esta evidencia establece que tanto el sexo como la edad están asociados a patrones de dinámica glucémica distinguibles, lo que proporciona la motivación necesaria para estudiar si un modelo LSTM entrenado sobre una composición demográfica desequilibrada generaliza peor a los subgrupos infrarrepresentados.

3.4. Desequilibrio demográfico en modelos clínicos

3.4.1. Desequilibrio demográfico frente a desequilibrio de clase

El desarrollo de modelos de aprendizaje automático en contextos sanitarios plantea un problema distinto del desequilibrio de clases. Mientras que el desequilibrio de clases hace referencia a la proporción desigual entre las categorías de la variable objetivo, el desequilibrio demográfico se refiere a la proporción desigual de observaciones pertenecientes a distintos grupos poblacionales dentro del conjunto de entrenamiento, con independencia de cuál sea la variable objetivo del modelo. Cuando esto ocurre, los algoritmos de aprendizaje —especialmente las redes neuronales recurrentes— tienden a ajustar sus representaciones internas preferentemente a la dinámica del subgrupo mayoritario, lo que puede traducirse en una degradación sistemática del rendimiento predictivo en los subgrupos infrarrepresentados [42, 43].

Una revisión sistemática publicada en el *Journal of Clinical Epidemiology* identificó múltiples mecanismos por los cuales el sesgo se introduce en modelos clínicos, señalando el reponderado de muestras como una de las estrategias de mitigación más eficaces, con un 83% de efectividad reportada en los estudios analizados [43]. Straw y Wu [42] demostraron en un estudio de predicción de enfermedad hepática que modelos entrenados sin considerar el desequilibrio por sexo presentaban disparidades de rendimiento sistemáticas entre subgrupos, replicando inequidades clínicas ya documentadas en la literatura médica.

3.4.2. Evidencia de disparidad de rendimiento por subgrupo

La pregunta de si la composición demográfica del entrenamiento afecta al rendimiento de un modelo predictivo ha sido investigada de forma directa en varios trabajos recientes.

Wang et al. [44] analizaron datos de más de 25.000 individuos con enfermedades crónicas —incluyendo diabetes— procedentes de siete *datasets* distintos, encontrando disparidades de rendimiento predictivo sistemáticas por sexo, favoreciendo la precisión en pacientes varones, y dispa-

ridades más acusadas por edad, con mejor precisión en pacientes jóvenes y un comportamiento inconsistente en pacientes de mayor edad. Un hallazgo central de este trabajo es que **la paridad demográfica en la composición del *dataset* no garantiza por sí sola la paridad en el rendimiento del modelo resultante**: incluso conjuntos de datos demográficamente equilibrados pueden producir modelos con disparidad de rendimiento.

Yan et al. [45] propusieron un método de corrección de sesgo de representación (*double prioritized bias correction*) y lo compararon sistemáticamente contra ocho técnicas de muestreo existentes —incluyendo SMOTE y ADASYN— para mitigar disparidades de rendimiento por edad y raza en pronóstico clínico. Un resultado especialmente relevante es que las **técnicas estándar de remuestreo de clase no están diseñadas para abordar sesgos de subgrupo demográfico**, ya que muestrean toda la clase minoritaria de la variable objetivo sin diferenciar a qué subgrupo demográfico pertenece cada observación.

En el dominio específico de la predicción de glucosa mediante CGM, Ovalle et al. [46] entrenaron modelos LSTM para predecir glucosa a 60 minutos a partir de datos CGM, evaluando la disparidad de rendimiento (medida en RMSE) entre subgrupos raciales en función de la composición demográfica del conjunto de entrenamiento. Esta constituye la referencia metodológicamente más próxima al presente trabajo. La diferencia sustancial es la variable de estratificación: mientras que Ovalle et al. estudian la raza, este trabajo estudia el sexo y la edad, dos dimensiones no exploradas en dicho estudio y con fundamento fisiológico propio.

3.4.3. Técnicas de mitigación del desequilibrio demográfico

Esta sección revisa las familias de técnicas disponibles para corregir el desequilibrio en la representación de subgrupos demográficos dentro de un conjunto de entrenamiento, evaluando para cada una su fundamento, sus ventajas y limitaciones, y su compatibilidad con la restricción metodológica de este trabajo: el balanceo debe operar exclusivamente sobre las ventanas de entrenamiento, sin modificar el modelo LSTM ni su procedimiento de entrenamiento.

Reponderado de muestras (*Reweighting*)

El reponderado, propuesto originalmente por Kamiran y Calders [47], asigna un peso distinto a cada observación en función de su pertenencia a un grupo demográfico, de modo que el grupo infrarrepresentado adquiere mayor influencia relativa en la función de pérdida sin necesidad de alterar físicamente el número de observaciones:

$$w(a) = \frac{P_{\text{teórica}}(a)}{P_{\text{empírica}}(a)} = \frac{1/|A|}{n_a/N} \quad (3.1)$$

donde n_a es el número de observaciones del grupo a y N el número total. Los grupos infrarrepresentados reciben así un peso $w(a) > 1$, mientras que los sobrerrepresentados reciben $w(a) < 1$ [48, 49]. Su aplicación estándar requiere que el algoritmo de entrenamiento acepte un parámetro de peso por muestra (**sample_weight**), lo que constituye una modificación del proceso de entrenamiento. Dado que en este trabajo el balanceo debe producirse exclusivamente como una transformación de los datos de entrada, el reponderado puro **no es aplicable** salvo que se aproxime mediante remuestreo proporcional a los pesos calculados. Esta técnica está ampliamente utilizada en el ecosistema de *IBM AI Fairness 360* [50] y ha sido evaluada extensamente como referencia en estudios de equidad clínica [43].

Remuestreo dirigido por grupo demográfico

El remuestreo dirigido por grupo es la contrapartida basada en remuestreo del reponderado: se duplican (*oversampling*) o eliminan (*undersampling*) físicamente observaciones hasta alcanzar la

proporción demográfica deseada [49, 47]. A esta familia pertenecen las técnicas implementadas en este trabajo —*Random Oversampling*, *Random Undersampling*, *Patient-Aware Undersampling*, SMOTE y *Jittering*—, aplicadas sobre la distribución de ventanas por grupo demográfico en lugar de sobre la distribución de clase glucémica. Su principal ventaja es la compatibilidad total con un *pipeline* en el que el balanceo debe materializarse como una transformación de los datos de entrada sin modificar el proceso de entrenamiento posterior. El riesgo de introducir sesgos está documentado [51, 52]: el remuestreo uniforme corrige la proporción global del grupo, pero puede mantener la concentración de las muestras añadidas en un subconjunto reducido de individuos, un riesgo de pseudo-replicación especialmente relevante en *datasets* de tamaño muestral reducido como DiaTrend.

Chu et al. [53] en *JMIR Aging* describen el caso de un estudio de neuroimagen en el que se duplicaron muestras de grupos etarios sobrerrepresentados para igualar la representación de grupos etarios minoritarios, observando que un sesgo residual persistió tras el balanceo. Yan et al. [45] mostraron empíricamente que las técnicas de remuestreo estándar de clase (incluido SMOTE) ofrecen una mitigación limitada de la disparidad por subgrupo demográfico precisamente por no diferenciar el subgrupo dentro de la clase remuestreada, motivando la necesidad de aplicar el remuestreo directamente sobre la variable demográfica, como se hace en este trabajo.

Generación sintética mediante redes generativas adversarias temporales

TimeGAN [54] combina un *autoencoder* con una arquitectura GAN y un componente supervisado adicional que preserva explícitamente la dinámica temporal de las secuencias generadas. A diferencia de las GAN convencionales que tratan cada muestra como independiente, TimeGAN aprende conjuntamente un espacio latente y una dinámica de transición en dicho espacio, optimizando simultáneamente una pérdida adversaria, una pérdida de reconstrucción y una pérdida supervisada de predicción del siguiente paso temporal. La aplicabilidad a balanceo por sexo y por edad requiere generación condicionada: el generador debe condicionarse a la etiqueta de grupo demográfico del paciente de origen, de forma que las ventanas sintéticas hereden las características temporales del subgrupo infrarrepresentado. Su limitación principal es que requiere entrenar un modelo generativo adicional, lo que añade complejidad sustancial. En el dominio de sensores corporales, TS-GAN [55] y un estudio de detección de estrés mediante GAN condicionales con arquitectura LSTM [56] confirman la viabilidad técnica de generar series fisiológicas sintéticas de calidad suficiente para aumentar el entrenamiento de modelos de clasificación, si bien ninguno de los dos evalúa explícitamente el sexo o la edad como variable de balanceo.

Representaciones invariantes al atributo demográfico

Esta familia de técnicas modifica el proceso de entrenamiento añadiendo un clasificador adversario que intenta predecir el atributo demográfico sensible a partir de la representación interna de la red. El modelo principal se entrena para minimizar simultáneamente su pérdida de predicción y maximizar la pérdida del adversario [57, 58, 59]. Su limitación es decisiva para este trabajo: es por definición una técnica de *in-processing*, que exige modificar la arquitectura y el proceso de entrenamiento del modelo LSTM, lo que la sitúa **fuera del alcance metodológico** de este trabajo.

Validación cruzada con muestreo estratificado por grupo

Esta técnica garantiza que la composición demográfica del conjunto de entrenamiento sea representativa de la composición demográfica global del *dataset*, evitando que el proceso de partición en *folds* introduzca o amplifique un desequilibrio adicional al ya presente [60]. Su ventaja es

el bajo coste de implementación y un riesgo metodológico mínimo; su limitación es que por sí sola no resuelve el problema central: si la población de pacientes está intrínsecamente desequilibrada en número de ventanas por grupo, una partición estratificada simplemente replicará ese desequilibrio en cada *fold* sin corregirlo.

Comparativa de técnicas

La tabla 3.2 resume las familias de técnicas revisadas según su tipo, su compatibilidad con la restricción metodológica, su complejidad de implementación y la evidencia disponible en el dominio sanitario.

Tabla 3.2: Comparativa de técnicas para la mitigación del desequilibrio demográfico.

Técnica	Tipo	Compat. restricción	Edad/ Sexo	Complej.	Evidencia <i>Healthcare</i>
Reponderado	Pre-procesado	Parcial	Sí	Baja	Alta
Remuestreo dirigido por grupo	Pre-procesado	Sí	Sí	Baja	Alta
GAN temporal condicionada	Generativa	Sí	Sí	Alta	Media
Representaciones invariantes	In-processing	No	Sí	Alta	Alta
CV estratificada por grupo	Estructural	Sí	Sí	Baja	Media

3.5. Técnicas de balanceo en series temporales y datos médicos

La sección anterior ha revisado las técnicas de mitigación del desequilibrio demográfico desde la perspectiva de la equidad algorítmica. Esta sección complementa esa revisión examinando la literatura específica sobre técnicas de balanceo aplicadas a series temporales clínicas y, cuando existe evidencia directa, a la predicción de glucosa.

3.5.1. Balanceo en datos de series temporales: estado de la cuestión

La aplicación de técnicas de remuestreo a series temporales plantea desafíos específicos que no se presentan en datos tabulares independientes. El principal es la preservación de la autocorrelación temporal y de las propiedades distribucionales de la serie: duplicar una ventana temporal introduce redundancia exacta que puede sesgar la estimación de las autocorrelaciones durante el entrenamiento; interpolar mediante SMOTE entre ventanas de distintos pacientes puede generar trayectorias fisiológicamente implausibles.

En el contexto de la predicción de glucosa, la aplicación de SMOTE a los rangos glucémicos minoritarios (hipoglucemia, hiperglucemia severa) ha sido estudiada como estrategia para mejorar el rendimiento del modelo en los eventos clínicamente más relevantes.

En el contexto específico de datos glucémicos, el trabajo de Machado et al. [61] constituye la referencia más completa hasta la fecha sobre el impacto de los métodos de balanceo en minería

de datos basada en señales CGM. Los autores evaluaron una batería amplia de técnicas de sobre-muestreo (*random oversampling*, SMOTE, Borderline-SMOTE, ADASYN), submuestreo (*near miss*, ENN, *Tomek links*) e híbridas (SMOTE+ENN, SMOTE+*Tomek*) sobre los conjuntos de datos Ohio y St. Louis, abordando el problema como clasificación de episodios glucémicos (hipoglucemia, normoglucemia, hiperglucemia). Sus resultados muestran que, contrariamente a la intuición, las técnicas de sobremuestreo aisladas no producen mejoras consistentes: la limpieza de la frontera de decisión aportada por los métodos de submuestreo —en particular ENN— resulta tan o más determinante que la generación de ejemplos sintéticos. La combinación SMO-TE+ENN es la que mayor robustez exhibe a lo largo de todos los experimentos, alcanzando ganancias de hasta un 21 % en F1 para hipoglucemia respecto a la condición sin balanceo en la validación *leave-one-out* sobre datos CGM. Los autores también señalan que el impacto del balanceo es irregular entre rangos glucémicos: las ganancias son pronunciadas para hipoglucemia e hiperglucemia, pero modestas para normoglucemia, anticipando la heterogeneidad por rango que se analiza sistemáticamente en el presente trabajo.

3.5.2. Balanceo demográfico en series temporales fisiológicas

En el dominio de las señales fisiológicas de series temporales —electrocardiogramas, registros de actividad, señales CGM— la mayoría de los trabajos sobre desequilibrio se han centrado en el desequilibrio de clase de la variable objetivo (p. ej., detección de arritmias en señales ECG con clases minoritarias muy infrecuentes), no en el desequilibrio de la composición demográfica del conjunto de entrenamiento.

Sin embargo, algunos trabajos recientes constituyen excepciones relevantes. Ovalle et al. [46] —revisado en la sección anterior— aplican balanceo demográfico por raza en ventanas CGM para LSTM de predicción de glucosa. En el dominio de señales de actividad y estrés, Dahmen et al. [56] entrenan GAN condicionales sobre señales de sensores corporales para generar muestras sintéticas de subgrupos infrarrepresentados, si bien el atributo de balanceo es la clase de actividad, no un atributo demográfico.

La evidencia empírica más directa de que la composición demográfica del conjunto de entrenamiento afecta al rendimiento de modelos LSTM de predicción de glucosa sobre señales CGM proviene de Thomsen et al. [62]. En un diseño experimental riguroso, los autores entrenaron modelos LSTM sobre 11 configuraciones de datos construidas variando la proporción de participantes de raza blanca (*non-Hispanic White*) y raza negra (*non-Hispanic Black*) entre 0 % y 100 %, utilizando datos CGM de 205 participantes con DM1 recogidos por el centro JAEB. Los resultados del modelo generalizado (*Base-Generalized*) revelan una interacción estadísticamente significativa ($p = 0.02$) entre la raza y la proporción racial del conjunto de entrenamiento: a medida que aumenta la proporción de participantes blancos, el RMSE crece 0.04 mmol/L más en los participantes negros que en los blancos, es decir, el modelo favorece progresivamente al grupo mayoritario en entrenamiento. Esta disparidad desaparece al aplicar *transfer learning* personalizado ($p = 0.20$), lo que sugiere que la personalización es una estrategia complementaria eficaz. El estudio también encuentra que la edad es un predictor significativo del error ($p < 0.001$): la predicción de glucosa en niños produce errores sistemáticamente mayores que en adultos, independientemente de la raza o la composición del entrenamiento. Esta evidencia establece que la composición demográfica del conjunto de entrenamiento no es un factor neutral en los modelos de predicción CGM y que atributos como la edad constituyen una fuente de heterogeneidad que merece intervención explícita, motivando directamente el enfoque de balanceo por edad y por sexo adoptado en el presente trabajo.

3.5.3. Generación sintética de series temporales fisiológicas

La generación de series temporales sintéticas mediante modelos generativos profundos ha recibido atención creciente en los últimos años como alternativa al remuestreo exacto o a la interpolación lineal. Las familias de modelos más relevantes son las GAN temporales (TimeGAN [54], TS-GAN [55]), los modelos de difusión sobre series temporales [63] y los *variational autoencoders* condicionales.

En el dominio de la diabetes y la glucosa específicamente, la generación de pacientes sintéticos se ha explorado principalmente como estrategia de aumento de datos para mejorar el rendimiento global del modelo, no como mecanismo de balanceo demográfico:

Una línea de trabajo emergente propone la generación sintética condicional de series temporales médicas como estrategia para compensar el desequilibrio de subpoblaciones en los conjuntos de entrenamiento. Bing et al. [64] presentan HEALTHGEN, un modelo generativo basado en VAE secuencial que permite sintetizar historiales clínicos longitudinales condicionados sobre variables estáticas del paciente —incluyendo edad, sexo y etnia— respetando además los patrones de datos ausentes de los registros reales. Los autores demuestran sobre el conjunto MIMIC-III que la generación condicional de cohortes de subpoblaciones infrarrepresentadas y su incorporación al conjunto de entrenamiento mejora significativamente la equidad de los modelos resultantes, elevando el rendimiento en los grupos minoritarios sin degradar el de los grupos mayoritarios. Esta aproximación es conceptualmente análoga a la filosofía del balanceo demográfico explorado en el presente trabajo, si bien opera sobre la distribución de pacientes completos (generación a nivel de sujeto) en lugar de sobre la distribución de ventanas temporales (balanceo a nivel de instancia de entrenamiento). La ausencia de un modelo de generación condicional específicamente validado para señales CGM con atributos de edad y sexo como factores de condicionamiento constituye una de las brechas que delimitan la contribución del presente trabajo.

El trabajo más directamente relacionado con el diseño experimental del presente estudio es el de Mayo et al. [?], que introduce dos contribuciones metodológicas relevantes. La primera es la propuesta de métricas de error *glucemia-conscientes*: en lugar de evaluar el RMSE o el MARD sobre el rango completo, los autores desagregan el error por rango glucémico (hipoglucemia, normoglucemia, hiperglucemia), demostrando que la selección del mejor modelo varía sustancialmente según el rango considerado. La segunda es la aplicación de técnicas de sobremuestreo (*random oversampling*, SMOTE, ADASYN) al problema de regresión glucémica sobre el conjunto OhioT1DM, para lo cual adaptan las etiquetas de clase mediante *pseudolabels* basados en los rangos glucémicos. Sus resultados muestran que las redes MLP entrenadas con sobremuestreo superan a los modelos lineales en el rango hipoglucémico, con diferencias estadísticamente significativas ($p = 0.025$) frente al mejor modelo sin balanceo, mientras que para el rango normoglucémico el modelo lineal sin balanceo es más competitivo. Esta asimetría por rango sugiere que el impacto del balanceo no es uniforme a lo largo de la escala glucémica, lo que anticipa la necesidad de analizar el rendimiento desagregado por rango que se adopta como eje central del análisis de resultados en este trabajo. No obstante, Mayo et al. abordan el desequilibrio de clase glucémica —la distribución desigual de valores objetivo entre rangos— y no el desequilibrio demográfico del conjunto de entrenamiento, que es el objeto específico de esta investigación.

El estudio de Thomsen et al. [62], ya citado en la sección 2.3.3, proporciona además la única evidencia disponible de disparidad de rendimiento por subgrupo demográfico en predicción de glucosa con modelos LSTM sobre señales CGM reales, confirmando que la composición racial del entrenamiento produce efectos mesurables y estadísticamente significativos. La extensión de este análisis a las dimensiones de sexo y edad en una taxonomía sistemática de técnicas de balanceo —en lugar de limitarse a la composición racial del conjunto de entrenamiento— constituye la principal brecha que el presente trabajo aborda.

3.6. Brechas en la literatura y motivación del trabajo

La revisión anterior permite identificar tres brechas específicas que motivan y delimitan la contribución de este trabajo.

Primera brecha: el único estudio de disparidad demográfica en predicción de glucosa con LSTM sobre señales CGM se restringe a la dimensión racial y no cubre sexo ni grupos de edad. La evidencia de que la composición demográfica del conjunto de entrenamiento afecta al rendimiento de modelos de predicción en DM1 ha quedado establecida recientemente por Thomsen et al. [62], que demostraron una divergencia estadísticamente significativa en el RMSE entre participantes blancos y negros al variar la proporción racial del conjunto de entrenamiento de modelos LSTM sobre datos CGM. Sin embargo, ese estudio no evalúa las dimensiones de sexo ni de edad, pese a que la sección 3.3 establece que ambas variables están asociadas a diferencias fisiológicas demostrables en la dinámica glucémica [?]. La propia discusión de Thomsen et al. señala explícitamente que “*Future studies on investigating algorithmic fairness by other sensitive attributes are warranted*”, identificando sexo y edad como las dimensiones prioritarias de análisis. Este trabajo responde directamente a esa llamada, evaluando por primera vez y de forma sistemática la disparidad de rendimiento predictivo por sexo y por grupos de edad en modelos LSTM de predicción de glucosa sobre datos CGM, junto con estrategias de mitigación mediante balanceo.

Segunda brecha: las técnicas de remuestreo aplicadas a predicción de glucosa corrigen el desequilibrio de clase glucémica, no la composición demográfica del conjunto de entrenamiento. Los trabajos de Machado et al. [61] y Mayo et al. [?] demuestran que el balanceo del conjunto de entrenamiento mejora el rendimiento de los modelos de predicción glucémica, especialmente en los rangos de hipoglucemia. No obstante, en ambos casos la variable remuestreada es la clase glucémica de la variable objetivo (hipoglucemia, normoglucemia, hiperglucemia): se trata de corregir cuántas ventanas de entrenamiento pertenecen a cada rango de glucosa, no cuántas proceden de cada subgrupo demográfico. Esta distinción es conceptualmente fundamental: un conjunto de entrenamiento puede estar perfectamente equilibrado en la distribución de rangos glucémicos y, al mismo tiempo, presentar un desequilibrio severo en la proporción de ventanas procedentes de distintos grupos de edad o sexo. Las técnicas de balanceo estándar —incluyendo SMOTE y sus variantes— no diferencian ni corrigen este desequilibrio demográfico porque fueron diseñadas para operar sobre la variable objetivo, no sobre los atributos del sujeto que generó los datos. Este trabajo aplica explícitamente estas mismas técnicas redefiniendo la unidad de balanceo: en lugar de operar sobre la distribución de clases glucémicas, se opera sobre la distribución de grupos demográficos (sexo o grupo de edad) dentro del conjunto de entrenamiento, una distinción metodológica que la literatura señala como necesaria pero que no ha sido implementada ni evaluada de forma sistemática en el contexto de predicción de glucosa.

Tercera brecha: la literatura de equidad algorítmica en salud no contempla la distinción entre balanceo a nivel de paciente y balanceo a nivel de ventana temporal. Los trabajos existentes sobre disparidad demográfica en aprendizaje automático clínico, incluido el de Thomsen et al. [62], operan sobre observaciones donde la unidad de análisis es el paciente o el episodio clínico discreto. En el contexto de series temporales generadas mediante ventana deslizante sobre señales CGM, la unidad de balanceo efectiva no es el paciente sino la ventana: un mismo paciente con una serie temporal larga y densa puede aportar órdenes de magnitud más ventanas de entrenamiento que otro paciente con una serie corta o fragmentada, incluso perteneciendo ambos al mismo grupo demográfico nominal. En consecuencia, el desequilibrio demográfico en el conjunto de ventanas puede ser cualitativamente distinto —y a menudo más severo— que el desequilibrio a nivel de paciente, y ambos niveles pueden divergir por razones

ajenas a la composición demográfica de la cohorte, como el patrón de datos ausentes o la heterogeneidad en el tiempo de seguimiento entre pacientes. La gestión de esta distinción entre balanceo a nivel de paciente y balanceo a nivel de ventana, y su impacto sobre el rendimiento y la equidad del modelo resultante, no ha sido abordada en ninguno de los trabajos revisados.

Este trabajo se sitúa en la intersección de estas tres brechas: aplica un conjunto sistemático de técnicas de balanceo demográfico —adaptadas explícitamente a la unidad de ventana temporal en lugar de a la unidad de paciente— para evaluar empíricamente, en tres *datasets* públicos de DM1 y mediante un modelo LSTM de referencia validado, si la corrección de la composición demográfica del conjunto de entrenamiento por sexo y por edad mejora el rendimiento predictivo y reduce la disparidad entre subgrupos en la predicción de glucosa, con especial atención a los rangos glucémicos clínicamente críticos.

Capítulo 4

Desarrollo del trabajo

Este capítulo describe en detalle el proceso completo llevado a cabo para abordar la pregunta de investigación planteada en el capítulo . Se sigue el orden cronológico y lógico del trabajo: desde la recopilación y comprensión de los datos hasta la construcción del *pipeline* de entrenamiento y evaluación que produce los resultados analizados en el capítulo 5. Cada sección documenta las decisiones de diseño adoptadas, las alternativas consideradas y los criterios que motivaron la elección final, con el objetivo de garantizar la reproducibilidad del trabajo y la trazabilidad de cada decisión metodológica.

La figura ?? ofrece una visión de conjunto del flujo de trabajo completo, que se detalla a lo largo de las secciones siguientes.

4.1. Recopilación y descripción de los datos

Esta sección describe el proceso de recopilación de los tres conjuntos de datos utilizados en el trabajo, los criterios de selección que motivaron su elección y las características estructurales relevantes de cada uno de ellos desde el punto de vista del problema de balanceo demográfico. La descripción clínica y demográfica de los *datasets* se introduce en el capítulo 2.3.4; aquí se documentan los aspectos prácticos de su obtención y las particularidades que condicionaron las decisiones de preprocesado posteriores.

4.1.1. Criterios de selección de los *datasets*

4.1.2. T1DiabetesGranada

4.1.3. REPLACE-BG

4.1.4. DiaTrend

4.1.5. Estructura unificada de datos de entrada

4.2. Análisis exploratorio de datos

Antes de proceder a la construcción del *pipeline* experimental, se realizó un análisis exploratorio de datos (EDA) con dos objetivos: comprender las propiedades estadísticas y estructurales de cada *dataset*, y obtener evidencia cuantitativa de la presencia —o ausencia— de desequilibrio demográfico en la composición de los datos de partida. Este análisis es el que justifica y motiva las decisiones de diseño del *pipeline* de balanceo descritas en la sección ??.

4.2.1. Distribución demográfica de los *datasets*

4.2.2. Distribución de la señal CGM

4.2.3. Análisis de datos ausentes

4.2.4. Análisis de separabilidad demográfica

4.3. Detección y cuantificación del desequilibrio demográfico

Una vez comprendidas las propiedades estructurales de los *datasets* a nivel de paciente, el siguiente paso es cuantificar el desequilibrio demográfico a nivel de **ventana de entrenamiento**, que es la unidad de balanceo relevante en este trabajo. Como se argumenta en la sección 2.3.3, la unidad de balanceo en el contexto de series temporales generadas mediante ventana deslizante no es el paciente sino la ventana, y el desequilibrio a nivel de ventana puede ser sustancialmente mayor que el desequilibrio a nivel de paciente.

4.3.1. Desequilibrio a nivel de paciente frente a nivel de ventana

4.3.2. Desequilibrio por dimensión demográfica y *fold*

4.4. Investigación de técnicas de balanceo para series temporales

La selección de las técnicas de balanceo a implementar requirió una fase de investigación específica orientada a evaluar la compatibilidad de las técnicas estándar de *imbalanced learning* con las restricciones propias de la señal CGM. Esta sección describe los criterios de selección y la taxonomía de técnicas resultante.

4.4.1. Criterios de selección de técnicas

4.4.2. Taxonomía de técnicas implementadas

Familia aleatoria

Familia guiada

Familia híbrida

4.4.3. Validación formal del *pipeline* de balanceo

4.5. Transformación de datos: generación de ventanas deslizantes

La transformación de las series temporales CGM originales en el formato de entrada requerido por el modelo LSTM es un paso crítico del *pipeline*, ya que determina la granularidad de la unidad de balanceo y la forma en que se materializan las particiones de validación cruzada. Esta sección describe el proceso de generación de ventanas y sus parámetros.

4.5.1. Parámetros de ventana

4.5.2. Restricciones de continuidad temporal

4.5.3. Esquema de partición: *Group K-Fold* con $K = 5$

4.6. Análisis exploratorio de ventanas

Una vez generadas las ventanas, se realizó un segundo análisis exploratorio centrado en las propiedades de la distribución de ventanas resultante, distinto del EDA sobre la señal CGM bruta descrito en la sección 4.2. Este análisis tiene como objetivo caracterizar el desequilibrio demográfico a nivel de ventana —la unidad de balanceo efectiva del *pipeline*— y verificar que las propiedades de las ventanas son coherentes con las restricciones metodológicas.

4.6.1. Distribución de ventanas por grupo demográfico y *fold*

4.6.2. Distribución de la variable objetivo por grupo demográfico

4.6.3. Verificación de integridad de las particiones

4.7. Arquitectura del modelo LSTM

El modelo de predicción de glucosa utilizado en este trabajo es una red LSTM de una sola capa recurrente con una capa densa de salida lineal. La elección de esta arquitectura está motivada por su consolidación en la literatura de predicción de glucosa (véase capítulo 2.3.4) y por el objetivo de este trabajo, que no es optimizar la arquitectura del modelo sino cuantificar el efecto del balanceo del conjunto de entrenamiento sobre un modelo de referencia bien establecido.

4.7.1. Especificación de la arquitectura

4.7.2. Función de pérdida y optimizador

4.7.3. Estrategia de entrenamiento

4.7.4. Configuración del entorno de ejecución

4.8. *Pipeline* de entrenamiento y evaluación

Esta sección describe el *pipeline* completo de entrenamiento y evaluación, integrando todos los componentes descritos en las secciones anteriores. Se detalla el flujo de datos desde los archivos *parquet* de entrada hasta los archivos de métricas que alimentan el análisis estadístico del capítulo 5.

4.8.1. Modo original y modo balanceado

4.8.2. Flujo de datos por *fold*

4.8.3. Evaluación por rango glucémico

4.8.4. Agregación de resultados y protocolo estadístico

4.8.5. Trazabilidad y reproducibilidad

Capítulo 5

Resultados y discusión

Aquí se discutirán los resultados, tablas de datos y gráficas.

Por ejemplo, la Tabla 5.1, muestra un ejemplo de como introducir tablas de forma limpia en el texto.

Tabla 5.1: Mi tabla grande con cabeceras en negrita

Categoría	Valor 1	Valor 2	Valor 3
Fruta 1	5	10	15
Fruta 2	8	12	18
Verdura 1	3	6	9
Verdura 2	4	7	11
Bebida 1	1	2	3
Bebida 2	6	9	12

Fíjate que tanto tablas como imágenes, deben estar previamente referenciadas en el texto, y no deben separarse mucho de éste. Fíjate también en como se crean títulos reducidos para que el texto del pie de tabla no ocupe demasiado en el índice.

Las tablas enormes como la Tabla 5.2, deben intentar colocarse en una página aparte.

Lo mismo se puede hacer con las gráficas. Pero ten cuidado de que las gráficas no se vayan lejos del texto tampoco. Vamos a poner un ejemplo para que no nos moleste la tabla anterior, vamos a forzar una nueva página.

Tabla 5.2: Mfi tabla enorme de poblaci3n

Categoría	Valor 1	Valor 2	Valor 3	Valor 4	Valor 5	Valor 6	Valor 7	Valor 8	Valor 9	Valor 10
Ecuador	5	10	15	20	25	30	35	40	45	
Nicaragua	8	12	18	24	30	36	42	48	54	
Honduras	3	6	9	12	15	18	21	24	27	
Argentina	4	7	11	15	19	23	27	31	35	
Venezuela	1	2	3	4	5	6	7	8	9	
Colombia	6	9	12	15	18	21	24	27	30	
Chile	2	4	6	8	10	12	14	16	18	
España	7	11	15	19	23	27	31	35	39	

Se deben evitar imágenes “por poner”¹, como la Figura 5.1. Que es un logotipo.



Figura 5.1: Mi logo

Por ejemplo, la Figura 5.2 sí que está correcta, y va de la misma forma que la tabla, y ahora está cerca del texto. Hemos sacrificado un poco de espacio al final de la página anterior a cambio de acercar la figura al texto. Esto solo debe hacerse en casos en que tengamos tablas y figuras que ocupen la página completa.

El tipo de extensiones ya está definido, así que no deben usarse a la hora de referenciar imágenes. Por defecto el orden es:

1. PDF: Son gráficos vectoriales con máxima calidad, bueno para esquemas y tablas.
2. PNG: Son gráficos que no pierden calidad, aunque son gráficos *raster* o matriciales. Utilízalos cuando los tonos sean planos, como en esquemas, en sustitución de los PDF cuando no tenemos opción a usar gráficos vectoriales.
3. JPEG: Con extensión **.jpg**, se suelen usar cuando son fotografías, principalmente, ya que pueden contener *artifacts*.

¹Por cierto, fíjate en cómo van las comillas. Aunque es mejor usar cursivas. Las palabras en inglés, por ejemplo, deberían ir en *cursiva*, como por ejemplo *buffer*.




Figura 5.2: Lista de distribuciones: Aquí iría una descripción de la figura para cada fila o columna, explicando los parámetros. Fíjate como el pie está recortado en el índice para que no sea extremadamente largo. Si hay una fuente, la podemos colocar aquí: <https://drive.google.com/file/d/14YN87TAF60Qq6JIuZiUz3YHn-6Pz8KHm/view?usp=sharing>

Capítulo 6

Conclusiones

Debes describir las conclusiones generales del trabajo, pero también debes cubrir qué objetivos se han cubierto. Para ello revisa la sección de [Objetivos](#) (Sección 1.2). Por último cierra el trabajo, y si tienes planes de continuar, menciona los trabajos futuros.

Bibliografía

- [1] M. A. Atkinson, G. S. Eisenbarth, and A. W. Michels, “Type 1 diabetes,” *The Lancet*, vol. 383, no. 9911, pp. 69–82, 2014.
- [2] J. Divers, E. J. Mayer-Davis, J. M. Lawrence, S. Isom, D. Dabelea, L. Dolan, G. Imperatore, S. Marcovina, D. J. Pettitt, C. Pihoker, R. F. Hamman, S. Saydah, and L. E. Wagenknecht, “Trends in incidence of type 1 and type 2 diabetes among youths — selected counties and indian reservations, united states, 2002–2015,” *MMWR. Morbidity and Mortality Weekly Report*, vol. 69, no. 6, pp. 161–165, 2020.
- [3] Sociedad Española de Diabetes, “Informe sobre la prevalencia e incidencia de la diabetes en españa.” <https://www.sediabetes.org>, 2023. Accedido en 2025.
- [4] B. Kovatchev, “Metrics for glycaemic control — from HbA1c to continuous glucose monitoring,” *Nature Reviews Endocrinology*, vol. 13, no. 7, pp. 425–436, 2019.
- [5] M. Brownlee, “The pathobiology of diabetic complications: A unifying mechanism,” *Diabetes*, vol. 54, no. 6, pp. 1615–1625, 2005.
- [6] D. C. Klonoff, D. Ahn, and A. Drincic, “Continuous glucose monitoring: a review of the technology and clinical use,” *Diabetes Research and Clinical Practice*, vol. 133, pp. 178–192, 2017.
- [7] K. Rebrin, G. M. Steil, W. P. van Antwerp, and J. J. Mastrototaro, “Subcutaneous glucose predicts plasma glucose independent of insulin: Implications for continuous monitoring,” *American Journal of Physiology — Endocrinology and Metabolism*, vol. 277, no. 3, pp. E561–E571, 2000.
- [8] T. Battelino, T. Danne, R. M. Bergenstal, *et al.*, “Clinical targets for continuous glucose monitoring data interpretation: recommendations from the international consensus on time in range,” *Diabetes Care*, vol. 42, no. 8, pp. 1593–1603, 2019.
- [9] W. L. Clarke, D. Cox, L. A. Gonder-Frederick, W. Carter, and S. L. Pohl, “Evaluating clinical accuracy of systems for self-monitoring of blood glucose,” *Diabetes Care*, vol. 10, no. 5, pp. 622–628, 1987.
- [10] D. E. Rumelhart, G. E. Hinton, and R. J. Williams, “Learning representations by back-propagating errors,” *Nature*, vol. 323, no. 6088, pp. 533–536, 1986.
- [11] Y. Bengio, P. Simard, and P. Frasconi, “Learning long-term dependencies with gradient descent is difficult,” *IEEE Transactions on Neural Networks*, vol. 5, no. 2, pp. 157–166, 1994.
- [12] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

- [13] G. Sparacino, F. Zanderigo, S. Corazza, *et al.*, “Glucose concentration can be predicted ahead in time from continuous glucose monitoring sensor time-series,” *IEEE Transactions on Biomedical Engineering*, vol. 54, no. 5, pp. 931–937, 2007.
- [14] scikit-learn developers, “GroupKFold — scikit-learn 1.4 documentation.” https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupKFold.html, 2024. Accedido en 2025.
- [15] H. He and E. A. Garcia, “Learning from imbalanced data,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, no. 9, pp. 1263–1284, 2009.
- [16] P. Branco, L. Torgo, and R. P. Ribeiro, “A survey of predictive modelling under imbalanced distributions,” *ACM Computing Surveys*, vol. 49, no. 2, pp. 31:1–31:50, 2016.
- [17] A. Fernández, S. García, M. Galar, R. C. Prati, B. Krawczyk, and F. Herrera, *Learning from Imbalanced Data Sets*. Springer, 2018.
- [18] I. Tomek, “Two modifications of CNN,” *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 6, no. 11, pp. 769–772, 1976.
- [19] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, “Smote: Synthetic minority over-sampling technique,” *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.
- [20] G. E. A. P. A. Batista, R. C. Prati, and M. C. Monard, “A study of the behavior of several methods for balancing machine learning training data,” *ACM SIGKDD Explorations Newsletter*, vol. 6, no. 1, pp. 20–29, 2004.
- [21] R. N. Bergman, Y. Z. Ider, C. R. Bowden, and C. Cobelli, “Quantitative estimation of insulin sensitivity,” *American Journal of Physiology-Endocrinology and Metabolism*, vol. 236, no. 6, pp. E667–E677, 1979.
- [22] J. Contreras, R. Espínola, F. J. Nogales, and A. J. Conejo, “ARIMA models to predict next-day electricity prices,” *IEEE Transactions on Power Systems*, vol. 18, no. 3, pp. 1014–1020, 2003. Referencia metodológica seminal para modelos ARIMA en series temporales. Para aplicación específica a glucosa, véase también Sparacino *et al.* (2007).
- [23] J. Reifman, S. Rajaraman, A. Gribok, and W. K. Ward, “Predictive monitoring for improved management of glucose levels,” *Journal of Diabetes Science and Technology*, vol. 1, no. 4, pp. 478–486, 2007.
- [24] S. M. Pappada, B. D. Cameron, P. M. Rosman, and T. J. Papadimos, “Development of a neural network for prediction of glucose concentration in type 1 diabetes patients,” *Journal of Diabetes Science and Technology*, vol. 2, no. 5, pp. 792–801, 2008.
- [25] M. Fraccaro, D. Bhatt, U. Bhatt, and M. Welling, “Prediction of blood glucose concentration in type 1 diabetes using kernel adaptive filtering,” in *Proceedings of the NIPS 2016 Workshop on Machine Learning for Health*, 2016. Disponible en: <https://arxiv.org/abs/1612.00901>.
- [26] K. Li, C. Liu, T. Zhu, P. Herrero, and P. Georgiou, “Glunet: a deep learning framework for accurate glucose forecasting,” *IEEE Journal of Biomedical and Health Informatics*, vol. 24, no. 2, pp. 414–423, 2019.

- [27] S. Mirshekarian, H. Shen, R. Bunescu, and C. Marling, “Lstms and neural attention models for blood glucose prediction: comparative experiments on real and synthetic data,” 2019.
- [28] V. Naumova, S. V. Pereverzyev, and S. Sivananthan, “A meta-learning approach to the regularized learning—case study: Blood glucose prediction,” *Neural Networks*, vol. 33, pp. 181–193, 2012.
- [29] Z. Li, S. Vyas, I. Kang, J. Wu, and A. E. Solomonides, “GluCTx: Glucose prediction leveraging transformer architecture with contextual data,” *arXiv preprint*, 2023. arXiv:2311.01232. Disponible en: <https://arxiv.org/abs/2311.01232>.
- [30] S. Oviedo, J. Vehí, R. Calm, and J. Armengol, “A review of personalized blood glucose prediction strategies for T1DM patients,” *International Journal for Numerical Methods in Biomedical Engineering*, vol. 33, no. 6, 2017.
- [31] C. D. Man, F. Micheletto, D. Lv, M. Breton, B. Kovatchev, and C. Cobelli, “The UVA/PADOVA type 1 diabetes simulator: New features,” *Journal of Diabetes Science and Technology*, vol. 8, no. 1, pp. 26–34, 2014.
- [32] C. Marling and R. Bunescu, “The OhioT1DM dataset for blood glucose level prediction: update 2020,” 2020.
- [33] F. Dubosson, J.-E. Ranvier, S. Bromuri, *et al.*, “The open D1NAMO dataset: a multi-modal dataset for research on non-invasive type 1 diabetes management,” *Informatics in Medicine Unlocked*, vol. 13, pp. 92–100, 2018.
- [34] G. Aleppo, K. L. Ruedy, T. T. Riddlesworth, *et al.*, “REPLACE-BG: A randomized trial comparing continuous glucose monitoring with and without routine blood glucose monitoring in adults with well-controlled type 1 diabetes,” *Diabetes Care*, vol. 40, no. 4, pp. 538–545, 2017.
- [35] Q. Sun, T. S. Bhatt, R. Nambhore, *et al.*, “DIATREND: A multivariate longitudinal clinical dataset of type 1 diabetes patients to advance glucose forecasting,” *Scientific Data*, vol. 10, no. 1, p. 612, 2023.
- [36] J. D. Díaz-López, R. Capel-Delgado, *et al.*, “T1diabetesgranada dataset,” 2023.
- [37] F. Mauvais-Jarvis *et al.*, “Sex differences in glucose homeostasis,” *Sex and Gender Effects in Pharmacology, Handbook of Experimental Pharmacology*, 2023.
- [38] M. Conti, I. Gironi, E. Meneghini, E. Mion, G. D. Vieste, F. Bertuzzi, and B. Pintaudi, “Sex differences in continuous glucose monitoring metrics and glucose variability in subjects with type 1 diabetes treated with advanced hybrid closed loop therapy: An observational, retrospective, one-year follow-up study,” *Journal of Clinical Medicine*, vol. 14, no. 24, p. 8823, 2025.
- [39] A. A. van der Heijden *et al.*, “Sex-based disparities in perceived versus objective glycaemic control in type 1 diabetes: a cross-sectional cohort study,” *The Lancet Diabetes & Endocrinology*, 2025. PIIS2213-8587(25)00136-6.
- [40] F. Deng *et al.*, “Deterioration in glycemic control on schooldays among children and adolescents with type 1 diabetes: a continuous glucose monitoring-based study,” *PMC9768037*, 2022.

- [41] M. Nwokolo *et al.*, “Glycaemic outcomes in people living with diabetes under 65 and over 65 years old using an intermittently scanned continuous glucose monitoring system,” *Journal of Diabetes Science and Technology*, 2024. PMC11337186.
- [42] I. Straw and H. Wu, “Investigating for bias in healthcare algorithms: a sex-stratified analysis of supervised machine learning models in liver disease prediction,” *BMJ Health & Care Informatics*, vol. 29, no. 1, 2022.
- [43] M. A. R. Lara *et al.*, “Sociodemographic bias in clinical machine learning models: a scoping review of algorithmic bias instances and mechanisms,” *Journal of Clinical Epidemiology*, 2024.
- [44] Y. Wang *et al.*, “Disparate model performance and stability in machine learning clinical support for diabetes and heart diseases,” 2024. arXiv:2412.19495.
- [45] C. Yan *et al.*, “Subpopulation-specific machine learning prognosis for underrepresented patients with double prioritized bias correction,” *Communications Medicine*, vol. 2, p. 121, 2022.
- [46] A. O. Aguilar *et al.*, “Racial disparities in continuous glucose monitoring-based 60-min glucose predictions among people with type 1 diabetes,” *medRxiv preprint*, 2024.
- [47] F. Kamiran and T. Calders, “Data preprocessing techniques for classification without discrimination,” *Knowledge and Information Systems*, vol. 33, no. 1, pp. 1–33, 2012.
- [48] I. Žliobaitė, “Measuring discrimination in algorithmic decision making,” *Data Mining and Knowledge Discovery*, vol. 31, no. 4, pp. 1060–1089, 2017.
- [49] J. Wiśniewski and P. Biecek, “fairmodels: A flexible tool for bias detection, visualization, and mitigation,” 2021. arXiv:2104.00507.
- [50] R. K. E. Bellamy *et al.*, “Ai fairness 360: An extensible toolkit for detecting, understanding, and mitigating unwanted algorithmic bias,” 2018. arXiv:1810.01943.
- [51] E. Krasanakis, E. Spyromitros-Xioufis, S. Papadopoulos, and Y. Kompatsiaris, “Adaptive sensitive reweighting to mitigate bias in fairness-aware classification,” in *Proceedings of the 2018 World Wide Web Conference (WWW)*, 2018.
- [52] M. A. Ahmad *et al.*, “Algorithm fairness in ai for medicine and healthcare,” 2021. arXiv:2110.00603.
- [53] C. Chu, S. Donato-Woodger, S. S. Khan, T. Shi, K. Leslie, S. Abbasgholizadeh-Rahimi, R. Nystrup, and A. Grenier, “Strategies to mitigate age-related bias in machine learning: Scoping review,” *JMIR Aging*, vol. 7, p. e53564, 2024.
- [54] J. Yoon, D. Jarrett, and M. van der Schaar, “Time-series generative adversarial networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.
- [55] H. Dong *et al.*, “Ts-gan: Time-series gan for sensor-based health data augmentation,” *ACM Transactions on Computing for Healthcare*, 2023.
- [56] J. Dahmen *et al.*, “A conditional gan for generating time series data for stress detection in wearable physiological sensor data,” *Sensors*, vol. 22, no. 16, p. 5969, 2022.
- [57] C. Louizos, K. Swersky, Y. Li, M. Welling, and R. Zemel, “The variational fair autoencoder,” in *International Conference on Learning Representations (ICLR)*, 2016.

- [58] H. Edwards and A. Storkey, “Censoring representations with an adversary,” in *International Conference on Learning Representations (ICLR)*, 2016.
- [59] R. Zemel, Y. Wu, K. Swersky, T. Pitassi, and C. Dwork, “Learning fair representations,” in *Proceedings of the 30th International Conference on Machine Learning (ICML)*, 2013.
- [60] J. Yang *et al.*, “Dataset representativeness and downstream task fairness,” 2024. arXiv:2407.00170.
- [61] D. Machado, V. Santos Costa, and P. Brandão, “Using balancing methods to improve glycaemia-based data mining,” in *Proceedings of the 16th International Joint Conference on Biomedical Engineering Systems and Technologies (BIOSTEC 2023), Volume 5: HEALTHINF*, pp. 188–198, 2023.
- [62] H. B. Thomsen, L. Y. Li, A. A. Isaksen, B. Lebiecka-Johansen, C. Bour, G. Fagherazzi, W. P. T. M. van Doorn, T. V. Varga, and A. Hulman, “Racial disparities in continuous glucose monitoring-based 60-min glucose predictions among people with type 1 diabetes,” *PLOS Digital Health*, vol. 4, no. 6, p. e0000918, 2025.
- [63] Y. Tashiro, J. Song, Y. Song, and S. Ermon, “CSDI: Conditional score-based diffusion models for probabilistic time series imputation,” in *Advances in Neural Information Processing Systems (NeurIPS 2021)*, vol. 34, pp. 24804–24816, 2021. Disponible en: <https://arxiv.org/abs/2107.03502>.
- [64] A. Bing *et al.*, “Healthgen: Equitable synthetic ehr generation,” *PMC*, 2022.

Apéndice A

Ejemplo de anexo: Planificación y gestión del proyecto (opcional)

El Apéndice A puede incluirse como recomendación si se ha realizado un proyecto de tipo práctico práctico de desarrollo del software.

De forma general se puede incluir la especificación requerimientos del proyecto, la información sobre stakeholders del proyecto, la justificación (interés, oportunidad, coste/beneficio...), etc.

En cuanto a la planificación: se indicarán las diferentes tareas a desarrollar durante el proyecto ordenadas cronológicamente.

En cuanto a la descripción: breve definición de las tareas indicando su relación con los requisitos del proyecto, método de trabajo, tecnologías a utilizar para desarrollar cada tarea, posibles obstáculos y riesgos.

En cuanto a la validación: qué método se utilizará para validar el proyecto (si se trata de desarrollo de software, indicando métricas referidas a `code coverage`", etc., pruebas unitarias, etc.).

En cuanto al estudio de costes y sostenibilidad: se indicarán las horas de programador necesarias para llevarlo a cabo, gasto en recursos, bibliografía, tiempos de conexión, etc.

En cuanto a la temporización, lo suyo es un Diagrama de Gantt donde quede claro el tiempo invertido en la realización de cada una de las tareas y su secuenciación/entrelazamiento a los largo de los meses de realización del proyecto.

Finalmente se acabará justificando la sostenibilidad de los productos software generados en cuanto a costes de prueba y mantenimiento del software.

Una posible estructuración de la gestión y planificación del proyecto podría ser en las siguientes subsecciones:

A.1. Metodología/Ciclo de vida

A.2. Herramientas y plataformas utilizadas para el desarrollo del proyecto

A.3. Costes del proyecto

A.4. Gestión del proyecto. Planificación temporal. Diagrama de Gantt

A.5. Texto añadido

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras

nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetur at, consectetur sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

Morbi luctus, wisi viverra faucibus pretium, nibh est placerat odio, nec commodo wisi enim eget quam. Quisque libero justo, consectetur a, feugiat vitae, porttitor eu, libero. Suspendisse sed mauris vitae elit sollicitudin malesuada. Maecenas ultricies eros sit amet ante. Ut venenatis velit. Maecenas sed mi eget dui varius euismod. Phasellus aliquet volutpat odio. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque sit amet pede ac sem eleifend consectetur. Nullam elementum, urna vel imperdiet sodales, elit ipsum pharetra ligula, ac pretium ante justo a nulla. Curabitur tristique arcu eu metus. Vestibulum lectus. Proin mauris. Proin eu nunc eu urna hendrerit faucibus. Aliquam auctor, pede consequat laoreet varius, eros tellus scelerisque quam, pellentesque hendrerit ipsum dolor sed augue. Nulla nec lacus.

Suspendisse vitae elit. Aliquam arcu neque, ornare in, ullamcorper quis, commodo eu, libero. Fusce sagittis erat at erat tristique mollis. Maecenas sapien libero, molestie et, lobortis in, sodales eget, dui. Morbi ultrices rutrum lorem. Nam elementum ullamcorper leo. Morbi dui. Aliquam sagittis. Nunc placerat. Pellentesque tristique sodales est. Maecenas imperdiet lacinia velit. Cras non urna. Morbi eros pede, suscipit ac, varius vel, egestas non, eros. Praesent malesuada, diam id pretium elementum, eros sem dictum tortor, vel consectetur odio sem sed wisi.

Sed feugiat. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Ut pellentesque augue sed urna. Vestibulum diam eros, fringilla et, consectetur eu, nonummy id, sapien. Nullam at lectus. In sagittis ultrices mauris. Curabitur malesuada erat sit amet massa. Fusce blandit. Aliquam erat volutpat. Aliquam euismod. Aenean vel lectus. Nunc imperdiet justo nec dolor.

Etiam euismod. Fusce facilisis lacinia dui. Suspendisse potenti. In mi erat, cursus id, nonummy sed, ullamcorper eget, sapien. Praesent pretium, magna in eleifend egestas, pede pede pretium lorem, quis consectetur tortor sapien facilisis magna. Mauris quis magna varius nulla scelerisque imperdiet. Aliquam non quam. Aliquam porttitor quam a lacus. Praesent vel arcu ut tortor cursus volutpat. In vitae pede quis diam bibendum placerat. Fusce elementum convallis neque. Sed dolor orci, scelerisque ac, dapibus nec, ultricies ut, mi. Duis nec dui quis leo sagittis commodo.

Aliquam lectus. Vivamus leo. Quisque ornare tellus ullamcorper nulla. Mauris porttitor pharetra tortor. Sed fringilla justo sed mauris. Mauris tellus. Sed non leo. Nullam elementum, magna in cursus sodales, augue est scelerisque sapien, venenatis congue nulla arcu et pede. Ut suscipit enim vel sapien. Donec congue. Maecenas urna mi, suscipit in, placerat ut, vestibulum ut, massa. Fusce ultrices nulla et nisl.

Etiam ac leo a risus tristique nonummy. Donec dignissim tincidunt nulla. Vestibulum rhoncus molestie odio. Sed lobortis, justo et pretium lobortis, mauris turpis condimentum augue, nec ultricies nibh arcu pretium enim. Nunc purus neque, placerat id, imperdiet sed, pellentesque nec, nisl. Vestibulum imperdiet neque non sem accumsan laoreet. In hac habitasse platea dictumst. Etiam condimentum facilisis libero. Suspendisse in elit quis nisl aliquam dapibus. Pellentesque auctor sapien. Sed egestas sapien nec lectus. Pellentesque vel dui vel neque bibendum viverra. Aliquam porttitor nisl nec pede. Proin mattis libero vel turpis. Donec rutrum mauris et libero. Proin euismod porta felis. Nam lobortis, metus quis elementum commodo, nunc lectus elementum mauris, eget vulputate ligula tellus eu neque. Vivamus eu dolor.

Nulla in ipsum. Praesent eros nulla, congue vitae, euismod ut, commodo a, wisi. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Aenean nonummy magna non leo. Sed felis erat, ullamcorper in, dictum non, ultricies ut, lectus. Proin vel arcu a odio lobortis euismod. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Proin ut est. Aliquam odio. Pellentesque massa turpis, cursus eu, euismod nec, tempor congue, nulla. Duis viverra gravida mauris. Cras tincidunt. Curabitur eros ligula, varius ut, pulvinar in, cursus faucibus, augue.

Apéndice B

Ejemplo de anexo: Innovación (opcional)

El Apéndice B puede ser recomendable incluir en los casos en los que se realice un proyecto práctico de desarrollo del software en los que se quiera hacer referencia a la posible innovación en el marco empresarial.

En caso positivo, se recomienda una posible estructuración en las siguientes subsecciones:

B.1. Estudio del Mercado

Contenido del estudio del mercado

B.1.1. Segmentos de Clientes

Contenido sobre los segmentos de clientes

B.1.2. Competidores

Información sobre los competidores

B.2. Propuesta de Valor

Descripción de la propuesta de valor

B.3. Recursos Clave

Enumeración de los recursos clave

B.4. Actividades Clave

Descripción de las actividades clave

B.5. Socios y Alianzas Clave

Detalles sobre socios y alianzas

B.6. Estructura de Costes Prevista

Desglose de los costes estimados. Incluir aquí la estimación presupuestaria de Costes

B.7. Vías de Ingresos

Estrategias para generar ingresos

Incluir aquí la proyección de ingresos a lo largo de los primeros tres años. Incluir las vías o fuentes de financiación.

B.8. Canales de Distribución

Descripción de los canales de distribución

B.9. Relación con los Clientes

Cómo se relacionará con los clientes

B.10. Descripción del Producto Mínimo Viable

Detalles sobre el producto mínimo viable

B.11. Roadmap de Desarrollo

Planificación del desarrollo

B.12. Aspectos Legales

Consideraciones legales, licencias y patentes

B.13. Texto añadido

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis

natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetur at, consectetur sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

Morbi luctus, wisi viverra faucibus pretium, nibh est placerat odio, nec commodo wisi enim eget quam. Quisque libero justo, consectetur a, feugiat vitae, porttitor eu, libero. Suspendisse sed mauris vitae elit sollicitudin malesuada. Maecenas ultricies eros sit amet ante. Ut venenatis velit. Maecenas sed mi eget dui varius euismod. Phasellus aliquet volutpat odio. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque sit amet

pede ac sem eleifend consectetur. Nullam elementum, urna vel imperdiet sodales, elit ipsum pharetra ligula, ac pretium ante justo a nulla. Curabitur tristique arcu eu metus. Vestibulum lectus. Proin mauris. Proin eu nunc eu urna hendrerit faucibus. Aliquam auctor, pede consequat laoreet varius, eros tellus scelerisque quam, pellentesque hendrerit ipsum dolor sed augue. Nulla nec lacus.

Suspendisse vitae elit. Aliquam arcu neque, ornare in, ullamcorper quis, commodo eu, libero. Fusce sagittis erat at erat tristique mollis. Maecenas sapien libero, molestie et, lobortis in, sodales eget, dui. Morbi ultrices rutrum lorem. Nam elementum ullamcorper leo. Morbi dui. Aliquam sagittis. Nunc placerat. Pellentesque tristique sodales est. Maecenas imperdiet lacinia velit. Cras non urna. Morbi eros pede, suscipit ac, varius vel, egestas non, eros. Praesent malesuada, diam id pretium elementum, eros sem dictum tortor, vel consectetur odio sem sed wisi.

Sed feugiat. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Ut pellentesque augue sed urna. Vestibulum diam eros, fringilla et, consectetur eu, nonummy id, sapien. Nullam at lectus. In sagittis ultrices mauris. Curabitur malesuada erat sit amet massa. Fusce blandit. Aliquam erat volutpat. Aliquam euismod. Aenean vel lectus. Nunc imperdiet justo nec dolor.

Etiam euismod. Fusce facilisis lacinia dui. Suspendisse potenti. In mi erat, cursus id, nonummy sed, ullamcorper eget, sapien. Praesent pretium, magna in eleifend egestas, pede pede pretium lorem, quis consectetur tortor sapien facilisis magna. Mauris quis magna varius nulla scelerisque imperdiet. Aliquam non quam. Aliquam porttitor quam a lacus. Praesent vel arcu ut tortor cursus volutpat. In vitae pede quis diam bibendum placerat. Fusce elementum convallis neque. Sed dolor orci, scelerisque ac, dapibus nec, ultricies ut, mi. Duis nec dui quis leo sagittis commodo. Aliquam lectus. Vivamus leo. Quisque ornare tellus ullamcorper nulla. Mauris porttitor pharetra tortor. Sed fringilla justo sed mauris. Mauris tellus. Sed non leo. Nullam elementum, magna in cursus sodales, augue est scelerisque sapien, venenatis congue nulla arcu et pede. Ut suscipit enim vel sapien. Donec congue. Maecenas urna mi, suscipit in, placerat ut, vestibulum ut, massa. Fusce ultrices nulla et nisl.

Etiam ac leo a risus tristique nonummy. Donec dignissim tincidunt nulla. Vestibulum rhoncus molestie odio. Sed lobortis, justo et pretium lobortis, mauris turpis condimentum augue, nec ultricies nibh arcu pretium enim. Nunc purus neque, placerat id, imperdiet sed, pellentesque nec, nisl. Vestibulum imperdiet neque non sem accumsan laoreet. In hac habitasse platea dictumst. Etiam condimentum facilisis libero. Suspendisse in elit quis nisl aliquam dapibus. Pellentesque auctor sapien. Sed egestas sapien nec lectus. Pellentesque vel dui vel neque bibendum viverra. Aliquam porttitor nisl nec pede. Proin mattis libero vel turpis. Donec rutrum mauris et libero. Proin euismod porta felis. Nam lobortis, metus quis elementum commodo, nunc lectus elementum mauris, eget vulputate ligula tellus eu neque. Vivamus eu dolor.

Nulla in ipsum. Praesent eros nulla, congue vitae, euismod ut, commodo a, wisi. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Aenean nonummy magna non leo. Sed felis erat, ullamcorper in, dictum non, ultricies ut, lectus. Proin vel arcu a odio lobortis euismod. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Proin ut est. Aliquam odio. Pellentesque massa turpis, cursus eu, euismod nec, tempor congue, nulla. Duis viverra gravida mauris. Cras tincidunt. Curabitur eros ligula, varius ut, pulvinar in, cursus faucibus, augue.

Apéndice C

Ejemplo de anexo: Manual de usuario (opcional)

Este es un apéndice opcional, en caso de que quieras añadir un manual de usuario del software realizado.

Puedes incluir tantos capítulos de Anexos como te haga falta. Si no tienes anexos, puedes comentar las líneas en el fichero **tfm.tex**.

C.1. Texto añadido

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat.

Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetur at, consectetur sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

Morbi luctus, wisi viverra faucibus pretium, nibh est placerat odio, nec commodo wisi enim eget quam. Quisque libero justo, consectetur a, feugiat vitae, porttitor eu, libero. Suspendisse sed mauris vitae elit sollicitudin malesuada. Maecenas ultricies eros sit amet ante. Ut venenatis velit. Maecenas sed mi eget dui varius euismod. Phasellus aliquet volutpat odio. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque sit amet pede ac sem eleifend consectetur. Nullam elementum, urna vel imperdiet sodales, elit ipsum pharetra ligula, ac pretium ante justo a nulla. Curabitur tristique arcu eu metus. Vestibulum lectus. Proin mauris. Proin eu nunc eu urna hendrerit faucibus. Aliquam auctor, pede consequat laoreet varius, eros tellus scelerisque quam, pellentesque hendrerit ipsum dolor sed augue. Nulla nec lacus.

Suspendisse vitae elit. Aliquam arcu neque, ornare in, ullamcorper quis, commodo eu, libero. Fusce sagittis erat at erat tristique mollis. Maecenas sapien libero, molestie et, lobortis in, sodales eget, dui. Morbi ultrices rutrum lorem. Nam elementum ullamcorper leo. Morbi dui. Aliquam sagittis. Nunc placerat. Pellentesque tristique sodales est. Maecenas imperdiet lacinia velit. Cras non urna. Morbi eros pede, suscipit ac, varius vel, egestas non, eros. Praesent malesuada, diam id pretium elementum, eros sem dictum tortor, vel consectetur odio sem sed wisi.

Sed feugiat. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Ut pellentesque augue sed urna. Vestibulum diam eros, fringilla et, consectetur eu, no-

nummy id, sapien. Nullam at lectus. In sagittis ultrices mauris. Curabitur malesuada erat sit amet massa. Fusce blandit. Aliquam erat volutpat. Aliquam euismod. Aenean vel lectus. Nunc imperdiet justo nec dolor.

Etiam euismod. Fusce facilisis lacinia dui. Suspendisse potenti. In mi erat, cursus id, nonummy sed, ullamcorper eget, sapien. Praesent pretium, magna in eleifend egestas, pede pede pretium lorem, quis consectetur tortor sapien facilisis magna. Mauris quis magna varius nulla scelerisque imperdiet. Aliquam non quam. Aliquam porttitor quam a lacus. Praesent vel arcu ut tortor cursus volutpat. In vitae pede quis diam bibendum placerat. Fusce elementum convallis neque. Sed dolor orci, scelerisque ac, dapibus nec, ultricies ut, mi. Duis nec dui quis leo sagittis commodo. Aliquam lectus. Vivamus leo. Quisque ornare tellus ullamcorper nulla. Mauris porttitor pharetra tortor. Sed fringilla justo sed mauris. Mauris tellus. Sed non leo. Nullam elementum, magna in cursus sodales, augue est scelerisque sapien, venenatis congue nulla arcu et pede. Ut suscipit enim vel sapien. Donec congue. Maecenas urna mi, suscipit in, placerat ut, vestibulum ut, massa. Fusce ultrices nulla et nisl.

Etiam ac leo a risus tristique nonummy. Donec dignissim tincidunt nulla. Vestibulum rhoncus molestie odio. Sed lobortis, justo et pretium lobortis, mauris turpis condimentum augue, nec ultricies nibh arcu pretium enim. Nunc purus neque, placerat id, imperdiet sed, pellentesque nec, nisl. Vestibulum imperdiet neque non sem accumsan laoreet. In hac habitasse platea dictumst. Etiam condimentum facilisis libero. Suspendisse in elit quis nisl aliquam dapibus. Pellentesque auctor sapien. Sed egestas sapien nec lectus. Pellentesque vel dui vel neque bibendum viverra. Aliquam porttitor nisl nec pede. Proin mattis libero vel turpis. Donec rutrum mauris et libero. Proin euismod porta felis. Nam lobortis, metus quis elementum commodo, nunc lectus elementum mauris, eget vulputate ligula tellus eu neque. Vivamus eu dolor.

Nulla in ipsum. Praesent eros nulla, congue vitae, euismod ut, commodo a, wisi. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Aenean nonummy magna non leo. Sed felis erat, ullamcorper in, dictum non, ultricies ut, lectus. Proin vel arcu a odio lobortis euismod. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Proin ut est. Aliquam odio. Pellentesque massa turpis, cursus eu, euismod nec, tempor congue, nulla. Duis viverra gravida mauris. Cras tincidunt. Curabitur eros ligula, varius ut, pulvinar in, cursus faucibus, augue.

